

Introduction au calcul de probabilités

Application au calcul de risque – Assurantiel, technologique, naturel
Cours, TD et corrigés

F. Richard

ENSAR — Sciences du Risque et de la Donnée

Notations. On note $q = 1 - p$, A^c le complémentaire de A et $\mathbf{1}_A$ l'indicatrice de A (qui vaut 1 si A est réalisé, 0 sinon). Chaque séance comprend les objectifs, le cours avec les démonstrations, les énoncés de TD puis leurs corrigés. Avant de commencer, lisez l'annexe A : elle présente les objectifs du cours, l'enchaînement des séances et la manière de travailler.

Organisation. Le cours est prévu pour cinq séances de deux heures en présence des étudiants, complétées par un travail personnel : lecture préalable de certaines parties du cours et préparation d'exercices, puis exercices d'approfondissement après la séance. Les exercices nécessitant un ordinateur (scripts Python) se prêtent particulièrement au travail personnel.

Séance	À préparer	En séance	Après la séance
1. Espérance et variance d'une somme	Rappels ; TD1, ex. 1 à 3	Cours ; TD1, ex. 4, 5, 9	TD1, ex. 6 à 8
2. Fonctions génératrices, sommes aléatoires, mélanges	Rappels d'analyse ; TD2, ex. 1	Cours ; TD2, ex. 4, 5, 8	TD2, ex. 2, 3, 6, 7
3. Inégalités, lois limites, extrêmes	TD3, ex. 1	Cours ; TD3, ex. 2, 3, 7	TD3, ex. 4 à 6 et 8
4. Mesures de risque, événements rares	Quantiles ; TD4, ex. 1	Cours ; TD4, ex. 2, 3	TD4, ex. 4
5. Vecteurs aléatoires et dépendance	Matrice de covariance ; TD5, ex. 1	Cours ; TD5, ex. 3, 4	TD5, ex. 2, 5

Table des matières

1 Séance 1 — Espérance et variance d'une somme	4
1.1 Cours	4
1.1.1 Rappels et notations	4
1.1.2 Loi conjointe, lois marginales, indépendance	6
1.1.3 Théorème de transfert	8
1.1.4 Linéarité et croissance	8
1.1.5 Espérance d'un produit	9
1.1.6 Covariance	10
1.1.7 Variance : formule de Koenig, transformation affine, somme	10
1.1.8 Coefficient de corrélation	11
1.1.9 Indicatrices	11
1.1.10 Variance totale	12
1.1.11 Espérance conditionnelle sachant une variable	13
1.2 TD 1	14
1.3 Corrigés du TD 1	17

2	Séance 2 — Fonctions génératrices, lois de Poisson, changements de variable	26
2.1	Cours	26
2.1.1	Rappels d'analyse	26
2.1.2	Définition	26
2.1.3	La fonction génératrice caractérise la loi	26
2.1.4	Calcul des moments	27
2.1.5	Somme de variables indépendantes	27
2.1.6	Fonctions génératrices des lois usuelles	27
2.1.7	Convergence en loi et approximation de Poisson	28
2.1.8	Sommes aléatoires	28
2.1.9	Amincissement d'une loi de Poisson	29
2.1.10	Mélanges de lois de Poisson et surdispersion	30
2.1.11	Changement de variable	32
2.1.12	Méthode d'inversion	32
2.2	TD 2	33
2.3	Corrigés du TD 2	35
3	Séance 3 — Inégalités et lois limites	39
3.1	Cours	39
3.1.1	Inégalités de Markov et de Chebyshev	39
3.1.2	Borne de Chernoff	40
3.1.3	Loi faible des grands nombres	40
3.1.4	Fonction génératrice des moments	40
3.1.5	Théorème central limite	41
3.1.6	Intervalle de confiance d'un résultat Monte-Carlo	42
3.1.7	Approximation normale en pratique	43
3.1.8	Loi du maximum et valeurs extrêmes	43
3.2	TD 3	44
3.3	Corrigés du TD 3	46
4	Séance 4 — Mesures de risque et événements rares	50
4.1	Cours	50
4.1.1	Quantiles	50
4.1.2	Value-at-Risk	50
4.1.3	Tail Value-at-Risk	51
4.1.4	Lien avec les valeurs extrêmes	52
4.1.5	Estimation empirique	52
4.1.6	Échantillonnage préférentiel	53
4.2	TD 4	53
4.3	Corrigés du TD 4	54
5	Séance 5 — Vecteurs aléatoires et dépendance	56
5.1	Cours	56
5.1.1	Vecteurs aléatoires et matrice de covariance	56
5.1.2	Agrégation des risques	56
5.1.3	Vecteurs gaussiens	56
5.1.4	VaR gaussienne et diversification	58
5.1.5	Limites de la corrélation : la dépendance de queue	58
5.1.6	Ouverture : les copules	58
5.2	TD 5	59
5.3	Corrigés du TD 5	60

A	Présentation du cours	62
A.1	Pourquoi ce cours ?	62
A.2	Séance 1 : additionner des variables, conditionner	62
A.3	Séance 2 : sommes aléatoires, hétérogénéité, transformations	62
A.4	Séance 3 : garanties, lois limites, extrêmes	63
A.5	Séance 4 : mesurer le risque, simuler l'improbable	63
A.6	Séance 5 : plusieurs risques à la fois	63
A.7	Les fils conducteurs du cours	64
A.8	Ce que vous saurez faire à l'issue du cours	64
A.9	Comment travailler	64

1 Séance 1 — Espérance et variance d'une somme

Objectifs. Savoir calculer l'espérance et la variance d'une somme de variables, dépendantes ou non. Découper une variable compliquée en somme d'indicateurs. Décomposer une variance par conditionnement, et prédire une variable à l'aide d'une autre par l'espérance conditionnelle.

1.1 Cours

1.1.1 Rappels et notations

Événements associés à une variable. Une variable aléatoire X associe un nombre $X(\omega)$ à chaque issue ω de l'ensemble fondamental Ω , de sorte que $\{X \leq x\}$ soit un événement pour tout réel x . Elle est dite *discrète* si l'ensemble R_X de ses valeurs est fini ou dénombrable. On note

$$\{X = x\} = \{\omega \in \Omega : X(\omega) = x\},$$

l'ensemble des issues pour lesquelles X prend la valeur x ; c'est un événement, donc une partie de Ω . De même, $\{X \in B\}$ est l'ensemble des issues pour lesquelles $X(\omega)$ appartient à B . Enfin, $\{X = x, Y = y\}$ ou $\{X = x \cap Y = y\}$ désigne l'intersection $\{X = x\} \cap \{Y = y\}$: les issues pour lesquelles, *à la fois*, X vaut x et Y vaut y .

Système complet. Des événements $A_1, A_2, \dots$ (en nombre fini ou dénombrable) forment un système complet s'ils sont deux à deux incompatibles ($A_i \cap A_j = \emptyset$ pour $i \neq j$) et si leur réunion est Ω . Autrement dit, chaque issue appartient à *un et un seul* des A_i .

Additivité. Si $A_1, A_2, \dots$ sont deux à deux incompatibles, $\mathbb{P}(\bigcup_i A_i) = \sum_i \mathbb{P}(A_i)$. C'est un axiome des probabilités ; lorsque les A_i sont en nombre infini dénombrable, on parle d'additivité dénombrable.

Distributivité. Pour tout événement A et toute famille (B_i) ,

$$A \cap \left(\bigcup_i B_i \right) = \bigcup_i (A \cap B_i).$$

On le vérifie élément par élément : une issue ω appartient au membre de gauche si et seulement si $\omega \in A$ et ω appartient à l'un des B_i ; c'est exactement dire que ω appartient à l'un des $A \cap B_i$, c'est-à-dire au membre de droite.

Séries. Une variable discrète peut prendre une infinité de valeurs : les espérances sont alors des sommes d'une infinité de termes, c'est-à-dire des *séries*. Une série $\sum_k u_k$ est dite *absolument convergente* si $\sum_k |u_k| < \infty$. On admet le résultat suivant, utilisé en permanence :

Si une série est absolument convergente, ou si tous ses termes sont positifs, on peut réordonner ses termes, les regrouper par paquets, ou intervertir deux signes somme ($\sum_x \sum_y = \sum_y \sum_x$), sans changer le résultat (pour une série à termes positifs, ce résultat peut valoir $+\infty$).

Sans cette hypothèse, ces manipulations peuvent changer la valeur de la somme : c'est pourquoi les énoncés qui suivent précisent toujours « si l'espérance existe ».

Espérance et variance (cas discret). Soit X discrète, de loi $p(x) = \mathbb{P}(X = x)$ pour $x \in R_X$. On dit que X admet une espérance si $\sum_x |x|p(x) < \infty$, et l'on pose alors $\mathbb{E}[X] = \sum_x x p(x)$. Si $X \geq 0$, on pose dans tous les cas $\mathbb{E}[X] = \sum_x x p(x) \in [0, +\infty]$ (série à termes positifs). On dit que X est de variance finie si $\mathbb{E}[X^2] < \infty$. Elle admet alors une espérance, car $|x| \leq \frac{1}{2}(1 + x^2)$ pour tout réel x (c'est l'inégalité $(|x| - 1)^2 \geq 0$) ; sa variance $\text{Var } X = \mathbb{E}[(X - \mu)^2]$, où $\mu = \mathbb{E}[X]$, est finie, car $(x - \mu)^2 \leq 2x^2 + 2\mu^2$; son écart-type est $\sigma = \sqrt{\text{Var } X}$.

Ce que garantit la condition $\sum_x |x|p(x) < \infty$. Cette condition n'est pas une formalité : c'est elle qui fait de $\mathbb{E}[X]$ un nombre réel unique, sur lequel toutes les règles du cours s'appliquent. Voici ce qu'elle apporte.

(1) **On sépare les valeurs positives et négatives.** Posons

$$P = \sum_{x>0} x p(x) \quad \text{et} \quad N = \sum_{x<0} |x| p(x).$$

Ce sont deux séries à termes positifs : chacune a une valeur dans $[0, +\infty]$, qui ne dépend pas de l'ordre des termes (rappel sur les séries). Comme $|x| = x$ si $x > 0$ et $|x| = -x$ si $x < 0$, en regroupant les termes selon le signe de x (ce qui est permis, les termes étant positifs),

$$\sum_x |x| p(x) = P + N.$$

La condition $\sum_x |x| p(x) < \infty$ dit donc exactement que P et N sont finis tous les deux. On a alors $\mathbb{E}[X] = P - N$, et $|\mathbb{E}[X]| = |P - N| \leq P + N = \mathbb{E}[X]$.

(2) **Pas de forme « $\infty - \infty$ ».** Trois situations peuvent se présenter.

- P et N finis : $\mathbb{E}[X] = P - N$ est un nombre réel bien défini. C'est le seul cas où X admet une espérance.
- *Un seul côté infini* (paradoxe de Saint-Pétersbourg). Soit $X = 2^k$ avec probabilité 2^{-k} , pour $k \geq 1$ (les probabilités ont bien pour somme $\sum_{k \geq 1} 2^{-k} = 1$). Alors $N = 0$ et $P = \sum_{k \geq 1} 2^k \cdot 2^{-k} = 1 + 1 + 1 + \dots = +\infty$. On écrit $\mathbb{E}[X] = +\infty$: ce n'est pas un nombre réel, et X n'admet pas d'espérance finie.
- *Les deux côtés infinis*. Soit X qui vaut $(-1)^{k+1} 2^k / k$ avec probabilité 2^{-k} , pour $k \geq 1$. Le terme $x p(x)$ correspondant vaut $(-1)^{k+1} / k$:

$$P = 1 + \frac{1}{3} + \frac{1}{5} + \dots = +\infty, \quad N = \frac{1}{2} + \frac{1}{4} + \frac{1}{6} + \dots = +\infty.$$

La quantité « $P - N$ » n'a pas de sens. Additionnés dans l'ordre des k , les termes donnent $1 - \frac{1}{2} + \frac{1}{3} - \frac{1}{4} + \dots = \ln 2$; dans un autre ordre (un terme positif, puis deux négatifs), ils donnent $\frac{1}{2} \ln 2$, et l'on peut obtenir n'importe quelle valeur en les réordonnant (théorème de Riemann, admis). X n'a pas d'espérance. La loi de Cauchy est l'analogue à densité de cet exemple (exercice 3 du TD 1, remarque du corrigé).

- (3) **Le résultat ne dépend pas de l'ordre de calcul.** Les valeurs d'une variable aléatoire n'ont pas d'ordre naturel dans lequel les additionner : un entier relatif peut se parcourir $0, 1, -1, 2, -2, \dots$ ou d'une infinité d'autres façons. Sous la condition, P et N sont finis et indépendants de l'ordre (point 1), donc $\mathbb{E}[X] = P - N$ l'est aussi. Pour une variable à densité, c'est l'équivalent de « les bornes peuvent partir à l'infini de n'importe quelle façon ».
- (4) **On peut calculer comme avec des sommes finies.** Les démonstrations du cours réordonnent, regroupent ou intervertissent des sommes : le théorème de transfert regroupe les valeurs de X selon celle de $g(X)$; la linéarité sépare une somme en plusieurs et intervertit $\sum_x \sum_y$; la variance totale et l'espérance conditionnelle découpent selon un système complet. La convergence absolue est exactement ce qui autorise ces manipulations (rappel sur les séries).
- (5) **Les valeurs extrêmes pèsent peu.** Sous la condition, $\sum_{|x|>M} |x| p(x) \rightarrow 0$ quand $M \rightarrow +\infty$. En effet, soit $\varepsilon > 0$. La somme $\sum_x |x| p(x)$, finie, est la limite de ses sommes partielles : il existe un ensemble fini F de valeurs tel que $\sum_{x \notin F} |x| p(x) < \varepsilon$. Si M dépasse toutes les valeurs $|x|$ pour $x \in F$, les valeurs telles que $|x| > M$ sont hors de F , donc $\sum_{|x|>M} |x| p(x) \leq \sum_{x \notin F} |x| p(x) < \varepsilon$. Les valeurs très grandes, même rares, ne peuvent donc pas à elles seules modifier la moyenne de façon importante. C'est ce qui permet à la moyenne d'un échantillon de se stabiliser (loi des grands nombres, séance 3) ; pour la loi de Cauchy, où la condition est violée, une seule observation énorme suffit à déplacer la moyenne, qui ne converge jamais (TD 3, exercice 4).

Ce que la condition ne garantit pas : une variance finie. Soit X à valeurs dans $\{1, 2, 3, \dots\}$, avec $\mathbb{P}(X = k) = c/k^3$, où $c = 1/\sum_{j \geq 1} j^{-3}$ assure que la somme des probabilités vaut 1. Alors $\mathbb{E}[X] = c \sum_k k \cdot k^{-3} = c \sum_k 1/k^2 < \infty$, mais $\mathbb{E}[X^2] = c \sum_k k^2 \cdot k^{-3} = c \sum_k 1/k = +\infty$: X admet une espérance mais pas de variance finie. (Les lois de Pareto de paramètre $\theta \in]1, 2]$ de la séance 4 en sont l'analogie à densité.)

En résumé, $\sum_x |x| p(x) < \infty$ signifie que la masse totale des valeurs, comptées sans leur signe et pondérées par leurs probabilités, est finie. C'est ce qui fait de $\mathbb{E}[X]$ un nombre réel unique, indépendant de l'ordre de calcul, sur lequel s'appliquent toutes les règles du cours. Pour une variable positive, $|x| = x$ et la condition se réduit à $\mathbb{E}[X] < \infty$: il n'y a rien de plus à vérifier dès que le calcul de $\mathbb{E}[X]$ donne une valeur finie. Pour une variable qui ne prend qu'un nombre fini de valeurs, les sommes sont finies et la condition est toujours satisfaite.

1.1.2 Loi conjointe, lois marginales, indépendance

Définition 1.1. Soient X et Y deux variables aléatoires discrètes. Leur *loi conjointe* est la fonction

$$p(x, y) = \mathbb{P}(X = x \cap Y = y).$$

Proposition 1.2 (Lois marginales). Les lois de X et de Y s'obtiennent en sommant la loi conjointe :

$$p_X(x) = \sum_y p(x, y), \quad p_Y(y) = \sum_x p(x, y).$$

En particulier, $\sum_x \sum_y p(x, y) = \sum_x p_X(x) = 1$.

Démonstration. Notons R_Y l'ensemble (fini ou dénombrable) des valeurs de Y .

Étape 1 (les événements $\{Y = y\}$ forment un système complet). Ils sont deux à deux incompatibles, car Y ne peut pas prendre deux valeurs à la fois : une issue ω ne peut pas vérifier à la fois $Y(\omega) = y$ et $Y(\omega) = y'$ avec $y \neq y'$. Leur réunion est Ω , car pour toute issue ω , $Y(\omega)$ prend une certaine valeur $y \in R_Y$, et ω appartient alors à $\{Y = y\}$.

Étape 2 (découpage de $\{X = x\}$ selon la valeur de Y). Montrons que

$$\{X = x\} = \{X = x\} \cap \Omega = \bigcup_{y \in R_Y} (\{X = x\} \cap \{Y = y\}).$$

La première égalité est une évidence ensembliste : pour toute partie A de Ω , $A \cap \Omega = A$, puisque intersecter avec Ω ne retire aucune issue. Elle sert seulement à faire apparaître Ω , que l'on va découper. Pour la seconde, on remplace Ω par la réunion des $\{Y = y\}$ (étape 1), puis on applique la distributivité :

$$\{X = x\} \cap \Omega = \{X = x\} \cap \bigcup_{y \in R_Y} \{Y = y\} = \bigcup_{y \in R_Y} (\{X = x\} \cap \{Y = y\}).$$

Interprétation : pour que X prenne la valeur x , il faut bien que Y prenne, au même moment, une certaine valeur y . On range donc les issues de $\{X = x\}$ dans des « tiroirs » selon la valeur de Y .

Étape 3 (les morceaux sont disjoints). Si une issue appartenait à la fois à $\{X = x\} \cap \{Y = y\}$ et à $\{X = x\} \cap \{Y = y'\}$, on aurait $Y(\omega) = y$ et $Y(\omega) = y'$, donc $y = y'$. Chaque issue de $\{X = x\}$ tombe donc dans un seul tiroir.

Étape 4 (additivité). La réunion de l'étape 2 est formée d'événements deux à deux incompatibles (étape 3). L'additivité donne

$$\mathbb{P}(X = x) = \sum_{y \in R_Y} \mathbb{P}(X = x \cap Y = y) = \sum_y p(x, y).$$

Le raisonnement est symétrique pour Y (on découpe $\{Y = y\}$ selon la valeur de X). Enfin, $\sum_x \sum_y p(x, y) = \sum_x p_X(x) = 1$, car la somme des probabilités d'une loi vaut 1. $\square$

Remarque. C'est la forme du théorème des probabilités totales sans conditionnement. La forme $\mathbb{P}(A) = \sum_i \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$ s'en déduit en écrivant $\mathbb{P}(A \cap B_i) = \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$, mais elle suppose $\mathbb{P}(B_i) > 0$; la forme avec intersections n'a pas besoin de cette hypothèse. Lorsque R_Y est infini, l'étape 4 utilise l'additivité dénombrable. Le même raisonnement « par tiroirs » reviendra dans plusieurs démonstrations : on le signalera à chaque fois.

Définition 1.3 (Indépendance). Les variables $X_1, \dots, X_n$ sont (mutuellement) indépendantes si, pour tous intervalles $B_1, \dots, B_n$ de $\mathbb{R}$ (éventuellement réduits à un point),

$$\mathbb{P}(X_1 \in B_1 \cap \dots \cap X_n \in B_n) = \mathbb{P}(X_1 \in B_1) \times \dots \times \mathbb{P}(X_n \in B_n).$$

Une suite $(X_i)_{i \geq 1}$ est indépendante si, pour tout n , $X_1, \dots, X_n$ le sont.

Proposition 1.4. Dans le cas discret, X et Y sont indépendantes si et seulement si $p(x, y) = p_X(x)p_Y(y)$ pour tous x, y (et de même pour n variables).

Démonstration. Étape 1 (sens direct). Si X et Y sont indépendantes, on applique la définition avec les intervalles réduits à un point $B_1 = [x, x] = \{x\}$ et $B_2 = [y, y] = \{y\}$: $\mathbb{P}(X = x \cap Y = y) = \mathbb{P}(X = x) \mathbb{P}(Y = y)$, c'est-à-dire $p(x, y) = p_X(x)p_Y(y)$.

Étape 2 (réciproque : découpage). Supposons que la loi conjointe se factorise, et soient B_1, B_2 deux intervalles. Par le raisonnement « par tiroirs » de la proposition précédente (appliqué aux deux variables), l'événement $\{X \in B_1\} \cap \{Y \in B_2\}$ est la réunion disjointe des événements $\{X = x\} \cap \{Y = y\}$, pour x valeur de X dans B_1 et y valeur de Y dans B_2 . L'additivité donne (les sommes portant sur les valeurs $x \in R_X \cap B_1$ et $y \in R_Y \cap B_2$)

$$\mathbb{P}(X \in B_1 \cap Y \in B_2) = \sum_{x \in B_1} \sum_{y \in B_2} p(x, y) = \sum_{x \in B_1} \sum_{y \in B_2} p_X(x) p_Y(y).$$

Étape 3 (factorisation de la double somme). Dans la somme intérieure, $p_X(x)$ ne dépend pas de y : on le sort de la somme sur y , puis on sort de même la somme sur y (qui ne dépend plus de x) de la somme sur x :

$$\sum_{x \in B_1} p_X(x) \sum_{y \in B_2} p_Y(y) = \left(\sum_{x \in B_1} p_X(x) \right) \left(\sum_{y \in B_2} p_Y(y) \right) = \mathbb{P}(X \in B_1) \mathbb{P}(Y \in B_2).$$

Les termes étant positifs, ces manipulations sont licites (rappel sur les séries). Pour n variables, on procède de même avec une somme n -uple. $\square$

Remarque. Dans le cas continu, on remplace la loi conjointe par une densité conjointe $f(x, y)$, telle que $\mathbb{P}((X, Y) \in D) = \iint_D f(x, y) dx dy$. Les densités marginales sont $f_X(x) = \int f(x, y) dy$ et $f_Y(y) = \int f(x, y) dx$, et l'indépendance s'écrit $f(x, y) = f_X(x)f_Y(y)$ (admis).

Remarque (Portée des démonstrations). Les démonstrations de cette séance sont écrites dans le cas discret, où elles sont complètes. Dans le cas continu, tous les énoncés restent vrais, mais certains ne se démontrent **pas** en remplaçant simplement les sommes par des intégrales :

- le théorème de transfert, car $g(X)$ peut n'avoir ni loi discrète ni densité ;
- la linéarité et la croissance, car le couple (X, Y) peut ne pas avoir de densité conjointe (c'est le cas du couple (X, X)).

Ces trois résultats sont **admis dans le cas général** : leur démonstration relève de l'intégrale de Lebesgue. Tout ce qui s'en déduit (covariance, variance d'une somme, variance totale) vaut alors en général. Le théorème du produit se transpose directement lorsque le couple a une densité conjointe $f_X f_Y$ (intersion des intégrales, admise).

1.1.3 Théorème de transfert

Théorème 1.5 (Transfert). Soit X discrète et g une fonction telle que $\sum_x |g(x)| p(x) < \infty$. Alors $g(X)$ admet une espérance et

$$\mathbb{E}[g(X)] = \sum_x g(x) p(x).$$

De même, pour un couple discret (X, Y) et une fonction g telle que $\sum_x \sum_y |g(x, y)| p(x, y) < \infty$, $\mathbb{E}[g(X, Y)] = \sum_x \sum_y g(x, y) p(x, y)$. Si $g \geq 0$, ces formules valent sans hypothèse, dans $[0, +\infty]$. Enfin, si X a une densité f et si g est continue par morceaux avec $\int |g(x)| f(x) dx < \infty$, $\mathbb{E}[g(X)] = \int g(x) f(x) dx$ (admis dans ce cas).

Démonstration. Idée. La variable $Z = g(X)$ prend la valeur z exactement lorsque X prend l'une des valeurs x telles que $g(x) = z$. On calcule donc la loi de Z à partir de celle de X , puis on regroupe.

Étape 1 (loi de Z). Pour une valeur z de Z , l'événement $\{Z = z\}$ est la réunion des événements $\{X = x\}$ pour les x tels que $g(x) = z$. Ces événements sont disjoints (X ne prend qu'une valeur à la fois), donc par additivité

$$\mathbb{P}(Z = z) = \sum_{x: g(x)=z} p(x).$$

Étape 2 (regroupement par paquets). Chaque valeur x de X appartient à un et un seul groupe $\{x : g(x) = z\}$, celui de $z = g(x)$. Pour toute fonction h telle que les séries ci-dessous aient un sens, la série $\sum_x h(x) p(x)$ est donc la série $\sum_z \sum_{x: g(x)=z} h(x) p(x)$, dont les termes ont été rangés par paquets.

Étape 3 (existence de $\mathbb{E}[Z]$). Avec $h = |g|$, les termes sont positifs et le regroupement est toujours permis (rappel sur les séries) :

$$\sum_z |z| \mathbb{P}(Z = z) = \sum_z \sum_{x: g(x)=z} |z| p(x) = \sum_z \sum_{x: g(x)=z} |g(x)| p(x) = \sum_x |g(x)| p(x) < \infty,$$

car dans la somme intérieure, z est justement égal à $g(x)$. Donc Z admet une espérance, et la série $\sum_x g(x) p(x)$ est absolument convergente.

Étape 4 (valeur de $\mathbb{E}[Z]$). Le même calcul avec $h = g$ est alors licite, par convergence absolue :

$$\mathbb{E}[Z] = \sum_z z \mathbb{P}(Z = z) = \sum_z \sum_{x: g(x)=z} g(x) p(x) = \sum_x g(x) p(x).$$

Si $g \geq 0$, l'étape 3 donne directement le résultat dans $[0, +\infty]$.

Pour $g(X, Y)$, la démonstration est identique en remplaçant la valeur x par le couple (x, y) et $p(x)$ par $p(x, y)$. $\square$

Remarque. On calcule $\mathbb{E}[g(X)]$ sans avoir à déterminer la loi de $g(X)$. Par exemple, si X est uniforme sur $\{-1, 0, 1\}$, on obtient directement $\mathbb{E}[X^2] = \frac{1}{3}((-1)^2 + 0^2 + 1^2) = \frac{2}{3}$, sans passer par la loi de X^2 .

1.1.4 Linéarité et croissance

Théorème 1.6 (Linéarité). Si X et Y admettent une espérance, alors pour tous réels a, b, c , la variable $aX + bY + c$ admet une espérance et $\mathbb{E}[aX + bY + c] = a\mathbb{E}[X] + b\mathbb{E}[Y] + c$. Ce résultat est vrai **sans aucune hypothèse d'indépendance**.

Démonstration. *Étape 1 (transfert).* On applique le théorème de transfert à la fonction $g(x, y) = ax + by + c$:

$$\mathbb{E}[aX + bY + c] = \sum_x \sum_y (ax + by + c) p(x, y).$$

La convergence absolue est assurée : $|ax + by + c| \leq |a||x| + |b||y| + |c|$, et $\sum_x \sum_y |x| p(x, y) = \sum_x |x| p_X(x) = \mathbb{E}[X] < \infty$ (loi marginale), de même pour y .

Étape 2 (on sépare en trois sommes). Grâce à la convergence absolue, on peut écrire

$$\sum_x \sum_y (ax + by + c) p(x, y) = a \sum_x \sum_y x p(x, y) + b \sum_x \sum_y y p(x, y) + c \sum_x \sum_y p(x, y).$$

Étape 3 (première somme). Dans $\sum_y x p(x, y)$, le facteur x ne dépend pas de y : on le sort, et il reste la loi marginale : $\sum_x \sum_y x p(x, y) = \sum_x x \sum_y p(x, y) = \sum_x x p_X(x) = \mathbb{E}[X]$.

Étape 4 (deuxième somme). On intervertit les deux sommes, puis on sort y : $\sum_x \sum_y y p(x, y) = \sum_y y \sum_x p(x, y) = \sum_y y p_Y(y) = \mathbb{E}[Y]$.

Étape 5 (troisième somme). $\sum_x \sum_y p(x, y) = 1$ (proposition sur les lois marginales).

Étape 6 (conclusion). $\mathbb{E}[aX + bY + c] = a\mathbb{E}[X] + b\mathbb{E}[Y] + c$. On n'a utilisé que les lois marginales, jamais l'indépendance. $\square$

Corollaire 1.7. $\mathbb{E}[X_1 + \dots + X_n] = \mathbb{E}[X_1] + \dots + \mathbb{E}[X_n]$.

Démonstration. Par récurrence sur n . Pour $n = 1$, il n'y a rien à montrer. Si la formule est vraie pour n variables, on applique la linéarité (avec $a = b = 1$, $c = 0$) aux deux variables $X_1 + \dots + X_n$ et X_{n+1} : $\mathbb{E}[(X_1 + \dots + X_n) + X_{n+1}] = \mathbb{E}[X_1 + \dots + X_n] + \mathbb{E}[X_{n+1}] = \mathbb{E}[X_1] + \dots + \mathbb{E}[X_{n+1}]$. $\square$

Proposition 1.8 (Croissance). Soient X et Y telles que $X \leq Y$ pour toute issue. Si X et Y admettent une espérance, alors $\mathbb{E}[X] \leq \mathbb{E}[Y]$. Si $0 \leq X \leq Y$, l'inégalité $\mathbb{E}[X] \leq \mathbb{E}[Y]$ vaut dans $[0, +\infty]$; en particulier, si $\mathbb{E}[Y] < \infty$, alors X admet une espérance.

Démonstration. Étape 1 (transfert). Le transfert, appliqué au couple (X, Y) et aux fonctions $(x, y) \mapsto x$ et $(x, y) \mapsto y$, donne $\mathbb{E}[X] = \sum_x \sum_y x p(x, y)$ et $\mathbb{E}[Y] = \sum_x \sum_y y p(x, y)$ (dans le cas positif, ces égalités valent dans $[0, +\infty]$).

Étape 2 (comparaison terme à terme). Si $x > y$, l'événement $\{X = x\} \cap \{Y = y\}$ est vide, puisque $X \leq Y$; donc $p(x, y) = 0$. Pour chaque couple (x, y) , on a donc $x p(x, y) \leq y p(x, y)$.

Étape 3 (sommation). En sommant ces inégalités terme à terme, on obtient $\mathbb{E}[X] \leq \mathbb{E}[Y]$. $\square$

1.1.5 Espérance d'un produit

Théorème 1.9. Si X et Y sont indépendantes et si $g(X)$ et $h(Y)$ admettent une espérance, alors $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$. Dans ce cas, $g(X)h(Y)$ admet une espérance. En particulier, $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ si X et Y admettent une espérance. Plus généralement, si $X_1, \dots, X_n$ sont indépendantes et si chaque $g_i(X_i)$ admet une espérance, $\mathbb{E}[\prod_i g_i(X_i)] = \prod_i \mathbb{E}[g_i(X_i)]$.

Démonstration. Étape 1 (indépendance). Comme X et Y sont indépendantes, $p(x, y) = p_X(x)p_Y(y)$ (proposition précédente).

Étape 2 (convergence absolue). Les termes étant positifs, on peut factoriser comme à l'étape 3 ci-dessous : $\sum_x \sum_y |g(x)||h(y)| p_X(x)p_Y(y) = \mathbb{E}[|g(X)|]\mathbb{E}[|h(Y)|] < \infty$. Le transfert s'applique donc à la fonction $g(x)h(y)$, et toutes les manipulations qui suivent sont licites :

$$\mathbb{E}[g(X)h(Y)] = \sum_x \sum_y g(x)h(y) p(x, y) = \sum_x \sum_y g(x)p_X(x) h(y)p_Y(y).$$

Étape 3 (factorisation). À x fixé, $g(x)p_X(x)$ ne dépend pas de y ; on le sort de la somme sur y : $\sum_y g(x)p_X(x) h(y)p_Y(y) = g(x)p_X(x) \sum_y h(y)p_Y(y) = g(x)p_X(x) \mathbb{E}[h(Y)]$. Puis $\mathbb{E}[h(Y)]$ est une constante, que l'on sort de la somme sur x :

$$\mathbb{E}[g(X)h(Y)] = \mathbb{E}[h(Y)] \sum_x g(x)p_X(x) = \mathbb{E}[h(Y)] \mathbb{E}[g(X)].$$

Pour n variables, la somme n -uple se factorise de la même façon, en sortant les facteurs un par un. $\square$

Remarque. Sans indépendance, le résultat est faux en général. Si X suit $\text{Be}(1/2)$ et $Y = X$, alors $\mathbb{E}[XY] = \mathbb{E}[X^2] = \mathbb{E}[X] = 1/2$, alors que $\mathbb{E}[X]\mathbb{E}[Y] = 1/4$.

1.1.6 Covariance

Définition 1.10. Pour X et Y de variances finies, $\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$, où μ_X et μ_Y sont les espérances de X et Y .

Cette espérance existe. En effet, pour tous réels u, v , on a $(|u| - |v|)^2 \geq 0$, c'est-à-dire $u^2 + v^2 - 2|u||v| \geq 0$, soit $|uv| \leq \frac{1}{2}(u^2 + v^2)$. Avec $u = X - \mu_X$ et $v = Y - \mu_Y$, la croissance (pour des variables positives) donne $\mathbb{E}|(X - \mu_X)(Y - \mu_Y)| \leq \frac{1}{2}(\text{Var } X + \text{Var } Y) < \infty$.

Proposition 1.11. $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.

Démonstration. Étape 1 (développement). $(X - \mu_X)(Y - \mu_Y) = XY - \mu_Y X - \mu_X Y + \mu_X \mu_Y$.

Étape 2 (linéarité). μ_X et μ_Y sont des constantes. L'espérance d'une constante fois une variable est la constante fois l'espérance, et l'espérance d'une constante est cette constante. Donc

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mu_Y \mathbb{E}[X] - \mu_X \mathbb{E}[Y] + \mu_X \mu_Y = \mathbb{E}[XY] - \mu_Y \mu_X - \mu_X \mu_Y + \mu_X \mu_Y = \mathbb{E}[XY] - \mu_X \mu_Y.$$

□

Propriétés.

- $\text{Cov}(X, X) = \mathbb{E}[(X - \mu_X)^2] = \text{Var } X$, par définition de la variance.
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$, car le produit $(X - \mu_X)(Y - \mu_Y)$ ne dépend pas de l'ordre.
- Bilinearité : $\text{Cov}(aX + bY, Z) = a \text{Cov}(X, Z) + b \text{Cov}(Y, Z)$. En effet, l'espérance de $aX + bY$ est $a\mu_X + b\mu_Y$, donc $aX + bY - (a\mu_X + b\mu_Y) = a(X - \mu_X) + b(Y - \mu_Y)$; on multiplie par $Z - \mu_Z$ et on applique la linéarité.
- $\text{Cov}(X, c) = 0$ pour toute constante c , car $c - \mathbb{E}[c] = c - c = 0$.

Proposition 1.12. Si X et Y sont indépendantes et de variances finies, alors $\text{Cov}(X, Y) = 0$. La réciproque est fautive (exercice 7 du TD 1).

Démonstration. Une variable de variance finie admet une espérance (car $|x| \leq \frac{1}{2}(1 + x^2)$). Le théorème du produit, avec g et h égales à l'identité, donne $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. La proposition précédente donne alors $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$. □

1.1.7 Variance : formule de Koenig, transformation affine, somme

Proposition 1.13 (Formule de Koenig). Si X est de variance finie, $\text{Var } X = \mathbb{E}[X^2] - \mathbb{E}[X]^2$.

Démonstration. On développe $(X - \mu)^2 = X^2 - 2\mu X + \mu^2$ et on applique la linéarité : $\text{Var } X = \mathbb{E}[X^2] - 2\mu \mathbb{E}[X] + \mu^2 = \mathbb{E}[X^2] - 2\mu^2 + \mu^2 = \mathbb{E}[X^2] - \mu^2$. □

Proposition 1.14. Si X est de variance finie, $\text{Var}(aX + b) = a^2 \text{Var } X$ pour tous réels a, b .

Démonstration. Étape 1. Par linéarité, $\mathbb{E}[aX + b] = a\mu + b$. Donc $aX + b - \mathbb{E}[aX + b] = aX + b - a\mu - b = a(X - \mu)$.

Étape 2. On élève au carré : $(a(X - \mu))^2 = a^2(X - \mu)^2$. On prend l'espérance (linéarité) : $\text{Var}(aX + b) = a^2 \mathbb{E}[(X - \mu)^2] = a^2 \text{Var } X$. La constante b disparaît : décaler une variable ne change pas sa dispersion. □

Théorème 1.15 (Variance d'une somme). Pour des variables de variances finies, $\text{Var}(X + Y) = \text{Var } X + \text{Var } Y + 2 \text{Cov}(X, Y)$, et plus généralement

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var } X_i + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

Démonstration. Étape 1 (on centre). On pose $U_i = X_i - \mu_i$. Par linéarité, l'espérance de $\sum X_i$ est $\sum \mu_i$, donc la somme centrée est $\sum X_i - \sum \mu_i = \sum U_i$, et $\text{Var}(\sum X_i) = \mathbb{E}[(\sum U_i)^2]$.

Étape 2 (cas de deux variables). $(U_1 + U_2)^2 = U_1^2 + U_2^2 + 2U_1U_2$. En prenant l'espérance : $\mathbb{E}[U_1^2] + \mathbb{E}[U_2^2] + 2\mathbb{E}[U_1U_2] = \text{Var } X_1 + \text{Var } X_2 + 2\text{Cov}(X_1, X_2)$.

Étape 3 (cas général). Le carré d'une somme est la somme de tous les produits deux à deux : $(\sum_i U_i)^2 = (\sum_i U_i)(\sum_j U_j) = \sum_i \sum_j U_i U_j$. Parmi ces n^2 termes, les n termes où $i = j$ donnent $\sum_i U_i^2$; les autres vont par paires ($U_i U_j$ et $U_j U_i$ sont égaux), d'où $2 \sum_{i < j} U_i U_j$. Par exemple, pour $n = 3$:

$$(U_1 + U_2 + U_3)^2 = U_1^2 + U_2^2 + U_3^2 + 2U_1U_2 + 2U_1U_3 + 2U_2U_3.$$

Étape 4 (espérance). Par linéarité, avec $\mathbb{E}[U_i^2] = \text{Var } X_i$ et $\mathbb{E}[U_i U_j] = \text{Cov}(X_i, X_j)$, on obtient la formule. $\square$

Corollaire 1.16. *Pour des variables deux à deux indépendantes (ou simplement non corrélées), la variance de la somme est la somme des variances.*

Démonstration. Toutes les covariances sont nulles (proposition précédente sur l'indépendance). $\square$

1.1.8 Coefficient de corrélation

Définition 1.17. Pour X et Y de variances finies et non nulles, $\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$.

Proposition 1.18. *On a toujours $-1 \leq \rho \leq 1$.*

Démonstration. Étape 1 (variables réduites). On pose $X^* = X/\sigma_X$ et $Y^* = Y/\sigma_Y$. Par la formule $\text{Var}(aX) = a^2 \text{Var } X$, $\text{Var } X^* = \text{Var } X/\sigma_X^2 = 1$, et de même $\text{Var } Y^* = 1$. Par bilinéarité, $\text{Cov}(X^*, Y^*) = \text{Cov}(X, Y)/(\sigma_X \sigma_Y) = \rho$.

Étape 2 (somme et différence). Par la variance d'une somme : $\text{Var}(X^* + Y^*) = 1 + 1 + 2\rho = 2(1 + \rho)$. De même, comme $\text{Cov}(X^*, -Y^*) = -\rho$ (bilinéarité), $\text{Var}(X^* - Y^*) = 1 + 1 - 2\rho = 2(1 - \rho)$.

Étape 3 (positivité). Une variance est l'espérance d'un carré, donc elle est positive (croissance). Ainsi $2(1 + \rho) \geq 0$ et $2(1 - \rho) \geq 0$, c'est-à-dire $-1 \leq \rho \leq 1$. $\square$

1.1.9 Indicatrices

L'indicatrice $\mathbf{1}_A$ vaut 1 si A est réalisé et 0 sinon.

Proposition 1.19.

$$\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A), \quad \text{Var}(\mathbf{1}_A) = \mathbb{P}(A)(1 - \mathbb{P}(A)), \quad \text{Cov}(\mathbf{1}_A, \mathbf{1}_B) = \mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B).$$

Deux événements sont donc indépendants si et seulement si leurs indicatrices sont non corrélées.

Démonstration. Étape 1 (espérance). $\mathbf{1}_A$ vaut 1 avec probabilité $\mathbb{P}(A)$ et 0 avec probabilité $1 - \mathbb{P}(A)$: c'est une variable de Bernoulli. Donc $\mathbb{E}[\mathbf{1}_A] = 1 \cdot \mathbb{P}(A) + 0 \cdot (1 - \mathbb{P}(A)) = \mathbb{P}(A)$.

Étape 2 (variance). Comme $0^2 = 0$ et $1^2 = 1$, on a $\mathbf{1}_A^2 = \mathbf{1}_A$, donc $\mathbb{E}[\mathbf{1}_A^2] = \mathbb{P}(A)$. Par la formule de Koenig, $\text{Var}(\mathbf{1}_A) = \mathbb{P}(A) - \mathbb{P}(A)^2 = \mathbb{P}(A)(1 - \mathbb{P}(A))$.

Étape 3 (produit). Le produit $\mathbf{1}_A \mathbf{1}_B$ vaut 1 si et seulement si les deux facteurs valent 1, c'est-à-dire si A et B sont réalisés tous les deux : $\mathbf{1}_A \mathbf{1}_B = \mathbf{1}_{A \cap B}$. Donc $\mathbb{E}[\mathbf{1}_A \mathbf{1}_B] = \mathbb{P}(A \cap B)$.

Étape 4 (covariance). Par la proposition sur la covariance, $\text{Cov}(\mathbf{1}_A, \mathbf{1}_B) = \mathbb{E}[\mathbf{1}_A \mathbf{1}_B] - \mathbb{E}[\mathbf{1}_A]\mathbb{E}[\mathbf{1}_B] = \mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B)$. Elle est nulle si et seulement si $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$, qui est la définition de l'indépendance de deux événements. $\square$

Méthode. Une variable de comptage « nombre d'objets ayant la propriété P » s'écrit $X = \sum_i \mathbf{1}_{A_i}$, où A_i est l'événement « l'objet i a la propriété P ». La linéarité, la variance d'une somme et la proposition précédente donnent

$$\mathbb{E}[X] = \sum_i \mathbb{P}(A_i), \quad \text{Var } X = \sum_i \mathbb{P}(A_i)(1 - \mathbb{P}(A_i)) + 2 \sum_{i < j} [\mathbb{P}(A_i \cap A_j) - \mathbb{P}(A_i)\mathbb{P}(A_j)].$$

Il n'y a besoin ni de la loi de X , ni d'identité combinatoire.

1.1.10 Variance totale

Rappel : lois conditionnelles. Si $\mathbb{P}(A) > 0$, la loi de X sachant A est $p(x | A) = \mathbb{P}(X = x | A) = \mathbb{P}(X = x \cap A) / \mathbb{P}(A)$. On note $\mathbb{E}[X | A] = \sum_x x p(x | A)$ et $\text{Var}(X | A)$ l'espérance et la variance calculées avec cette loi ; la formule de Koenig s'y applique : $\text{Var}(X | A) = \mathbb{E}[X^2 | A] - \mathbb{E}[X | A]^2$.

Théorème 1.20 (Variance totale). *Soit X de variance finie et $A_1, \dots, A_n$ un système complet d'événements de probabilités non nulles, $\pi_i = \mathbb{P}(A_i)$, $\mu_i = \mathbb{E}[X | A_i]$, $\sigma_i^2 = \text{Var}(X | A_i)$ et $\mu = \mathbb{E}[X]$. Alors*

$$\mathbb{E}[X] = \sum_i \pi_i \mu_i, \quad \text{Var } X = \underbrace{\sum_i \pi_i \sigma_i^2}_{\text{intra}} + \underbrace{\sum_i \pi_i (\mu_i - \mu)^2}_{\text{inter}}.$$

Démonstration. Étape 1 (probabilités totales). Pour chaque valeur x , on découpe $\{X = x\}$ selon le système complet (A_i) , par le même raisonnement « par tiroirs » que pour les lois marginales : $\{X = x\} = \bigcup_i (\{X = x\} \cap A_i)$, réunion disjointe. Donc

$$p(x) = \sum_i \mathbb{P}(X = x \cap A_i) = \sum_i \pi_i p(x | A_i).$$

Étape 2 (espérance). On multiplie par x et on somme sur x . Chaque série $\sum_x |x| p(x | A_i)$ converge, car $\pi_i p(x | A_i) = \mathbb{P}(X = x \cap A_i) \leq p(x)$; la somme sur i étant finie, on peut donc intervertir les deux sommes :

$$\mathbb{E}[X] = \sum_x x \sum_i \pi_i p(x | A_i) = \sum_i \pi_i \sum_x x p(x | A_i) = \sum_i \pi_i \mu_i.$$

Étape 3 (moment d'ordre 2). Le même calcul avec x^2 donne $\mathbb{E}[X^2] = \sum_i \pi_i \mathbb{E}[X^2 | A_i]$. Par la formule de Koenig conditionnelle, $\mathbb{E}[X^2 | A_i] = \sigma_i^2 + \mu_i^2$, donc $\mathbb{E}[X^2] = \sum_i \pi_i \sigma_i^2 + \sum_i \pi_i \mu_i^2$.

Étape 4 (variance). Par la formule de Koenig, $\text{Var } X = \mathbb{E}[X^2] - \mu^2 = \sum_i \pi_i \sigma_i^2 + (\sum_i \pi_i \mu_i^2 - \mu^2)$.

Étape 5 (terme inter). Il reste à voir que $\sum_i \pi_i \mu_i^2 - \mu^2 = \sum_i \pi_i (\mu_i - \mu)^2$. On développe $(\mu_i - \mu)^2 = \mu_i^2 - 2\mu\mu_i + \mu^2$, on multiplie par π_i et on somme :

$$\sum_i \pi_i (\mu_i - \mu)^2 = \sum_i \pi_i \mu_i^2 - 2\mu \sum_i \pi_i \mu_i + \mu^2 \sum_i \pi_i = \sum_i \pi_i \mu_i^2 - 2\mu \cdot \mu + \mu^2 \cdot 1 = \sum_i \pi_i \mu_i^2 - \mu^2,$$

en utilisant $\sum_i \pi_i \mu_i = \mu$ (étape 2) et $\sum_i \pi_i = 1$ (système complet). $\square$

Remarque (Partitions dénombrables). Le théorème s'étend à un système complet dénombrable $(A_i)_{i \geq 1}$ d'événements de probabilités non nulles : la démonstration est identique, les sommes finies devenant des séries. L'interversion $\sum_x \sum_i = \sum_i \sum_x$ est licite car les termes sont positifs (pour x^2) ou la série est absolument convergente (pour x), et $\sum_i \pi_i \mu_i^2 \leq \sum_i \pi_i \mathbb{E}[X^2 | A_i] = \mathbb{E}[X^2] < \infty$ car $\mu_i^2 \leq \mathbb{E}[X^2 | A_i]$ (une variance conditionnelle est positive).

Remarque. C'est le théorème de Huygens : le moment d'inertie total est la somme des moments d'inertie propres de chaque groupe et du moment d'inertie de leurs centres de gravité, affectés des masses π_i , autour du centre de gravité global.

Corollaire 1.21. $\text{Var } X \geq \sum_i \pi_i \sigma_i^2$: en moyenne, connaître le groupe réduit l'incertitude.

Démonstration. Le terme inter $\sum_i \pi_i (\mu_i - \mu)^2$ est une somme de termes positifs. $\square$

1.1.11 Espérance conditionnelle sachant une variable

La variance totale découpe Ω selon un système complet d'événements. Lorsque ce système est formé des événements $\{Y = y\}$ associés à une variable discrète Y , on obtient une écriture plus compacte, et une notion nouvelle : l'espérance conditionnelle comme *variable aléatoire*.

Dans ce paragraphe, Y est discrète et, quitte à retirer de R_Y les valeurs de probabilité nulle (ce qui ne change pas la loi de Y), on suppose $\mathbb{P}(Y = y) > 0$ pour tout $y \in R_Y$; on a alors $\mathbb{P}(Y \in R_Y) = 1$, et les événements $\{Y = y\}$, $y \in R_Y$, forment un système complet à un événement de probabilité nulle près, ce qui ne change aucune des sommes qui suivent.

Définition 1.22. Soit X de variance finie. Pour $y \in R_Y$, on note $h(y) = \mathbb{E}[X \mid Y = y]$ et $v(y) = \text{Var}(X \mid Y = y)$ l'espérance et la variance de X calculées avec la loi conditionnelle sachant $\{Y = y\}$. On appelle *espérance conditionnelle de X sachant Y* la variable aléatoire $\mathbb{E}[X \mid Y] = h(Y)$, et *variance conditionnelle* la variable $\text{Var}(X \mid Y) = v(Y)$.

Remarque. $\mathbb{E}[X \mid Y]$ n'est pas un nombre mais une variable aléatoire : c'est une fonction de Y . Elle représente la valeur moyenne de X une fois connue la valeur de Y . Par exemple, si X est le nombre de défauts d'une pièce et Y sa ligne de production, $\mathbb{E}[X \mid Y]$ est le nombre moyen de défauts de la ligne dont provient la pièce.

Théorème 1.23 (Espérance totale, variance totale). *Si X est de variance finie, alors $\mathbb{E}[X \mid Y]$ et $\text{Var}(X \mid Y)$ admettent une espérance, et*

$$\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}[X], \quad \text{Var } X = \mathbb{E}[\text{Var}(X \mid Y)] + \text{Var}(\mathbb{E}[X \mid Y]).$$

Démonstration. On applique le théorème de la variance totale, avec la remarque sur les partitions dénombrables, au système complet $A_y = \{Y = y\}$, $y \in R_Y$; on note $\pi_y = \mathbb{P}(Y = y)$, $\mu_y = h(y)$ et $\sigma_y^2 = v(y)$.

Étape 1 (espérance totale). Par le transfert appliqué à la variable Y et à la fonction h , $\mathbb{E}[h(Y)] = \sum_y h(y) \mathbb{P}(Y = y) = \sum_y \pi_y \mu_y$, à condition que $\sum_y |\mu_y| \pi_y < \infty$. C'est le cas : $|\mu_y| \leq \mathbb{E}[|X| \mid Y = y]$ (croissance appliquée à la loi conditionnelle, avec $-|X| \leq X \leq |X|$), et $\sum_y \pi_y \mathbb{E}[|X| \mid Y = y] = \mathbb{E}[|X|] < \infty$ (partie « espérance » du théorème de la variance totale, appliquée à $|X|$). Le théorème de la variance totale donne alors $\sum_y \pi_y \mu_y = \mathbb{E}[X]$.

Étape 2 (partie intra). De même, $\mathbb{E}[v(Y)] = \sum_y \pi_y \sigma_y^2$, série à termes positifs, majorée par $\sum_y \pi_y \mathbb{E}[X^2 \mid Y = y] = \mathbb{E}[X^2] < \infty$.

Étape 3 (partie inter). La variable $h(Y)$ a pour espérance $\mu = \mathbb{E}[X]$ (étape 1), donc, par le transfert, $\text{Var}(h(Y)) = \mathbb{E}[(h(Y) - \mu)^2] = \sum_y \pi_y (\mu_y - \mu)^2$.

Étape 4 (conclusion). Le théorème de la variance totale s'écrit $\text{Var } X = \sum_y \pi_y \sigma_y^2 + \sum_y \pi_y (\mu_y - \mu)^2$, c'est-à-dire, d'après les étapes 2 et 3, $\text{Var } X = \mathbb{E}[\text{Var}(X \mid Y)] + \text{Var}(\mathbb{E}[X \mid Y])$. $\square$

Proposition 1.24 (Meilleure prédiction). *Si X est de variance finie, alors pour toute fonction g telle que $\mathbb{E}[g(Y)^2] < \infty$,*

$$\mathbb{E}[(X - g(Y))^2] = \mathbb{E}[(X - \mathbb{E}[X \mid Y])^2] + \mathbb{E}[(\mathbb{E}[X \mid Y] - g(Y))^2] \geq \mathbb{E}[(X - \mathbb{E}[X \mid Y])^2] = \mathbb{E}[\text{Var}(X \mid Y)].$$

Parmi toutes les prédictions de X par une fonction de Y , $\mathbb{E}[X \mid Y]$ est celle qui minimise l'erreur quadratique moyenne.

Démonstration. On note $h(Y) = \mathbb{E}[X \mid Y]$; on a $\mathbb{E}[h(Y)^2] = \sum_y \pi_y \mu_y^2 \leq \mathbb{E}[X^2] < \infty$ (remarque sur les partitions dénombrables), donc toutes les variables ci-dessous sont de variance finie.

Étape 1 (développement). $X - g(Y) = (X - h(Y)) + (h(Y) - g(Y))$, donc

$$(X - g(Y))^2 = (X - h(Y))^2 + 2(X - h(Y))(h(Y) - g(Y)) + (h(Y) - g(Y))^2.$$

Étape 2 (le terme croisé est d'espérance nulle). On découpe selon les valeurs de Y (partie « espérance » du théorème de la variance totale). Sachant $Y = y$, le terme croisé vaut $(X - h(y))(h(y) - g(y))$, où $h(y) - g(y)$ est une constante; son espérance conditionnelle vaut donc $(h(y) - g(y))(\mathbb{E}[X | Y = y] - h(y)) = 0$. En moyennant sur y , le terme croisé est d'espérance nulle.

Étape 3 (conclusion). Par linéarité, on obtient l'égalité annoncée. Le dernier terme est l'espérance d'un carré, donc il est positif, d'où l'inégalité. Enfin, sachant $Y = y$, $\mathbb{E}[(X - h(y))^2 | Y = y] = v(y)$, donc $\mathbb{E}[(X - h(Y))^2] = \mathbb{E}[v(Y)]$. $\square$

Remarque. Le théorème s'écrit de la même façon lorsque Y a une densité, avec les lois conditionnelles à densité (admis). Il fournira en une ligne les formules de Wald de la séance 2 : si S est la somme de N variables indépendantes de même loi que Z , alors $\mathbb{E}[S | N] = N \mathbb{E}[Z]$ et $\text{Var}(S | N) = N \text{Var } Z$, d'où $\mathbb{E}[S] = \mathbb{E}[N]\mathbb{E}[Z]$ et $\text{Var } S = \mathbb{E}[N] \text{Var } Z + \text{Var}(N) \mathbb{E}[Z]^2$.

1.2 TD 1

Les exercices 1 à 3 calculent directement l'espérance et la variance des lois de Poisson, exponentielle et normale. Ils utilisent le théorème de transfert (pour écrire $\mathbb{E}[X^2] = \sum x^2 p(x)$ ou $\int x^2 f(x) dx$), la linéarité et la formule de Koenig. Les exercices suivants utilisent les indicatrices et la variance d'une somme.

Rappels d'analyse pour les exercices 1 à 3.

- *Série exponentielle.* Pour tout réel u , $\sum_{k \geq 0} \frac{u^k}{k!} = e^u$.
- *Intégrale jusqu'à $+\infty$.* $\int_0^{+\infty} h(x) dx = \lim_{A \rightarrow +\infty} \int_0^A h(x) dx$; l'écriture $[F(x)]_0^{+\infty}$ est un raccourci pour $\lim_{A \rightarrow +\infty} F(A) - F(0)$. De même, lorsque $\int_{-\infty}^{+\infty} |h|$ est finie, $\int_{-\infty}^{+\infty} h = \lim_{A \rightarrow +\infty} \int_{-A}^A h$.
- *Intégration par parties.* Pour u et v de classe C^1 sur un intervalle borné $[a, b]$, $\int_a^b u(x)v'(x) dx = [u(x)v(x)]_a^b - \int_a^b u'(x)v(x) dx$. Pour une intégrale jusqu'à $+\infty$, on l'applique sur $[0, A]$, où tout est fini, puis on fait tendre A vers $+\infty$.
- *Croissances comparées :* voir la proposition ci-dessous.

Proposition 1.25 (Croissances comparées).

(a) Pour tout $\lambda > 0$ et tout entier $n \geq 0$, $\lim_{x \rightarrow +\infty} x^n e^{-\lambda x} = 0$.

(b) Pour tout entier $n \geq 0$, $\lim_{|x| \rightarrow +\infty} |x|^n e^{-x^2/2} = 0$.

Autrement dit, l'exponentielle l'emporte sur toute puissance.

Démonstration. Idée. Le produit $x^n e^{-\lambda x}$ est une forme indéterminée « $\infty \times 0$ » : x^n tend vers $+\infty$ et $e^{-\lambda x}$ vers 0. On ne peut pas conclure directement; on va *coïncider* l'expression entre 0 et une quantité simple qui tend vers 0 (théorème d'encadrement, dit « des gendarmes »).

Étape 1 (minorer l'exponentielle par une puissance). Pour tout réel u ,

$$e^u = \sum_{k \geq 0} \frac{u^k}{k!} = 1 + u + \frac{u^2}{2!} + \cdots + \frac{u^{n+1}}{(n+1)!} + \cdots$$

Si $u \geq 0$, tous les termes de cette série sont positifs. Une somme de termes positifs est plus grande que n'importe lequel d'entre eux; en ne gardant que le terme d'indice $n+1$:

$$e^u \geq \frac{u^{n+1}}{(n+1)!} \quad \text{pour tout } u \geq 0.$$

Par exemple, pour $n = 1$: $e^u \geq u^2/2$; l'exponentielle est au-dessus de la parabole $u^2/2$ sur $[0, +\infty[$.

Étape 2 (application avec $u = \lambda x$). Soit $x > 0$. Alors $u = \lambda x > 0$, et l'étape 1 donne $e^{\lambda x} \geq \frac{(\lambda x)^{n+1}}{(n+1)!} > 0$.

Étape 3 (encadrement). On écrit $x^n e^{-\lambda x} = \frac{x^n}{e^{\lambda x}}$. Cette quantité est positive : c'est la borne inférieure. Pour la borne supérieure, on remplace le dénominateur $e^{\lambda x}$ par la quantité plus petite (et strictement positive) de l'étape 2. Or, pour des nombres strictement positifs, *diviser par un nombre plus petit donne un résultat plus grand*. Donc

$$0 \leq \frac{x^n}{e^{\lambda x}} \leq \frac{x^n}{(\lambda x)^{n+1}/(n+1)!} = \frac{(n+1)! x^n}{\lambda^{n+1} x^{n+1}} = \frac{(n+1)!}{\lambda^{n+1}} \cdot \frac{1}{x},$$

en simplifiant $x^n/x^{n+1} = 1/x$.

Étape 4 (conclusion de (a)). Le majorant est une constante, $(n+1)!/\lambda^{n+1}$, multipliée par $1/x$; il tend vers 0 quand $x \rightarrow +\infty$. L'expression $x^n e^{-\lambda x}$, coincée entre 0 et une quantité qui tend vers 0, tend donc vers 0.

Étape 5 (preuve de (b) : on se ramène à (a)). Soit $|x| \geq 1$. En multipliant l'inégalité $|x| \geq 1$ par $|x| > 0$, on obtient $x^2 = |x| \cdot |x| \geq |x|$, puis, en divisant par 2, $x^2/2 \geq |x|/2$. On passe à l'opposé, ce qui renverse l'inégalité : $-x^2/2 \leq -|x|/2$. La fonction exponentielle étant croissante, $e^{-x^2/2} \leq e^{-|x|/2}$. En multipliant par $|x|^n \geq 0$:

$$0 \leq |x|^n e^{-x^2/2} \leq |x|^n e^{-|x|/2}.$$

Le majorant est l'expression de (a), avec $\lambda = 1/2$ et la variable $|x|$, qui tend vers $+\infty$: il tend vers 0. Par encadrement, $|x|^n e^{-x^2/2} \rightarrow 0$ quand $|x| \rightarrow +\infty$. $\square$

Remarques. Pourquoi garder le terme d'indice $n+1$ et pas celui d'indice n ? Avec $e^u \geq u^n/n!$, les puissances de x se simplifieraient entièrement, et l'on obtiendrait seulement $x^n e^{-\lambda x} \leq n!/\lambda^n$: une constante, qui ne tend pas vers 0. Il faut une puissance de plus au dénominateur pour qu'il reste un facteur $1/x$.

Un exemple chiffré. Pour $n = 1$ et $\lambda = 1$, le majorant vaut $2/x$. En $x = 10$, il vaut 0,2, alors que $10 e^{-10} \approx 0,00045$. La borne est grossière, mais cela n'a aucune importance : on a seulement besoin qu'elle tende vers 0.

Ce qu'il faut écrire dans une copie. La phrase « l'exponentielle tend vers 0 plus vite que la puissance ne tend vers l'infini » est un bon moyen mnémotechnique, mais ce n'est pas une justification. On écrit : « par croissances comparées, $\lim_{x \rightarrow +\infty} x^n e^{-\lambda x} = 0$ », en citant la proposition 1.25.

Exercice 1 — Espérance et variance de la loi de Poisson.

Soit $X \sim \text{Po}(\mu)$ avec $\mu > 0$: $p(x) = e^{-\mu} \frac{\mu^x}{x!}$ pour $x = 0, 1, 2, \dots$

1. Vérifier que $\sum_{x \geq 0} p(x) = 1$.
2. Montrer que, pour $x \geq 1$, $x p(x) = \mu p(x-1)$. Pourquoi faut-il $x \geq 1$?
3. Calculer $\mathbb{E}[X]$: on expliquera pourquoi la somme peut commencer à $x = 1$, puis on posera $j = x - 1$. Retrouver ensuite le résultat à l'aide de la question 2.
4. Comparer les simplifications de $\frac{x}{x!}$, $\frac{x(x-1)}{x!}$ et $\frac{x^2}{x!}$. En déduire pourquoi on calcule $\mathbb{E}[X(X-1)]$ plutôt que $\mathbb{E}[X^2]$, et vérifier que $X^2 = X(X-1) + X$.
5. Calculer $\mathbb{E}[X(X-1)]$, puis $\mathbb{E}[X^2]$ et $\text{Var } X$.
6. *Variante.* Calculer directement $\mathbb{E}[X^2]$ à l'aide de la question 2.

Exercice 2 — Espérance et variance de la loi exponentielle : deux méthodes.

Soit $X \sim \text{Exp}(\lambda)$ avec $\lambda > 0$: $f(x) = \lambda e^{-\lambda x}$ pour $x \geq 0$, $f(x) = 0$ sinon.

1. Vérifier que $\int_{-\infty}^{+\infty} f(x) dx = 1$.
2. *Méthode 1 : intégrations par parties.*
 - a) Calculer $\mathbb{E}[X] = \int_0^{+\infty} x \lambda e^{-\lambda x} dx$ par une intégration par parties sur $[0, A]$, puis faire tendre A vers $+\infty$. Justifier soigneusement la limite du crochet.
 - b) Calculer de même $\mathbb{E}[X^2]$, en se ramenant au calcul de a).
 - c) En déduire $\text{Var } X$.
3. *Méthode 2 : fonction Gamma.* Pour $z > 0$, on pose $\Gamma(z) = \int_0^{+\infty} x^{z-1} e^{-x} dx$ (on admet que cette intégrale converge).
 - a) Calculer $\Gamma(1)$.
 - b) Montrer, par une intégration par parties, que $\Gamma(n+1) = n\Gamma(n)$ pour tout entier $n \geq 1$.
 - c) En déduire que $\Gamma(n+1) = n!$ pour tout entier $n \geq 0$.
 - d) À l'aide du changement de variable $u = \lambda x$, montrer que $\int_0^{+\infty} x^n e^{-\lambda x} dx = \frac{n!}{\lambda^{n+1}}$.
 - e) En déduire $\mathbb{E}[X^n]$ pour tout n , puis $\mathbb{E}[X]$, $\mathbb{E}[X^2]$ et $\text{Var } X$.
4. Comparer les deux méthodes.

Exercice 3 — Espérance et variance de la loi normale.

Soit $Z \sim \mathcal{N}(0, 1)$, de densité $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$. On admet que $\int_{-\infty}^{+\infty} \varphi(z) dz = 1$ (intégrale de Gauss).

1. Montrer que $\varphi'(z) = -z\varphi(z)$.
2. Montrer que $\mathbb{E}|Z|$ est finie, puis que $\mathbb{E}[Z] = 0$. Pourquoi faut-il établir d'abord que $\mathbb{E}|Z| < \infty$? (On pourra examiner le cas de la loi de Cauchy, de densité $\frac{1}{\pi(1+x^2)}$.)
3. Montrer que $\mathbb{E}[Z^2] = 1$ par une intégration par parties. En déduire $\text{Var } Z$.
4. Soit $X = \mu + \sigma Z$ avec $\sigma > 0$, qui suit $\mathcal{N}(\mu, \sigma^2)$ (centrage-réduction du cours). En déduire $\mathbb{E}[X]$ et $\text{Var } X$.
5. *Pour aller plus loin.* Montrer que $\mathbb{E}[Z^n] = (n-1)\mathbb{E}[Z^{n-2}]$ pour tout entier $n \geq 2$. En déduire $\mathbb{E}[Z^3]$, $\mathbb{E}[Z^4]$ et, plus généralement, les moments de Z .

Exercice 4 — La binomiale par les indicatrices.

Soit $X \sim \text{Bi}(n, p)$, vue comme $X = Y_1 + \dots + Y_n$ avec des $Y_i \sim \text{Be}(p)$ indépendantes. On note $q = 1 - p$, de sorte que $\mathbb{P}(X = x) = \binom{n}{x} p^x q^{n-x}$.

1. Calculer $\mathbb{E}[X]$ et $\text{Var } X$ à l'aide du cours.
2. Retrouver $\mathbb{E}[X]$ par le calcul direct, en utilisant $x \binom{n}{x} = n \binom{n-1}{x-1}$.
3. Retrouver $\text{Var } X$ par le calcul direct, en calculant d'abord $\mathbb{E}[X(X-1)]$ à l'aide de $x(x-1) \binom{n}{x} = n(n-1) \binom{n-2}{x-2}$.
4. Comparer les deux approches.

Exercice 5 — Contrôle par échantillonnage sans remise.

Un lot contient N pièces, dont k défectueuses. On en prélève n sans remise, tous les tirages ordonnés étant équiprobables. On note $p = k/N$, $q = 1 - p = (N-k)/N$, Y_i l'indicatrice « la i -ème pièce tirée est défectueuse » et $X = Y_1 + \dots + Y_n$.

1. Dénombrer les tirages ordonnés de n pièces parmi N , puis ceux où une pièce donnée occupe la position i . En déduire $\mathbb{P}(Y_i = 1)$.
2. En déduire $\mathbb{E}[X]$.
3. Pour $i \neq j$, calculer $\mathbb{P}(Y_i = 1, Y_j = 1)$, puis $\text{Cov}(Y_i, Y_j)$. Interpréter le signe.

4. Montrer que $\text{Var } X = npq \frac{N-n}{N-1}$.
5. Examiner les cas $n = 1$, $n = N$ et $N \rightarrow +\infty$ avec $k/N = p$ fixé.
6. Application numérique : $N = 200$, $k = 10$, $n = 20$. Comparer avec la variance binomiale.

Exercice 6 — Le problème des rencontres.

On place au hasard n lettres dans n enveloppes adressées, toutes les répartitions étant équiprobables. Soit X le nombre de lettres placées dans la bonne enveloppe.

1. Écrire X comme somme d'indicateurs et calculer $\mathbb{E}[X]$.
2. Calculer $\text{Var } X$.
3. Comparer avec les moments de $\text{Po}(1)$. Sachant que $\mathbb{P}(X = 0) \rightarrow e^{-1}$, que peut-on conjecturer ?

Exercice 7 — Corrélation et diversification.

1. Soit X uniforme sur $\{-1, 0, 1\}$ et $Y = X^2$. Calculer $\text{Cov}(X, Y)$. X et Y sont-elles indépendantes ?
2. Un assureur couvre n risques $X_1, \dots, X_n$ de même variance σ^2 , avec une corrélation ρ entre chaque paire. Calculer la variance de la perte moyenne $\bar{X} = (X_1 + \dots + X_n)/n$.
3. Étudier la limite quand $n \rightarrow +\infty$. Interpréter.
4. En déduire que $\rho \geq -1/(n-1)$.
5. Application numérique : $\sigma = 1$, $\rho = 0,2$. Calculer $\text{Var } \bar{X}$ pour $n = 10$ et pour $n \rightarrow \infty$. Comparer avec le cas $\rho = 0$.

Exercice 8 — Lot issu de deux fournisseurs.

Une proportion π des pièces provient du fournisseur A, dont la cote suit $\mathcal{N}(\mu_1, \sigma^2)$, et le reste du fournisseur B, de loi $\mathcal{N}(\mu_2, \sigma^2)$.

1. Calculer $\mathbb{E}[X]$ et $\text{Var } X$ pour une pièce tirée au hasard. On posera $d = \mu_1 - \mu_2$ et on montrera que $\text{Var } X = \sigma^2 + \pi(1-\pi)d^2$.
2. Application numérique : $\pi = 1/2$, $\mu_1 = 10$, $\mu_2 = 16$, $\sigma = 1$.
3. Quelle valeur de π maximise $\text{Var } X$?
4. On trace une carte de contrôle avec des limites $\mu \pm 3\sigma_X$ calculées sur le lot mélangé. Pourquoi est-ce une mauvaise idée ?

Exercice 9 — Défauts selon la ligne de production.

Une pièce provient de la ligne $Y \in \{1, 2, 3\}$ avec probabilités 0,5, 0,3 et 0,2. Sachant $Y = y$, son nombre de défauts X suit une loi de Poisson de paramètre λ_y , avec $\lambda_1 = 1$, $\lambda_2 = 2$ et $\lambda_3 = 5$.

1. Déterminer les variables aléatoires $\mathbb{E}[X | Y]$ et $\text{Var}(X | Y)$.
2. En déduire $\mathbb{E}[X]$ et $\text{Var } X$ par les formules de l'espérance totale et de la variance totale.
3. X suit-elle une loi de Poisson ? On comparera $\mathbb{E}[X]$ et $\text{Var } X$.
4. Quelle est l'erreur quadratique moyenne de la meilleure prédiction de X connaissant la ligne ? Et celle de la meilleure prédiction constante ? Interpréter.
5. Une pièce ne présente aucun défaut. Quelle est la probabilité qu'elle provienne de la ligne 3 ?

1.3 Corrigés du TD 1

Exercice 1.

1. On sort la constante $e^{-\mu}$, qui ne dépend pas de x , et on reconnaît la série exponentielle avec $u = \mu$:

$$\sum_{x \geq 0} e^{-\mu} \frac{\mu^x}{x!} = e^{-\mu} \sum_{x \geq 0} \frac{\mu^x}{x!} = e^{-\mu} e^{\mu} = 1.$$

2. Pour $x \geq 1$, on utilise deux réécritures :

- $x! = x \times (x-1)!$, car $x! = x \times [(x-1) \times \cdots \times 1]$;
- $\mu^x = \mu \times \mu^{x-1}$.

Donc

$$x p(x) = x \cdot e^{-\mu} \frac{\mu \cdot \mu^{x-1}}{x \cdot (x-1)!} = \mu \cdot e^{-\mu} \frac{\mu^{x-1}}{(x-1)!} = \mu p(x-1),$$

le facteur x se simplifiant en haut et en bas. Il faut $x \geq 1$: pour $x = 0$, il faudrait écrire $(x-1)! = (-1)!$, qui n'existe pas, et $p(-1)$ n'a pas de sens.

3. Par définition, $\mathbb{E}[X] = \sum_{x \geq 0} x p(x)$. Tous les termes sont positifs, donc la série est absolument convergente dès qu'elle est finie, ce que le calcul va montrer.

Le terme $x = 0$. Il vaut $0 \times p(0) = 0$: on peut le retirer sans rien changer, et la somme commence à $x = 1$. C'est nécessaire avant la réécriture de la question 2, valable seulement pour $x \geq 1$.

Le calcul. Avec la question 2, puis en sortant les constantes μ et $e^{-\mu}$:

$$\mathbb{E}[X] = \sum_{x \geq 1} \mu e^{-\mu} \frac{\mu^{x-1}}{(x-1)!} = \mu e^{-\mu} \sum_{x \geq 1} \frac{\mu^{x-1}}{(x-1)!}.$$

Le changement d'indice. On pose $j = x-1$: quand $x = 1$, $j = 0$, et quand x parcourt $1, 2, 3, \dots$, j parcourt $0, 1, 2, \dots$. Donc $\sum_{x \geq 1} \frac{\mu^{x-1}}{(x-1)!} = \sum_{j \geq 0} \frac{\mu^j}{j!} = e^{\mu}$ (série exponentielle). Finalement, $\mathbb{E}[X] = \mu e^{-\mu} e^{\mu} = \mu$.

Avec la question 2. $\mathbb{E}[X] = \sum_{x \geq 1} x p(x) = \mu \sum_{x \geq 1} p(x-1) = \mu(p(0) + p(1) + p(2) + \dots) = \mu \times 1 = \mu$, par la question 1. Cette écriture n'a même pas besoin de la série exponentielle : il suffit de savoir que les probabilités ont pour somme 1.

4. On compare :

- $\frac{x}{x!} = \frac{x}{x(x-1)!} = \frac{1}{(x-1)!}$: le facteur x « mange » le dernier facteur de la factorielle ;
- $\frac{x(x-1)}{x!} = \frac{x(x-1)}{x(x-1)(x-2)!} = \frac{1}{(x-2)!}$: les deux facteurs se simplifient entièrement ;
- $\frac{x^2}{x!} = \frac{x}{(x-1)!}$: il reste un x au numérateur, la simplification n'est pas complète.

Les produits $x(x-1) \cdots (x-k+1)$ sont faits pour se simplifier avec une factorielle, qui est elle-même un produit de ce type. On calcule donc $\mathbb{E}[X(X-1)]$, puis on revient à $\mathbb{E}[X^2]$ grâce à l'identité $x(x-1) + x = x^2 - x + x = x^2$, et à la linéarité : $\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X]$.

5. Par le transfert, $\mathbb{E}[X(X-1)] = \sum_{x \geq 0} x(x-1) p(x)$.

Les termes $x = 0$ et $x = 1$. Ils sont nuls, car $x(x-1) = 0$: la somme commence à $x = 2$.

La réécriture. Pour $x \geq 2$, $x! = x(x-1)(x-2)!$ et $\mu^x = \mu^2 \mu^{x-2}$, donc

$$x(x-1) p(x) = x(x-1) \cdot e^{-\mu} \frac{\mu^2 \mu^{x-2}}{x(x-1)(x-2)!} = \mu^2 e^{-\mu} \frac{\mu^{x-2}}{(x-2)!} = \mu^2 p(x-2).$$

Le calcul. Avec $j = x-2$ (qui parcourt $0, 1, 2, \dots$ quand x parcourt $2, 3, 4, \dots$) :

$$\mathbb{E}[X(X-1)] = \mu^2 \sum_{x \geq 2} p(x-2) = \mu^2 \sum_{j \geq 0} p(j) = \mu^2 \times 1 = \mu^2.$$

Conclusion. $\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X] = \mu^2 + \mu$, et par la formule de Koenig

$$\text{Var } X = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mu^2 + \mu - \mu^2 = \mu.$$

L'espérance et la variance d'une loi de Poisson sont égales.

6. Le terme $x = 0$ est nul. Pour $x \geq 1$, on écrit $x^2 p(x) = x \cdot (x p(x)) = x \cdot \mu p(x-1)$. Avec $j = x-1$, donc $x = j+1$:

$$\mathbb{E}[X^2] = \mu \sum_{x \geq 1} x p(x-1) = \mu \sum_{j \geq 0} (j+1) p(j) = \mu \left(\sum_{j \geq 0} j p(j) + \sum_{j \geq 0} p(j) \right) = \mu (\mathbb{E}[X] + 1) = \mu(\mu + 1).$$

On retrouve $\mathbb{E}[X^2] = \mu^2 + \mu$, sans passer par $X(X-1)$.

Exercice 2.

1. f est nulle sur $]-\infty, 0[$. Sur $[0, A]$, une primitive de $\lambda e^{-\lambda x}$ est $-e^{-\lambda x}$ (sa dérivée vaut $-(-\lambda)e^{-\lambda x}$). Donc $\int_0^A \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_0^A = -e^{-\lambda A} + 1 \rightarrow 1$ quand $A \rightarrow +\infty$, car $e^{-\lambda A} \rightarrow 0$.

2. Méthode 1.

- a) Par le transfert (et puisque $f = 0$ sur $]-\infty, 0[$), $\mathbb{E}[X] = \int_0^{+\infty} x \lambda e^{-\lambda x} dx$. On intègre par parties sur $[0, A]$ avec

$$u(x) = x, \quad u'(x) = 1, \quad v'(x) = \lambda e^{-\lambda x}, \quad v(x) = -e^{-\lambda x}.$$

$$\int_0^A x \lambda e^{-\lambda x} dx = [-x e^{-\lambda x}]_0^A - \int_0^A (-e^{-\lambda x}) dx = -A e^{-\lambda A} + \int_0^A e^{-\lambda x} dx.$$

Le crochet vaut $-A e^{-\lambda A} - (-0 \times e^0) = -A e^{-\lambda A}$. L'intégrale restante vaut $[-\frac{1}{\lambda} e^{-\lambda x}]_0^A = -\frac{1}{\lambda}(1 - e^{-\lambda A})$.

Passage à la limite. Quand $A \rightarrow +\infty$: $e^{-\lambda A} \rightarrow 0$; et $A e^{-\lambda A}$ est une forme indéterminée « $\infty \times 0$ », qui tend vers 0 par croissances comparées (proposition 1.25(a) avec $n = 1$). Donc $\mathbb{E}[X] = 0 + \frac{1}{\lambda}(1 - 0) = \frac{1}{\lambda}$.

- b) $\mathbb{E}[X^2] = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx$. Sur $[0, A]$, avec $u(x) = x^2$, $u'(x) = 2x$, $v'(x) = \lambda e^{-\lambda x}$, $v(x) = -e^{-\lambda x}$:

$$\int_0^A x^2 \lambda e^{-\lambda x} dx = [-x^2 e^{-\lambda x}]_0^A + \int_0^A 2x e^{-\lambda x} dx = -A^2 e^{-\lambda A} + \frac{2}{\lambda} \int_0^A x \lambda e^{-\lambda x} dx.$$

On a fait apparaître l'intégrale de a) en écrivant $2x e^{-\lambda x} = \frac{2}{\lambda} \cdot x \lambda e^{-\lambda x}$. Quand $A \rightarrow +\infty$, $A^2 e^{-\lambda A} \rightarrow 0$ (proposition 1.25(a) avec $n = 2$) et l'intégrale tend vers $\mathbb{E}[X] = 1/\lambda$. Donc $\mathbb{E}[X^2] = \frac{2}{\lambda} \cdot \frac{1}{\lambda} = \frac{2}{\lambda^2}$.

- c) Par la formule de Koenig, $\text{Var } X = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}$.

3. Méthode 2.

- a) $\Gamma(1) = \int_0^{+\infty} x^0 e^{-x} dx = \lim_{A \rightarrow +\infty} [-e^{-x}]_0^A = \lim_{A \rightarrow +\infty} (1 - e^{-A}) = 1$.

- b) Soit $n \geq 1$ entier. Sur $[0, A]$, on intègre par parties avec $u(x) = x^n$, $u'(x) = n x^{n-1}$, $v'(x) = e^{-x}$, $v(x) = -e^{-x}$:

$$\int_0^A x^n e^{-x} dx = [-x^n e^{-x}]_0^A + n \int_0^A x^{n-1} e^{-x} dx.$$

Le crochet vaut $-A^n e^{-A} + 0^n e^0 = -A^n e^{-A}$ (car $0^n = 0$ pour $n \geq 1$) ; il tend vers 0 par croissances comparées (proposition 1.25(a) avec $\lambda = 1$). En faisant tendre A vers $+\infty$, on obtient $\Gamma(n+1) = n \Gamma(n)$. (Ce résultat reste vrai pour tout réel $z > 0$: $\Gamma(z+1) = z \Gamma(z)$.)

- c) Par récurrence. Pour $n = 0$: $\Gamma(1) = 1 = 0!$. Si $\Gamma(n) = (n-1)!$, alors $\Gamma(n+1) = n \Gamma(n) = n(n-1)! = n!$. La fonction Gamma prolonge la factorielle : $\Gamma(n+1) = n!$.

- d) Sur $[0, A]$, on pose $u = \lambda x$, donc $x = u/\lambda$ et $dx = du/\lambda$; quand x va de 0 à A , u va de 0 à λA :

$$\int_0^A x^n e^{-\lambda x} dx = \int_0^{\lambda A} \left(\frac{u}{\lambda}\right)^n e^{-u} \frac{du}{\lambda} = \frac{1}{\lambda^{n+1}} \int_0^{\lambda A} u^n e^{-u} du.$$

Quand $A \rightarrow +\infty$, $\lambda A \rightarrow +\infty$ et l'intégrale tend vers $\Gamma(n+1) = n!$. Donc $\int_0^{+\infty} x^n e^{-\lambda x} dx = \frac{n!}{\lambda^{n+1}}$.

- e) Par le transfert, $\mathbb{E}[X^n] = \int_0^{+\infty} x^n \lambda e^{-\lambda x} dx = \lambda \cdot \frac{n!}{\lambda^{n+1}} = \frac{n!}{\lambda^n}$. Avec $n = 1$: $\mathbb{E}[X] = \frac{1}{\lambda}$; avec $n = 2$: $\mathbb{E}[X^2] = \frac{2}{\lambda^2}$; donc $\text{Var } X = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$.

4. L'intégration par parties de la méthode 1 est exactement la relation $\Gamma(n+1) = n \Gamma(n)$, cachée dans le calcul. La méthode 2 demande un peu plus de mise en place, mais donne tous les moments d'un coup : $\mathbb{E}[X^n] = n!/\lambda^n$.

Remarque. Une troisième voie consiste à poser $X = Y/\lambda$ avec $Y \sim \text{Exp}(1)$: il suffit alors de calculer $\mathbb{E}[Y] = \Gamma(2) = 1$ et $\mathbb{E}[Y^2] = \Gamma(3) = 2$, puis d'utiliser $\mathbb{E}[X] = \mathbb{E}[Y]/\lambda$ et $\text{Var } X = \text{Var } Y/\lambda^2$ (séance 1).

Remarque. On rencontre aussi $\Gamma(1/2) = \int_0^{+\infty} x^{-1/2} e^{-x} dx = \sqrt{\pi}$ (admis, lié à l'intégrale de Gauss). Ici l'intégrande $x^{-1/2} e^{-x}$ tend vers $+\infty$ quand $x \rightarrow 0$, mais l'intégrale converge, car $x^{-1/2}$ est intégrable près de 0 : $\int_\varepsilon^1 x^{-1/2} dx = 2 - 2\sqrt{\varepsilon} \rightarrow 2$. On la définit donc comme une limite en 0 et en $+\infty$: $\lim_{\varepsilon \rightarrow 0^+, A \rightarrow +\infty} \int_\varepsilon^A x^{-1/2} e^{-x} dx$.

Exercice 3.

- La dérivée de $e^{w(z)}$ est $w'(z) e^{w(z)}$; ici $w(z) = -z^2/2$ et $w'(z) = -z$. Donc $\varphi'(z) = \frac{1}{\sqrt{2\pi}} (-z) e^{-z^2/2} = -z \varphi(z)$.
- Pourquoi deux temps : l'existence, puis la valeur.* Pour une variable X de densité f , on dit que X admet une espérance si $\int_{-\infty}^{+\infty} |x| f(x) dx < \infty$, et l'on pose alors $\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f(x) dx$. C'est la convergence absolue, exactement comme pour les séries dans le cas discret. Sous cette condition, la valeur de l'intégrale ne dépend pas de la façon dont les bornes partent à l'infini : on écrit $\int_a^b x f(x) dx = \int_a^0 x f(x) dx + \int_0^b x f(x) dx$; quand $b \rightarrow +\infty$, le second terme est croissant (intégrande positive) et majoré par $\int_0^{+\infty} |x| f(x) dx < \infty$, donc il a une limite finie; de même pour le premier terme quand $a \rightarrow -\infty$. La limite de $\int_a^b x f(x) dx$ existe donc, et elle est la même quelle que soit la manière dont $a \rightarrow -\infty$ et $b \rightarrow +\infty$; en particulier, on peut la calculer avec des bornes symétriques $a = -A$, $b = A$.

Il faut donc d'abord montrer que $\mathbb{E}|Z| < \infty$, puis calculer la valeur. Trouver 0 en intégrant sur $[-A, A]$ ne suffirait pas à prouver l'existence (voir la remarque qui suit ce corrigé).

Étape 1 (une primitive de $z\varphi(z)$). Par la question 1, $\varphi'(z) = -z\varphi(z)$, c'est-à-dire $z\varphi(z) = -\varphi'(z)$. La fonction $-\varphi$ a pour dérivée $-\varphi' = z\varphi$: c'est une primitive de $z\varphi(z)$.

Étape 2 (intégrale sur $[0, A]$). Pour $A > 0$,

$$\int_0^A z\varphi(z) dz = [-\varphi(z)]_0^A = -\varphi(A) - (-\varphi(0)) = \varphi(0) - \varphi(A).$$

Étape 3 (limite). $\varphi(A) = \frac{1}{\sqrt{2\pi}} e^{-A^2/2} \rightarrow 0$ quand $A \rightarrow +\infty$. Donc

$$\int_0^{+\infty} z\varphi(z) dz = \varphi(0) = \frac{1}{\sqrt{2\pi}},$$

qui est une valeur finie.

Étape 4 (passage à $|z|$ par parité). φ est paire : $\varphi(-z) = \varphi(z)$, car seul z^2 apparaît dans son expression. Comme $|-z| = |z|$, la fonction $|z|\varphi(z)$ est paire aussi : son graphe est symétrique par rapport à l'axe vertical. Le changement de variable $u = -z$ donne $\int_{-A}^0 |z|\varphi(z) dz = \int_0^A |u|\varphi(u) du$: l'aire à gauche de 0 est égale à l'aire à droite. Sur $[0, +\infty[$, $|z| = z$. Donc

$$\mathbb{E}[Z] = \int_{-\infty}^{+\infty} |z|\varphi(z) dz = 2 \int_0^{+\infty} z\varphi(z) dz = \frac{2}{\sqrt{2\pi}} \approx 0,80 < \infty.$$

Z admet donc une espérance.

Étape 5 ($z\varphi(z)$ est impaire). En remplaçant z par $-z$: $(-z)\varphi(-z) = -z\varphi(z)$. C'est le produit de la fonction impaire z et de la fonction paire φ .

Étape 6 (intégrale sur un intervalle symétrique). Dans $\int_{-A}^0 z\varphi(z) dz$, on pose $u = -z$, donc $z = -u$ et $dz = -du$; quand z va de $-A$ à 0, u va de A à 0 :

$$\int_{-A}^0 z\varphi(z) dz = \int_A^0 (-u)\varphi(-u)(-du) = \int_A^0 u\varphi(u) du = - \int_0^A u\varphi(u) du,$$

en utilisant $\varphi(-u) = \varphi(u)$, puis en échangeant les bornes (ce qui change le signe). Les deux moitiés se compensent :

$$\int_{-A}^A z\varphi(z) dz = \int_{-A}^0 z\varphi(z) dz + \int_0^A z\varphi(z) dz = 0 \quad \text{pour tout } A > 0.$$

Géométriquement, l'aire négative à gauche de 0 compense exactement l'aire positive à droite.

Étape 7 (conclusion). L'espérance existe (étape 4) ; on peut donc la calculer comme limite des intégrales sur $[-A, A]$, qui valent toutes 0 (étape 6). Donc $\mathbb{E}[Z] = 0$.

Remarque (Pourquoi l'étape 4 est indispensable : la loi de Cauchy). Pour toute fonction impaire g , $\int_{-A}^A g(z) dz = 0$ pour tout A (même calcul qu'à l'étape 6), aussi grande que soit g . Obtenir 0 sur $[-A, A]$ ne dit donc rien de l'existence de l'intégrale jusqu'à l'infini.

Considérons la loi de Cauchy, de densité $f(x) = \frac{1}{\pi(1+x^2)}$ (TD 2, exercice 6, et TD 3, exercice 4).

Cette densité est paire, donc $xf(x)$ est impaire et $\int_{-A}^A xf(x) dx = 0$ pour tout A . Pourtant, une primitive de $\frac{x}{1+x^2}$ est $\frac{1}{2} \ln(1+x^2)$, donc $\int_0^A xf(x) dx = \frac{1}{2\pi} \ln(1+A^2) \rightarrow +\infty$: la loi de Cauchy n'a pas d'espérance. Et si l'on fait tendre les bornes vers l'infini autrement, par exemple de $-A$ à $2A$:

$$\int_{-A}^{2A} xf(x) dx = \frac{1}{2\pi} \left[\ln(1+x^2) \right]_{-A}^{2A} = \frac{1}{2\pi} \ln \frac{1+4A^2}{1+A^2} \xrightarrow{A \rightarrow +\infty} \frac{1}{2\pi} \ln 4 = \frac{\ln 2}{\pi} \approx 0,22.$$

Selon la manière dont les bornes partent à l'infini, on obtient 0, 0,22, ou n'importe quelle autre valeur (en intégrant de $-A$ à cA , on trouve $\ln(c)/\pi$) : il n'y a pas de valeur naturelle, et l'espérance n'existe pas.

À retenir. « La densité est symétrique autour de 0, donc $\mathbb{E}[X] = 0$ » est **faux** en général. L'énoncé correct est : « si X admet une espérance et si sa densité est symétrique autour de 0, alors $\mathbb{E}[X] = 0$ ».

3. Par le transfert, $\mathbb{E}[Z^2] = \int z^2\varphi(z) dz = \int z \cdot (z\varphi(z)) dz = \int z \cdot (-\varphi'(z)) dz$. On intègre par parties sur $[-A, A]$ avec

$$u(z) = z, \quad u'(z) = 1, \quad v'(z) = -\varphi'(z), \quad v(z) = -\varphi(z).$$

$$\int_{-A}^A z^2\varphi(z) dz = [-z\varphi(z)]_{-A}^A + \int_{-A}^A \varphi(z) dz.$$

Le crochet vaut $-A\varphi(A) - (-(-A)\varphi(-A)) = -A\varphi(A) - A\varphi(-A) = -2A\varphi(A)$ (φ paire). Or $A\varphi(A) = \frac{1}{\sqrt{2\pi}} Ae^{-A^2/2} \rightarrow 0$ par croissances comparées (proposition 1.25(b) avec $n = 1$). L'intégrale restante tend vers $\int \varphi = 1$. Donc $\mathbb{E}[Z^2] = 0 + 1 = 1$, et $\text{Var } Z = \mathbb{E}[Z^2] - \mathbb{E}[Z]^2 = 1 - 0 = 1$.

4. Par linéarité, $\mathbb{E}[X] = \mathbb{E}[\mu + \sigma Z] = \mu + \sigma \mathbb{E}[Z] = \mu$. Par la formule $\text{Var}(aZ + b) = a^2 \text{Var} Z$ (séance 1), avec $a = \sigma$ et $b = \mu$: $\text{Var} X = \sigma^2 \text{Var} Z = \sigma^2$. Les paramètres μ et σ^2 de $\mathcal{N}(\mu, \sigma^2)$ sont bien l'espérance et la variance.
5. Tous les moments existent : par la proposition 1.25(b), $|z|^{n+2}\varphi(z) \rightarrow 0$ quand $|z| \rightarrow +\infty$, donc $|z|^n\varphi(z) \leq 1/z^2$ pour $|z|$ assez grand, et $1/z^2$ est intégrable au voisinage de $\pm\infty$. Pour $n \geq 2$, on écrit $z^n\varphi(z) = z^{n-1} \cdot (-\varphi'(z))$ et on intègre par parties sur $[-A, A]$ avec $u(z) = z^{n-1}$, $u'(z) = (n-1)z^{n-2}$ et $v(z) = -\varphi(z)$:

$$\int_{-A}^A z^n \varphi(z) dz = [-z^{n-1}\varphi(z)]_{-A}^A + (n-1) \int_{-A}^A z^{n-2} \varphi(z) dz.$$

Le crochet tend vers 0, car $|z|^{n-1}\varphi(z) \rightarrow 0$ quand $|z| \rightarrow +\infty$ (proposition 1.25(b)). À la limite, $\mathbb{E}[Z^n] = (n-1) \mathbb{E}[Z^{n-2}]$. On en déduit :

- $\mathbb{E}[Z^3] = 2 \mathbb{E}[Z] = 0$, et plus généralement tous les moments impairs sont nuls ;
- $\mathbb{E}[Z^4] = 3 \mathbb{E}[Z^2] = 3$, $\mathbb{E}[Z^6] = 5 \mathbb{E}[Z^4] = 15$, et $\mathbb{E}[Z^{2k}] = 1 \times 3 \times 5 \times \cdots \times (2k-1)$.

Remarque. On peut appliquer la même idée directement à $X \sim \mathcal{N}(\mu, \sigma^2)$, dont la densité vérifie $f'(x) = -\frac{x-\mu}{\sigma^2} f(x)$: on obtient $\mathbb{E}[X^n] = \sigma^2(n-1)\mathbb{E}[X^{n-2}] + \mu\mathbb{E}[X^{n-1}]$, d'où $\mathbb{E}[X^2] = \sigma^2 + \mu^2$ et $\text{Var} X = \sigma^2$. Passer par Z évite de transporter μ et σ dans tous les calculs.

Exercice 4.

- Chaque Y_i suit $\text{Be}(p)$: $\mathbb{E}[Y_i] = 1 \cdot p + 0 \cdot q = p$ et $\text{Var} Y_i = pq$ (formule des indicatrices). Par linéarité, $\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[Y_i] = np$. Les Y_i étant indépendantes, leurs covariances sont nulles, donc $\text{Var} X = \sum_{i=1}^n \text{Var} Y_i = npq$.
- Par définition, $\mathbb{E}[X] = \sum_{x=0}^n x \binom{n}{x} p^x q^{n-x}$. Le terme $x=0$ est nul ; on commence donc à $x=1$.

L'identité. $x \binom{n}{x} = x \frac{n!}{x!(n-x)!} = \frac{n!}{(x-1)!(n-x)!} = n \frac{(n-1)!}{(x-1)!((n-1)-(x-1))!} = n \binom{n-1}{x-1}.$

Le calcul. On écrit $p^x = p \cdot p^{x-1}$, on sort np , puis on pose $j = x-1$ (qui va de 0 à $n-1$), de sorte que $n-x = (n-1)-j$:

$$\mathbb{E}[X] = np \sum_{x=1}^n \binom{n-1}{x-1} p^{x-1} q^{n-x} = np \sum_{j=0}^{n-1} \binom{n-1}{j} p^j q^{(n-1)-j}.$$

Il reste à montrer que la dernière somme vaut 1. On peut le voir de deux façons.

Par la formule du binôme de Newton. Pour tous réels a, b et tout entier m ,

$$(a+b)^m = \sum_{j=0}^m \binom{m}{j} a^j b^{m-j}.$$

Par exemple, pour $m=2$, on retrouve l'identité remarquable $(a+b)^2 = \binom{2}{0}b^2 + \binom{2}{1}ab + \binom{2}{2}a^2 = b^2 + 2ab + a^2$. Notre somme a exactement cette forme, avec $m = n-1$, $a = p$ et $b = q$: elle vaut $(p+q)^{n-1}$. Comme $q = 1-p$, on a $p+q = 1$, donc $(p+q)^{n-1} = 1^{n-1} = 1$.

Par une somme de probabilités. Les termes $\binom{n-1}{j} p^j q^{(n-1)-j}$, pour j allant de 0 à $n-1$, sont exactement les probabilités de la loi binomiale $\text{Bi}(n-1, p)$. La somme de toutes les probabilités d'une loi vaut 1.

Dans les deux cas, $\mathbb{E}[X] = np \times 1 = np$.

- Les termes $x=0$ et $x=1$ de $\mathbb{E}[X(X-1)] = \sum_x x(x-1) \binom{n}{x} p^x q^{n-x}$ sont nuls. En appliquant deux fois l'identité précédente, $x(x-1) \binom{n}{x} = (x-1) n \binom{n-1}{x-1} = n(n-1) \binom{n-2}{x-2}$. On sort $n(n-1)p^2$ et on pose $j = x-2$:

$$\mathbb{E}[X(X-1)] = n(n-1)p^2 \sum_{j=0}^{n-2} \binom{n-2}{j} p^j q^{(n-2)-j} = n(n-1)p^2(p+q)^{n-2} = n(n-1)p^2.$$

La somme vaut 1 pour les mêmes raisons qu'à la question 2 : c'est le binôme $(p+q)^{n-2} = 1$, ou encore la somme des probabilités de la loi $\text{Bi}(n-2, p)$. Comme $X^2 = X(X-1) + X$, la formule de Koenig donne

$$\text{Var } X = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - \mathbb{E}[X]^2 = n^2 p^2 - np^2 + np - n^2 p^2 = np - np^2 = np(1-p) = npq.$$

4. Les indicatrices ne demandent aucune identité combinatoire et se généralisent aux cas où la loi est inconnue ou compliquée (exercices 5 et 6).

Exercice 5.

1. Un tirage ordonné est une suite de n pièces distinctes : N choix pour la première, $N-1$ pour la deuxième, $\dots$, $N-n+1$ pour la n -ième, soit $N!/(N-n)!$ tirages. Si l'on impose une pièce donnée en position i , il reste à remplir les $n-1$ autres positions avec des pièces distinctes choisies parmi les $N-1$ restantes : $(N-1)!/(N-n)!$ tirages. La probabilité qu'une pièce donnée soit en position i est donc $\frac{(N-1)!/(N-n)!}{N!/(N-n)!} = \frac{(N-1)!}{N!} = \frac{1}{N}$.

L'événement $\{Y_i = 1\}$ est la réunion disjointe des k événements « la pièce défectueuse numéro j est en position i », $j = 1, \dots, k$. Donc $\mathbb{P}(Y_i = 1) = k/N = p$.

2. Par linéarité, $\mathbb{E}[X] = \sum_{i=1}^n \mathbb{P}(Y_i = 1) = np$, la même valeur qu'avec remise.
3. Si l'on impose un couple ordonné de pièces distinctes aux positions (i, j) , il reste $(N-2)!/(N-n)!$ tirages ; la probabilité vaut $(N-2)!/N! = 1/(N(N-1))$. Il y a $k(k-1)$ couples ordonnés de pièces défectueuses distinctes, donc $\mathbb{P}(Y_i = 1, Y_j = 1) = \frac{k(k-1)}{N(N-1)}$.

Par la formule des indicatrices, $\text{Cov}(Y_i, Y_j) = \mathbb{P}(Y_i = 1, Y_j = 1) - \mathbb{P}(Y_i = 1)\mathbb{P}(Y_j = 1)$. Au dénominateur commun $N^2(N-1)$:

$$\text{Cov}(Y_i, Y_j) = \frac{k(k-1)N - k^2(N-1)}{N^2(N-1)} = \frac{k(kN - N - kN + k)}{N^2(N-1)} = \frac{-k(N-k)}{N^2(N-1)} = -\frac{pq}{N-1},$$

car $\frac{k(N-k)}{N^2} = \frac{k}{N} \cdot \frac{N-k}{N} = pq$. La covariance est négative : tirer une pièce défectueuse diminue les chances que la suivante le soit, puisqu'il en reste moins dans le lot.

4. Par la variance d'une somme : n variances égales à pq , et $\frac{n(n-1)}{2}$ couples $i < j$, comptés deux fois :

$$\text{Var } X = npq + 2 \cdot \frac{n(n-1)}{2} \cdot \left(-\frac{pq}{N-1}\right) = npq \left(1 - \frac{n-1}{N-1}\right) = npq \frac{(N-1) - (n-1)}{N-1} = npq \frac{N-n}{N-1}.$$

5. Pour $n = 1$, $\text{Var } X = pq$: c'est une variable de Bernoulli. Pour $n = N$, $\text{Var } X = 0$: on prélève tout le lot, et $X = k$ est certain. Quand $N \rightarrow \infty$ à p fixé, $\frac{N-n}{N-1} \rightarrow 1$: la variance tend vers celle de la binomiale. Cela rend l'approximation binomiale plausible quand n est petit devant N ; la convergence de la loi elle-même se démontre à partir de la formule de l'hypergéométrie.
6. $p = 10/200 = 0,05$ et $\mathbb{E}[X] = 20 \times 0,05 = 1$. Avec remise : $20 \times 0,05 \times 0,95 = 0,95$. Sans remise : $0,95 \times \frac{180}{199} \approx 0,859$, soit environ 10 % de moins.

Exercice 6.

1. Soit A_i : « la lettre i est bien placée ». Les répartitions sont les $n!$ permutations. Celles où la lettre i est bien placée correspondent à une répartition quelconque des $n-1$ autres lettres dans les $n-1$ autres enveloppes : $(n-1)!$. Donc $\mathbb{P}(A_i) = (n-1)!/n! = 1/n$. Avec $X = \sum_i \mathbf{1}_{A_i}$, la linéarité donne $\mathbb{E}[X] = n \times \frac{1}{n} = 1$, quel que soit n .

2. Chaque indicatrice a pour variance $\frac{1}{n}(1 - \frac{1}{n})$. Pour $i \neq j$, les lettres i et j sont bien placées dans $(n-2)!$ répartitions, donc $\mathbb{P}(A_i \cap A_j) = \frac{(n-2)!}{n!} = \frac{1}{n(n-1)}$ et

$$\text{Cov}(\mathbf{1}_{A_i}, \mathbf{1}_{A_j}) = \frac{1}{n(n-1)} - \frac{1}{n^2} = \frac{n - (n-1)}{n^2(n-1)} = \frac{1}{n^2(n-1)}.$$

Par la variance d'une somme, avec $\frac{n(n-1)}{2}$ couples $i < j$ comptés deux fois :

$$\text{Var } X = n \cdot \frac{1}{n} \left(1 - \frac{1}{n}\right) + 2 \cdot \frac{n(n-1)}{2} \cdot \frac{1}{n^2(n-1)} = \left(1 - \frac{1}{n}\right) + \frac{1}{n} = 1.$$

La covariance est positive : si la lettre i est bien placée, une enveloppe est « libérée » pour les autres.

3. $\text{Po}(1)$ a aussi une espérance et une variance égales à 1, et $\mathbb{P}(0) = e^{-1}$. On peut conjecturer que X converge en loi vers $\text{Po}(1)$; c'est vrai et se démontre par la formule de Poincaré (admis ici).

Exercice 7.

- $\mathbb{E}[X] = \frac{-1+0+1}{3} = 0$. Comme $XY = X^3$ prend les valeurs $-1, 0, 1$ avec probabilité $\frac{1}{3}$ chacune, $\mathbb{E}[XY] = 0$. Donc $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$. Pourtant X et Y ne sont pas indépendantes : $X = 0$ entraîne $Y = 0$, donc $\mathbb{P}(X = 0, Y = 1) = 0$, alors que $\mathbb{P}(X = 0)\mathbb{P}(Y = 1) = \frac{1}{3} \cdot \frac{2}{3} = \frac{2}{9}$. La covariance ne mesure que la dépendance linéaire.
- Chaque covariance vaut $\rho\sigma \cdot \sigma = \rho\sigma^2$. Par la variance d'une somme, avec $\frac{n(n-1)}{2}$ couples $i < j$ comptés deux fois : $\text{Var} \left(\sum X_i \right) = n\sigma^2 + n(n-1)\rho\sigma^2$. Par $\text{Var}(aX) = a^2 \text{Var } X$ avec $a = 1/n$:

$$\text{Var } \bar{X} = \frac{1}{n^2} [n\sigma^2 + n(n-1)\rho\sigma^2] = \sigma^2 \left[\frac{1}{n} + \frac{(n-1)\rho}{n} \right].$$

- Quand $n \rightarrow \infty$, $\frac{1}{n} \rightarrow 0$ et $\frac{n-1}{n} \rightarrow 1$, donc $\text{Var } \bar{X} \rightarrow \rho\sigma^2$. La diversification est plafonnée par la corrélation : la part de risque due à une cause commune (tempête, crise) ne peut pas être éliminée par la mutualisation.
- Une variance est positive et $\sigma^2 > 0$, donc $\frac{1}{n} + \frac{(n-1)\rho}{n} \geq 0$; en multipliant par n , $1 + (n-1)\rho \geq 0$, soit $\rho \geq -1/(n-1)$.
- Pour $n = 10 : 0,1 + 0,9 \times 0,2 = 0,28$. À la limite : 0,20. Avec $\rho = 0 : 0,1$ puis 0. Au-delà de quelques dizaines de risques corrélés, ajouter des contrats ne réduit presque plus le risque.

Exercice 8.

- On applique la variance totale avec le système complet $\{A, B\}$, de probabilités π et $1 - \pi$, de moyennes conditionnelles μ_1, μ_2 et de variances conditionnelles σ^2 . Espérance : $\mu = \pi\mu_1 + (1 - \pi)\mu_2$. Écarts à la moyenne : $\mu_1 - \mu = \mu_1 - \pi\mu_1 - (1 - \pi)\mu_2 = (1 - \pi)(\mu_1 - \mu_2) = (1 - \pi)d$, et $\mu_2 - \mu = \mu_2 - \pi\mu_1 - \mu_2 + \pi\mu_2 = -\pi d$. Donc :

— partie intra : $\pi\sigma^2 + (1 - \pi)\sigma^2 = \sigma^2$;

— partie inter : $\pi(1 - \pi)^2 d^2 + (1 - \pi)\pi^2 d^2 = \pi(1 - \pi)d^2[(1 - \pi) + \pi] = \pi(1 - \pi)d^2$.

D'où $\text{Var } X = \sigma^2 + \pi(1 - \pi)d^2$.

- $\mu = \frac{10+16}{2} = 13$, $d = -6$, $\text{Var } X = 1 + \frac{1}{4} \times 36 = 10$, $\sigma_X \approx 3,16$: l'écart-type global est trois fois celui de chaque fournisseur.
- $\pi(1 - \pi) = \pi - \pi^2$ a pour dérivée $1 - 2\pi$, nulle en $\pi = \frac{1}{2}$; c'est une parabole tournée vers le bas, donc le maximum est atteint en $\pi = 1/2$.
- Les limites $13 \pm 3 \times 3,16$, soit $13 \pm 9,5$, donnent $[3,5 ; 22,5]$, alors que les pièces de chaque fournisseur restent dans $[7 ; 13]$ et $[13 ; 19]$. Une dérive de plusieurs unités chez un fournisseur passerait inaperçue. Il faut stratifier par fournisseur, c'est-à-dire surveiller chaque population avec sa propre variance intra.

Exercice 9.

1. Sachant $Y = y$, X suit $\text{Po}(\lambda_y)$, d'espérance et de variance λ_y (exercice 1). Donc $h(y) = v(y) = \lambda_y$, et $\mathbb{E}[X | Y] = \text{Var}(X | Y) = \lambda_Y$: c'est la variable qui vaut 1, 2 ou 5 avec probabilités 0,5, 0,3 et 0,2.
2. Espérance totale : $\mathbb{E}[X] = \mathbb{E}[\lambda_Y] = 0,5 \times 1 + 0,3 \times 2 + 0,2 \times 5 = 2,1$.
Variance totale : $\mathbb{E}[\text{Var}(X | Y)] = \mathbb{E}[\lambda_Y] = 2,1$ (partie intra), et $\text{Var}(\mathbb{E}[X | Y]) = \text{Var}(\lambda_Y) = \mathbb{E}[\lambda_Y^2] - \mathbb{E}[\lambda_Y]^2 = (0,5 \times 1 + 0,3 \times 4 + 0,2 \times 25) - 2,1^2 = 6,7 - 4,41 = 2,29$ (partie inter). Donc $\text{Var } X = 2,1 + 2,29 = 4,39$.
3. Une loi de Poisson a une espérance égale à sa variance (exercice 1). Ici $\text{Var } X = 4,39 > 2,1 = \mathbb{E}[X]$: X ne suit pas une loi de Poisson. Le mélange de lois de Poisson de paramètres différents est *surdispersé* ; l'excès de variance est exactement la partie inter, $\text{Var}(\lambda_Y)$. Ce phénomène est étudié en séance 2.
4. La meilleure prédiction connaissant la ligne est $\mathbb{E}[X | Y] = \lambda_Y$, d'erreur quadratique moyenne $\mathbb{E}[\text{Var}(X | Y)] = 2,1$. Pour une prédiction constante c , le développement $(X - c)^2 = (X - \mathbb{E}[X])^2 + 2(X - \mathbb{E}[X])(\mathbb{E}[X] - c) + (\mathbb{E}[X] - c)^2$ et la linéarité donnent $\mathbb{E}[(X - c)^2] = \text{Var } X + (\mathbb{E}[X] - c)^2$, minimal pour $c = \mathbb{E}[X]$, avec la valeur $\text{Var } X = 4,39$. Connaître la ligne divise l'erreur par deux environ : la partie inter de la variance est exactement ce que l'information sur la ligne permet d'expliquer.
5. Par les probabilités totales, $\mathbb{P}(X = 0) = 0,5e^{-1} + 0,3e^{-2} + 0,2e^{-5} \approx 0,2259$. Par la formule de Bayes,

$$\mathbb{P}(Y = 3 | X = 0) = \frac{0,2 e^{-5}}{\mathbb{P}(X = 0)} \approx \frac{0,00135}{0,2259} \approx 0,006.$$

Une pièce sans défaut provient presque sûrement d'une autre ligne ; on trouve de même $\mathbb{P}(Y = 1 | X = 0) \approx 0,81$.

2 Séance 2 — Fonctions génératrices, lois de Poisson, changements de variable

Objectifs. Maîtriser un outil qui transforme les sommes de variables indépendantes en produits. Manipuler les sommes aléatoires, qui modélisent la fréquence et la sévérité en analyse de risque. Modéliser l'hétérogénéité d'une fréquence par un mélange de lois de Poisson. Savoir déterminer la loi d'une fonction d'une variable, et simuler n'importe quelle loi à partir d'une loi uniforme.

2.1 Cours

2.1.1 Rappels d'analyse

Séries entières. Une série entière est une somme $\sum_{k \geq 0} a_k s^k$. Si elle converge pour $|s| < R$, la fonction $s \mapsto \sum_k a_k s^k$ est indéfiniment dérivable sur $] -R, R[$, et ses dérivées se calculent *terme à terme*, comme pour un polynôme (admis). Deux exemples :

- la série géométrique : pour $|u| < 1$, $\sum_{k \geq 0} u^k = \frac{1}{1-u}$. En effet, la somme partielle vaut $1 + u + \dots + u^n = \frac{1 - u^{n+1}}{1 - u}$ (on le vérifie en multipliant par $1 - u$), et $u^{n+1} \rightarrow 0$;
- la série exponentielle : pour tout réel u , $\sum_{k \geq 0} \frac{u^k}{k!} = e^u$ (admis).

Proposition 2.1 (Une limite fondamentale). *Si (u_n) est une suite telle que $nu_n \rightarrow a$, alors $(1 + u_n)^n \rightarrow e^a$. En particulier, pour tout réel a , $(1 + a/n)^n \rightarrow e^a$.*

Démonstration. Étape 1 (passage à l'exponentielle). Comme $nu_n \rightarrow a$, $u_n \rightarrow 0$; pour n assez grand, $1 + u_n > 0$ et l'on peut écrire $(1 + u_n)^n = \exp(n \ln(1 + u_n))$.

Étape 2 (limite de $\ln(1 + u)/u$). Quand $u \rightarrow 0$, $\frac{\ln(1 + u)}{u} = \frac{\ln(1 + u) - \ln 1}{u}$ est un taux d'accroissement de $\ln$ en 1 ; il tend vers $\ln'(1) = 1$.

Étape 3 (limite de l'exposant). Pour $u_n \neq 0$, $n \ln(1 + u_n) = nu_n \cdot \frac{\ln(1 + u_n)}{u_n} \rightarrow a \times 1 = a$ (et si $u_n = 0$, $n \ln(1 + u_n) = 0 = nu_n$).

Étape 4 (conclusion). L'exponentielle étant continue, $\exp(n \ln(1 + u_n)) \rightarrow e^a$. Le cas particulier correspond à $u_n = a/n$. $\square$

Cette limite servira pour l'approximation de Poisson, le TCL et les lois des valeurs extrêmes.

2.1.2 Définition

Définition 2.2. Soit X une variable à valeurs dans $\mathbb{N}$. Sa *fonction génératrice* est

$$G_X(s) = \mathbb{E}[s^X] = \sum_{x \geq 0} p(x) s^x \quad (\text{transfert avec } g(x) = s^x).$$

La série converge au moins pour $|s| \leq 1$: dans ce cas $|s|^x \leq 1$, donc $|p(x)s^x| \leq p(x)$, et la série des $p(x)$ converge (elle vaut 1) ; la série est donc absolument convergente. On a $G_X(1) = \sum_x p(x) = 1$ et $G_X(0) = p(0)$ (avec la convention $0^0 = 1$).

2.1.3 La fonction génératrice caractérise la loi

Théorème 2.3. $p(x) = G_X^{(x)}(0)/x!$, où $G_X^{(x)}$ désigne la dérivée d'ordre x .

Démonstration. Étape 1 (premiers cas). $G_X(s) = p(0) + p(1)s + p(2)s^2 + p(3)s^3 + \dots$, donc $G_X(0) = p(0)$. En dérivant terme à terme (rappel sur les séries entières), $G'_X(s) = p(1) + 2p(2)s + 3p(3)s^2 + \dots$, donc $G'_X(0) = p(1)$. Puis $G''_X(s) = 2p(2) + 6p(3)s + \dots$, donc $G''_X(0) = 2p(2)$.

Étape 2 (cas général). Dérivée k fois le monôme s^j donne 0 si $j < k$, et $j(j-1)\dots(j-k+1)s^{j-k}$ si $j \geq k$. En $s = 0$, seul le terme $j = k$ ne s'annule pas; il vaut $k(k-1)\dots 1 = k!$. Donc $G_X^{(k)}(0) = k!p(k)$. $\square$

Corollaire 2.4. Deux variables dont les fonctions génératrices coïncident sur $[0, 1[$ ont la même loi. Pour identifier une loi, il suffit de reconnaître sa fonction génératrice.

Démonstration. Si $G_X = G_Y$ sur $[0, 1[$, leurs dérivées de tous ordres coïncident sur $]0, 1[$ (ce sont les dérivées d'une même fonction), donc aussi en 0, par continuité des dérivées d'une série entière. Le théorème donne alors $p_X(k) = p_Y(k)$ pour tout k . $\square$

2.1.4 Calcul des moments

Théorème 2.5. Si $\mathbb{E}[X]$ (resp. $\mathbb{E}[X^2]$) est finie, G_X est dérivable (resp. deux fois dérivable) à gauche en 1 et

$$G'_X(1) = \mathbb{E}[X], \quad G''_X(1) = \mathbb{E}[X(X-1)], \quad \text{Var } X = G''_X(1) + G'_X(1) - G'_X(1)^2.$$

Démonstration. Étape 1 (dérivées). En dérivant terme à terme, $G'_X(s) = \sum_x x p(x) s^{x-1}$ et $G''_X(s) = \sum_x x(x-1) p(x) s^{x-2}$.

Étape 2 (valeur en 1). Si le rayon de convergence R est strictement supérieur à 1, ces formules valent en $s = 1$, où toutes les puissances de s valent 1 : $G'_X(1) = \sum_x x p(x) = \mathbb{E}[X]$ et $G''_X(1) = \sum_x x(x-1) p(x) = \mathbb{E}[X(X-1)]$ (transfert). Si $R = 1$, $G'_X(s)$ tend vers $\sum_x x p(x)$ quand $s \rightarrow 1^-$ (les termes sont positifs et croissent avec s), et la dérivée à gauche en 1 vaut cette limite par le théorème des accroissements finis (admis). Pour les lois usuelles (binomiale, Poisson, géométrique), le rayon est strictement supérieur à 1 et la question ne se pose pas.

Étape 3 (variance). Comme $X^2 = X(X-1) + X$, la linéarité donne $\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X]$, et la formule de Koenig donne $\text{Var } X = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - \mathbb{E}[X]^2 = G''_X(1) + G'_X(1) - G'_X(1)^2$. $\square$

2.1.5 Somme de variables indépendantes

Théorème 2.6. Si X et Y sont indépendantes, $G_{X+Y}(s) = G_X(s) G_Y(s)$ pour $|s| \leq 1$.

Démonstration. Étape 1. Par les règles de calcul sur les puissances, $s^{X+Y} = s^X s^Y$.

Étape 2. On applique le théorème du produit (séance 1) avec $g(x) = s^x$ et $h(y) = s^y$. Les espérances existent car $|s^X| \leq 1$ et $|s^Y| \leq 1$. Donc $G_{X+Y}(s) = \mathbb{E}[s^X s^Y] = \mathbb{E}[s^X] \mathbb{E}[s^Y] = G_X(s) G_Y(s)$. $\square$

De même, si $X_1, \dots, X_n$ sont indépendantes, la fonction génératrice de leur somme est le produit de leurs fonctions génératrices (théorème du produit pour n variables, avec $s^{X_1+\dots+X_n} = s^{X_1} \dots s^{X_n}$).

2.1.6 Fonctions génératrices des lois usuelles

- **Bernoulli** $\text{Be}(p)$. $G(s) = q s^0 + p s^1 = q + ps$.
- **Binomiale** $\text{Bi}(n, p)$. C'est la loi d'une somme de n variables $\text{Be}(p)$ indépendantes; par le théorème précédent, $G(s) = (q + ps)^n$. On le vérifie aussi directement par la formule du binôme : $\sum_x \binom{n}{x} p^x q^{n-x} s^x = \sum_x \binom{n}{x} (ps)^x q^{n-x} = (q + ps)^n$.
- **Poisson** $\text{Po}(\mu)$. On regroupe $\mu^x s^x = (\mu s)^x$ et on reconnaît la série exponentielle avec $u = \mu s$: $G(s) = \sum_x e^{-\mu} \frac{(\mu s)^x}{x!} = e^{-\mu} e^{\mu s} = e^{\mu(s-1)}$.

- **Géométrique** $\text{Ge}(p)$. On met ps en facteur, puis on pose $j = x - 1 : G(s) = \sum_{x \geq 1} p q^{x-1} s^x = ps \sum_{x \geq 1} (qs)^{x-1} = ps \sum_{j \geq 0} (qs)^j = \frac{ps}{1 - qs}$, par la série géométrique avec $u = qs$, valable pour $|qs| < 1$, c'est-à-dire $|s| < 1/q$.
- **Pascal** $\text{Pa}(k, p)$. $G(s) = (ps/(1 - qs))^k$, par identification des coefficients (exercice 2 du TD). C'est aussi la fonction génératrice d'une somme de k géométriques indépendantes.

2.1.7 Convergence en loi et approximation de Poisson

Définition 2.7 (Convergence en loi). Une suite (X_n) converge en loi vers X si $F_{X_n}(x) \rightarrow F_X(x)$ en tout point x où F_X est continue.

Proposition 2.8. Pour des variables à valeurs dans $\mathbb{N}$, X_n converge en loi vers X si et seulement si $\mathbb{P}(X_n = k) \rightarrow \mathbb{P}(X = k)$ pour tout entier k .

Démonstration. Étape 1 (points de continuité). X ne prend que des valeurs entières, donc F_X est constante sur chaque intervalle $[k, k + 1[$: elle ne saute qu'aux entiers. Les points $k \pm \frac{1}{2}$ sont donc des points de continuité de F_X .

Étape 2 (sens direct). X_n étant entière, $\{X_n \leq k + \frac{1}{2}\} = \{X_n \leq k\}$ et $\{X_n \leq k - \frac{1}{2}\} = \{X_n \leq k - 1\}$; la différence de ces deux événements est $\{X_n = k\}$. Donc $\mathbb{P}(X_n = k) = F_{X_n}(k + \frac{1}{2}) - F_{X_n}(k - \frac{1}{2})$, qui tend vers $F_X(k + \frac{1}{2}) - F_X(k - \frac{1}{2}) = \mathbb{P}(X = k)$ par l'étape 1.

Étape 3 (réciproque). Pour $x \geq 0$, $F_{X_n}(x) = \sum_{k=0}^{\lfloor x \rfloor} \mathbb{P}(X_n = k)$ est une somme d'un nombre fini de termes, qui convergent chacun; elle converge donc vers $\sum_{k=0}^{\lfloor x \rfloor} \mathbb{P}(X = k) = F_X(x)$. Pour $x < 0$, les deux membres sont nuls. $\square$

Théorème 2.9 (Continuité, admis). Soient X_n et X à valeurs dans $\mathbb{N}$. Si $G_{X_n}(s) \rightarrow G_X(s)$ pour tout $s \in [0, 1]$, alors $\mathbb{P}(X_n = x) \rightarrow \mathbb{P}(X = x)$ pour tout x , c'est-à-dire que X_n converge en loi vers X .

Corollaire 2.10 (Approximation de Poisson). Si $X_n \sim \text{Bi}(n, \mu/n)$ (pour $n > \mu$), alors X_n converge en loi vers $\text{Po}(\mu)$.

Démonstration. Étape 1. Avec $p = \mu/n : q + ps = 1 - \frac{\mu}{n} + \frac{\mu}{n}s = 1 + \frac{\mu(s-1)}{n}$.

Étape 2. Donc $G_{X_n}(s) = (1 + \mu(s-1)/n)^n$. Par la limite fondamentale avec $a = \mu(s-1)$ (fixé), $G_{X_n}(s) \rightarrow e^{\mu(s-1)}$.

Étape 3. On reconnaît la fonction génératrice de $\text{Po}(\mu)$; le théorème de continuité conclut. $\square$

2.1.8 Sommes aléatoires

Cadre. $S = Y_1 + \dots + Y_N$, où N est à valeurs dans $\mathbb{N}$ et où les Y_i sont de même loi et où, pour tout n , les variables $N, Y_1, \dots, Y_n$ sont indépendantes (avec $S = 0$ si $N = 0$). On admet qu'alors, pour tout n et tout intervalle B , les événements $\{Y_1 + \dots + Y_n \in B\}$ et $\{N = n\}$ sont indépendants; dans le cas discret, cela se vérifie en sommant la loi conjointe de $(N, Y_1, \dots, Y_n)$. En assurance, N est le nombre de sinistres et Y_i le coût du i -ème; en risque industriel, N peut être un nombre de départs de feu et Y_i la surface brûlée.

Loi de S sachant $N = n$. Soit n tel que $\mathbb{P}(N = n) > 0$. Sur l'événement $\{N = n\}$, $S = Y_1 + \dots + Y_n$. Donc, pour tout intervalle B ,

$$\mathbb{P}(S \in B \mid N = n) = \frac{\mathbb{P}(Y_1 + \dots + Y_n \in B \cap N = n)}{\mathbb{P}(N = n)} = \frac{\mathbb{P}(Y_1 + \dots + Y_n \in B) \mathbb{P}(N = n)}{\mathbb{P}(N = n)} = \mathbb{P}(Y_1 + \dots + Y_n \in B),$$

la deuxième égalité venant de l'indépendance admise dans le cadre. Sachant $N = n$, S a la loi de $Y_1 + \dots + Y_n$: c'est le point clé des trois démonstrations qui suivent.

Théorème 2.11 (Fonction génératrice composée). *Si les Y_i sont à valeurs dans $\mathbb{N}$, $G_S(s) = G_N(G_Y(s))$ pour $|s| \leq 1$.*

Démonstration. Étape 1 (découpage selon N). Par le raisonnement « par tiroirs » de la séance 1, appliqué au système complet $\{N = n\}$ (on ne garde que les n tels que $\mathbb{P}(N = n) > 0$) : $\mathbb{P}(S = k) = \sum_n \mathbb{P}(N = n) \mathbb{P}(S = k \mid N = n) = \sum_n \mathbb{P}(N = n) \mathbb{P}(Y_1 + \dots + Y_n = k)$.

Étape 2 (fonction génératrice). On multiplie par s^k et on somme sur k ; l'interversion des deux sommes est licite car la double série est absolument convergente pour $|s| \leq 1$:

$$G_S(s) = \sum_k s^k \sum_n \mathbb{P}(N = n) \mathbb{P}(Y_1 + \dots + Y_n = k) = \sum_n \mathbb{P}(N = n) \sum_k s^k \mathbb{P}(Y_1 + \dots + Y_n = k).$$

Étape 3 (somme de n variables indépendantes). La somme intérieure est la fonction génératrice de $Y_1 + \dots + Y_n$, qui vaut $G_Y(s)^n$ (produit de n fonctions génératrices identiques).

Étape 4 (on reconnaît G_N). Il reste $\sum_n \mathbb{P}(N = n) u^n$ avec $u = G_Y(s)$, qui vérifie $|u| \leq 1$: c'est $G_N(u) = G_N(G_Y(s))$. $\square$

Théorème 2.12 (Formules de Wald). *Pour Y discrète ou continue, si N et Y admettent une variance :*

$$\mathbb{E}[S] = \mathbb{E}[N] \mathbb{E}[Y], \quad \text{Var } S = \mathbb{E}[N] \text{Var } Y + \text{Var } N \mathbb{E}[Y]^2.$$

Démonstration. Étape 1 (moments conditionnels). Sachant $N = n$, S a la loi de $Y_1 + \dots + Y_n$. Par linéarité, $\mathbb{E}[S \mid N = n] = n \mathbb{E}[Y]$; les Y_i étant indépendantes, la variance de la somme est la somme des variances : $\text{Var}(S \mid N = n) = n \text{Var } Y$.

Étape 2 (S est de variance finie). Par la formule de Koenig conditionnelle, $\mathbb{E}[S^2 \mid N = n] = n \text{Var } Y + n^2 \mathbb{E}[Y]^2$. En sommant (termes positifs), $\mathbb{E}[S^2] = \sum_n \mathbb{P}(N = n) (n \text{Var } Y + n^2 \mathbb{E}[Y]^2) = \mathbb{E}[N] \text{Var } Y + \mathbb{E}[N^2] \mathbb{E}[Y]^2 < \infty$.

Étape 3 (variance totale). On applique la variance totale (séance 1, avec la remarque sur les partitions dénombrables) au système complet $\{N = n\}$, avec $\pi_n = \mathbb{P}(N = n)$, $\mu_n = n \mathbb{E}[Y]$ et $\sigma_n^2 = n \text{Var } Y$:

- espérance : $\mathbb{E}[S] = \sum_n \pi_n n \mathbb{E}[Y] = \mathbb{E}[Y] \sum_n n \pi_n = \mathbb{E}[Y] \mathbb{E}[N]$;
- partie intra : $\sum_n \pi_n n \text{Var } Y = \text{Var } Y \sum_n n \pi_n = \mathbb{E}[N] \text{Var } Y$;
- partie inter : $\sum_n \pi_n (n \mathbb{E}[Y] - \mathbb{E}[N] \mathbb{E}[Y])^2 = \mathbb{E}[Y]^2 \sum_n \pi_n (n - \mathbb{E}[N])^2 = \mathbb{E}[Y]^2 \text{Var } N$.

En additionnant les parties intra et inter, on obtient la formule. $\square$

Remarque. Le premier terme mesure le risque de **sévérité**, le second le risque de **fréquence**. Pour une loi de Poisson composée, $\mathbb{E}[N] = \text{Var } N = \lambda$, d'où $\text{Var } S = \lambda(\text{Var } Y + \mathbb{E}[Y]^2) = \lambda \mathbb{E}[Y^2]$. (La première formule est l'identité de Wald ; la seconde est souvent attribuée à Blackwell et Girshick.)

2.1.9 Amincissement d'une loi de Poisson

Théorème 2.13. *Soit $N \sim \text{Po}(\lambda)$ et $M = B_1 + \dots + B_N$, où les B_i suivent $\text{Be}(p)$ et où, pour tout n , $N, B_1, \dots, B_n$ sont indépendantes : chacun des N événements est retenu avec probabilité p , et M est le nombre d'événements retenus. Alors $M \sim \text{Po}(\lambda p)$, $N - M \sim \text{Po}(\lambda q)$, et M et $N - M$ sont indépendantes.*

Démonstration. Étape 1 (loi de M sachant $N = n$). C'est un cas particulier de somme aléatoire : sachant $N = n$, M a la loi de $B_1 + \dots + B_n$, somme de n variables $\text{Be}(p)$ indépendantes, c'est-à-dire $\text{Bi}(n, p)$. Tous les $\mathbb{P}(N = n)$ sont non nuls pour une loi de Poisson.

Étape 2 (réécriture de l'événement). Dire que $M = m$ et $N - M = j$, c'est dire que $M = m$ et $N = m + j$. Par la formule des probabilités composées, $\mathbb{P}(M = m, N - M = j) = \mathbb{P}(N = m + j) \mathbb{P}(M = m \mid N = m + j)$.

Étape 3 (on remplace). Avec la loi de Poisson pour N et la loi binomiale de l'étape 1, où $\binom{m+j}{m} = \frac{(m+j)!}{m!j!}$:

$$\mathbb{P}(M = m, N - M = j) = e^{-\lambda} \frac{\lambda^{m+j}}{(m+j)!} \cdot \frac{(m+j)!}{m!j!} p^m q^j = e^{-\lambda} \frac{\lambda^{m+j} p^m q^j}{m!j!}.$$

Étape 4 (on sépare m et j). Comme $p + q = 1$, $e^{-\lambda} = e^{-\lambda(p+q)} = e^{-\lambda p} e^{-\lambda q}$, et $\lambda^{m+j} p^m q^j = (\lambda p)^m (\lambda q)^j$. Donc

$$\mathbb{P}(M = m, N - M = j) = \left[e^{-\lambda p} \frac{(\lambda p)^m}{m!} \right] \times \left[e^{-\lambda q} \frac{(\lambda q)^j}{j!} \right].$$

Étape 5 (lois marginales). Pour obtenir la loi de M , on somme sur j (lois marginales, séance 1) ; le second crochet est la loi $\text{Po}(\lambda q)$, dont la somme vaut 1. Donc $\mathbb{P}(M = m) = e^{-\lambda p} (\lambda p)^m / m!$: $M \sim \text{Po}(\lambda p)$. De même, en sommant sur m , $N - M \sim \text{Po}(\lambda q)$.

Étape 6 (indépendance). L'étape 4 dit exactement que la loi conjointe est le produit des deux lois marginales : M et $N - M$ sont indépendantes (séance 1). $\square$

Remarque. Variante : M est une somme aléatoire avec $Y \sim \text{Be}(p)$, donc $G_M(s) = G_N(q + ps) = e^{\lambda(q+ps-1)} = e^{\lambda p(s-1)}$, fonction génératrice de $\text{Po}(\lambda p)$.

2.1.10 Mélanges de lois de Poisson et surdispersion

En pratique, l'intensité d'un phénomène varie : d'une saison à l'autre pour les feux, d'un assuré à l'autre pour les sinistres, d'un site à l'autre pour les incidents. On modélise cette hétérogénéité en rendant le paramètre de la loi de Poisson lui-même aléatoire.

La fonction Gamma et la loi Gamma. Pour $a > 0$, on pose $\Gamma(a) = \int_0^{+\infty} x^{a-1} e^{-x} dx$. Cette intégrale converge : près de 0, $\int_\varepsilon^1 x^{a-1} dx = (1 - \varepsilon^a)/a \leq 1/a$; près de $+\infty$, pour $x \geq 1$ et l'entier $m = \lceil a \rceil + 1 \geq a + 1$, on a $0 \leq x^{a+1} e^{-x} \leq x^m e^{-x}$, qui tend vers 0 par croissances comparées (proposition 1.25(a) du TD 1) ; donc $x^{a-1} e^{-x} \leq 1/x^2$ pour x assez grand. Une intégration par parties sur $[\varepsilon, A]$ donne $\Gamma(a+1) = a \Gamma(a)$, et l'on a vu que $\Gamma(n+1) = n!$ (exercice 2 du TD 1).

Définition 2.14. Pour $\alpha > 0$ et $\beta > 0$, la loi Gamma $\Gamma(\alpha, \beta)$ a pour densité

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \quad \text{pour } x > 0, \quad f(x) = 0 \text{ sinon.}$$

C'est bien une densité : le changement de variable $u = \beta x$ donne $\int_0^{+\infty} x^{\alpha-1} e^{-\beta x} dx = \Gamma(\alpha) / \beta^\alpha$. Pour $\alpha = 1$, on retrouve la loi exponentielle de paramètre β .

Proposition 2.15. Si $\Lambda \sim \Gamma(\alpha, \beta)$, alors $\mathbb{E}[\Lambda] = \alpha/\beta$ et $\text{Var } \Lambda = \alpha/\beta^2$.

Démonstration. Par le transfert et le calcul précédent (avec $\alpha + 1$ puis $\alpha + 2$ à la place de α) : $\mathbb{E}[\Lambda] = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+1)}{\beta^{\alpha+1}} = \frac{\alpha}{\beta}$ et $\mathbb{E}[\Lambda^2] = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+2)}{\beta^{\alpha+2}} = \frac{\alpha(\alpha+1)}{\beta^2}$, en utilisant $\Gamma(\alpha+2) = (\alpha+1)\alpha\Gamma(\alpha)$. Par Koenig, $\text{Var } \Lambda = \frac{\alpha(\alpha+1) - \alpha^2}{\beta^2} = \frac{\alpha}{\beta^2}$. $\square$

Définition 2.16 (Loi de Poisson mélangée). Soit $\Lambda \geq 0$ une variable de densité f_Λ . On dit que N suit une loi de Poisson mélangée par Λ si, pour tout entier $k \geq 0$,

$$\mathbb{P}(N = k) = \int_0^{+\infty} e^{-\lambda} \frac{\lambda^k}{k!} f_\Lambda(\lambda) d\lambda.$$

C'est la version à densité des probabilités totales : sachant $\Lambda = \lambda$, N suit $\text{Po}(\lambda)$.

On vérifie que c'est une loi : les termes sont positifs, et en intervertissant somme et intégrale (licite pour des termes positifs, admis), $\sum_k \mathbb{P}(N = k) = \int (\sum_k e^{-\lambda} \lambda^k / k!) f_\Lambda(\lambda) d\lambda = \int f_\Lambda = 1$.

Théorème 2.17 (Surdispersion). *Si $\mathbb{E}[\Lambda^2] < \infty$, alors $\mathbb{E}[N] = \mathbb{E}[\Lambda]$ et $\text{Var } N = \mathbb{E}[\Lambda] + \text{Var } \Lambda$. En particulier $\text{Var } N \geq \mathbb{E}[N]$, avec égalité si et seulement si Λ est constante.*

Démonstration. Étape 1 (espérance). Par définition et interversion somme-intégrale (termes positifs), puis par l'exercice 1 du TD 1 ($\sum_k k e^{-\lambda} \lambda^k / k! = \lambda$) : $\mathbb{E}[N] = \int (\sum_k k e^{-\lambda} \frac{\lambda^k}{k!}) f_\Lambda(\lambda) d\lambda = \int \lambda f_\Lambda(\lambda) d\lambda = \mathbb{E}[\Lambda]$.

Étape 2 (moment factoriel). De même, avec $\sum_k k(k-1) e^{-\lambda} \lambda^k / k! = \lambda^2$: $\mathbb{E}[N(N-1)] = \int \lambda^2 f_\Lambda(\lambda) d\lambda = \mathbb{E}[\Lambda^2]$.

Étape 3 (variance). $\text{Var } N = \mathbb{E}[N(N-1)] + \mathbb{E}[N] - \mathbb{E}[N]^2 = \mathbb{E}[\Lambda^2] + \mathbb{E}[\Lambda] - \mathbb{E}[\Lambda]^2 = \mathbb{E}[\Lambda] + \text{Var } \Lambda$. Enfin $\text{Var } \Lambda = 0$ si et seulement si Λ est constante presque sûrement. $\square$

C'est exactement la variance totale : $\mathbb{E}[\text{Var}(N | \Lambda)] = \mathbb{E}[\Lambda]$ (partie intra) et $\text{Var}(\mathbb{E}[N | \Lambda]) = \text{Var } \Lambda$ (partie inter). L'hétérogénéité du paramètre crée un excès de variance, qu'on appelle *surdispersion*.

Théorème 2.18 (Mélange Poisson-Gamma). *Si $\Lambda \sim \Gamma(\alpha, \beta)$, alors, avec $p = \frac{\beta}{1+\beta}$ et $q = 1 - p$,*

$$\mathbb{P}(N = k) = \frac{\Gamma(k + \alpha)}{k! \Gamma(\alpha)} p^\alpha q^k, \quad k = 0, 1, 2, \dots$$

C'est la loi binomiale négative $\text{BN}(\alpha, p)$, d'espérance $\alpha/\beta = \alpha q/p$ et de variance $\alpha/\beta + \alpha/\beta^2 = \alpha q/p^2$.

Démonstration. Étape 1 (on regroupe les exponentielles).

$$\mathbb{P}(N = k) = \int_0^{+\infty} e^{-\lambda} \frac{\lambda^k}{k!} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} d\lambda = \frac{\beta^\alpha}{k! \Gamma(\alpha)} \int_0^{+\infty} \lambda^{k+\alpha-1} e^{-(1+\beta)\lambda} d\lambda.$$

Étape 2 (on reconnaît une fonction Gamma). Par le calcul qui montre que la loi Gamma est une densité (avec $k + \alpha$ et $1 + \beta$ à la place de α et β), l'intégrale vaut $\Gamma(k + \alpha)/(1 + \beta)^{k+\alpha}$. Donc

$$\mathbb{P}(N = k) = \frac{\Gamma(k + \alpha)}{k! \Gamma(\alpha)} \left(\frac{\beta}{1 + \beta}\right)^\alpha \left(\frac{1}{1 + \beta}\right)^k = \frac{\Gamma(k + \alpha)}{k! \Gamma(\alpha)} p^\alpha q^k.$$

Étape 3 (moments). Par le théorème de surdispersion et les moments de la loi Gamma, $\mathbb{E}[N] = \alpha/\beta$ et $\text{Var } N = \alpha/\beta + \alpha/\beta^2$. Comme $q/p = 1/\beta$, cela s'écrit $\alpha q/p$ et $\alpha q/p \cdot (1 + 1/\beta) = \alpha q/p^2$ (car $1 + 1/\beta = 1/p$). $\square$

Remarque. Lorsque $\alpha = r$ est entier, $\frac{\Gamma(k+r)}{k! \Gamma(r)} = \frac{(k+r-1)!}{k! (r-1)!} = \binom{k+r-1}{k}$: $\text{BN}(r, p)$ est la loi du nombre d'échecs avant le r -ième succès, c'est-à-dire $X - r$ où X suit la loi de Pascal $\text{Pa}(r, p)$. Le paramètre α mesure l'hétérogénéité : quand $\alpha \rightarrow \infty$ à espérance $\alpha/\beta = \mu$ fixée, $\text{Var } \Lambda = \mu^2/\alpha \rightarrow 0$ et l'on retrouve la loi de Poisson.

Proposition 2.19 (Amincissement d'un mélange). *Soit N une loi de Poisson mélangée par Λ , avec $\mathbb{E}[\Lambda^2] < \infty$, dont chaque événement est retenu avec probabilité p comme dans le théorème d'amincissement : sachant $\Lambda = \lambda$, M et $N - M$ sont indépendantes, de lois $\text{Po}(\lambda p)$ et $\text{Po}(\lambda q)$. Alors $\text{Cov}(M, N - M) = pq \text{Var } \Lambda$. Les événements retenus et rejetés ne sont plus indépendants dès que l'intensité est aléatoire.*

Démonstration. Comme à l'étape 1 du théorème de surdispersion, on calcule les espérances en intégrant les espérances conditionnelles contre f_Λ (interversion licite par convergence absolue, admise) : $\mathbb{E}[M] = p \mathbb{E}[\Lambda]$, $\mathbb{E}[N - M] = q \mathbb{E}[\Lambda]$ et, par l'indépendance conditionnelle, $\mathbb{E}[M(N - M)] = \int (\lambda p)(\lambda q) f_\Lambda(\lambda) d\lambda = pq \mathbb{E}[\Lambda^2]$. Donc $\text{Cov}(M, N - M) = pq \mathbb{E}[\Lambda^2] - pq \mathbb{E}[\Lambda]^2 = pq \text{Var } \Lambda$. $\square$

Cette proposition justifie la remarque de l'exercice sur les départs de feu : une corrélation observée entre petits et grands feux révèle une intensité variable d'une saison à l'autre.

2.1.11 Changement de variable

Rappels. (i) Une fonction $h \geq 0$ est une densité de Y si $F_Y(y) = \int_{-\infty}^y h(u) du$ pour tout y . (ii) Si g est de classe C^1 sur un intervalle I et si g' ne s'annule pas sur I , alors g' , continue, garde un signe constant (théorème des valeurs intermédiaires) : g est strictement monotone, sa réciproque g^{-1} est de classe C^1 sur l'intervalle $g(I)$ et $(g^{-1})'(y) = 1/g'(g^{-1}(y))$. L'hypothèse $g' \neq 0$ est indispensable : $g(x) = x^3$ est strictement croissante, mais $g^{-1}(y) = y^{1/3}$ n'est pas dérivable en 0. (iii) Changement de variable dans une intégrale : si φ est de classe C^1 et strictement monotone sur $[c, d]$ et si f est continue par morceaux, $\int_{\varphi(c)}^{\varphi(d)} f(x) dx = \int_c^d f(\varphi(u)) \varphi'(u) du$; cette formule s'étend aux bornes infinies lorsque $f \geq 0$, les deux membres étant alors des limites d'intégrales sur des intervalles bornés.

Théorème 2.20. Soit X de densité f_X continue par morceaux, avec $\mathbb{P}(X \in I) = 1$ pour un intervalle ouvert I , et $Y = g(X)$, avec g de classe C^1 sur I et g' ne s'annulant pas (donc g strictement monotone, et g^{-1} de classe C^1 sur l'intervalle $g(I)$, par le rappel (ii)). Alors

$$f_Y(y) = f_X(g^{-1}(y)) |(g^{-1})'(y)| \quad \text{pour } y \in g(I), \quad f_Y(y) = 0 \text{ sinon.}$$

Démonstration. On note $I =]\alpha, \beta[$ et $g(I) =]\gamma, \delta[$ (bornes éventuellement infinies), et $h(u) = f_X(g^{-1}(u)) |(g^{-1})'(u)|$ pour $u \in g(I)$. D'après le rappel (i), il suffit de montrer que $F_Y(y) = \int_{\gamma}^y h(u) du$ pour $y \in g(I)$. En dehors de $g(I)$, Y ne prend pas de valeurs : F_Y vaut 0 à gauche de $g(I)$ et 1 à droite, et la densité y est nulle.

Étape 1 (g croissante : on résout l'inégalité). Pour $X \in I$, appliquer g^{-1} (croissante) aux deux membres de $g(X) \leq y$ donne $X \leq g^{-1}(y)$, et réciproquement en appliquant g . Comme $X \in I$ avec probabilité 1,

$$F_Y(y) = \mathbb{P}(X \leq g^{-1}(y)) = \int_{\alpha}^{g^{-1}(y)} f_X(x) dx.$$

Étape 2 (g croissante : changement de variable). On pose $x = g^{-1}(u)$ (rappel (iii) avec $\varphi = g^{-1}$). Quand u va de γ à y , x va de α à $g^{-1}(y)$. Donc $F_Y(y) = \int_{\gamma}^y f_X(g^{-1}(u)) (g^{-1})'(u) du$, et ici $(g^{-1})' > 0$, donc $(g^{-1})' = |(g^{-1})'|$.

Étape 3 (g décroissante). Appliquer une fonction décroissante renverse l'inégalité : $g(X) \leq y \iff X \geq g^{-1}(y)$. Donc $F_Y(y) = \int_{g^{-1}(y)}^{\beta} f_X(x) dx$. Avec $x = g^{-1}(u)$: quand u va de y à γ , x va de $g^{-1}(y)$ à β . Donc

$$F_Y(y) = \int_y^{\gamma} f_X(g^{-1}(u)) (g^{-1})'(u) du = \int_{\gamma}^y f_X(g^{-1}(u)) (-(g^{-1})'(u)) du,$$

en échangeant les bornes (ce qui change le signe). Ici $(g^{-1})' < 0$, donc $-(g^{-1})' = |(g^{-1})'|$.

Dans les deux cas, $F_Y(y) = \int_{\gamma}^y h(u) du$. Cette preuve ne suppose pas f_X continue : continue par morceaux suffit. $\square$

Remarque. Si g n'est pas monotone, on revient à la méthode générale : on calcule $F_Y(y) = \mathbb{P}(g(X) \leq y)$ en résolvant l'inégalité en X , puis on dérive là où c'est licite (par exemple lorsque F_Y est continue et de classe C^1 par morceaux).

2.1.12 Méthode d'inversion

Théorème 2.21. Soit $U \sim \text{Un}(0, 1)$ et F une fonction de répartition continue, strictement croissante sur l'intervalle $I = \{x : 0 < F(x) < 1\}$; on note $F^{-1} :]0, 1[\rightarrow I$ sa réciproque. Alors $X = F^{-1}(U)$ a pour fonction de répartition F .

Démonstration. *Étape 1 (X est bien défini).* Avec probabilité 1, $U \in]0, 1[$; donc $F^{-1}(U)$ est défini et $X \in I$.

Étape 2 (on résout l'inégalité). Soit $x \in I$. Si $F^{-1}(U) \leq x$, on applique F , croissante : $F(F^{-1}(U)) \leq F(x)$, c'est-à-dire $U \leq F(x)$. Réciproquement, si $U \leq F(x)$, on applique F^{-1} , croissante : $F^{-1}(U) \leq F^{-1}(F(x)) = x$. Donc $\{X \leq x\} = \{U \leq F(x)\}$.

Étape 3 (loi uniforme). Pour $u \in [0, 1]$, $\mathbb{P}(U \leq u) = u$. Donc $\mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) = F(x)$.

Étape 4 (hors de I). Si x est à gauche de I , $F(x) = 0$, et $\mathbb{P}(X \leq x) = 0$ puisque $X \in I$; si x est à droite, $F(x) = 1$ et $\mathbb{P}(X \leq x) = 1$. $\square$

Remarque. L'hypothèse porte sur I seulement : les lois exponentielle, uniforme ou de Pareto, dont F est constante hors de leur support, sont bien couvertes.

Proposition 2.22 (Réciproque). *Si X a une fonction de répartition F vérifiant les hypothèses du théorème, $F(X) \sim \text{Un}(0, 1)$.*

Démonstration. Étape 1. F étant continue, $\mathbb{P}(X \notin I) = 0$: en effet, X ne tombe à gauche de I qu'avec probabilité $F(\inf I) = 0$, et à droite qu'avec probabilité $1 - F(\sup I) = 0$.

Étape 2. Pour $X \in I$ et $u \in]0, 1[$, le même raisonnement qu'à l'étape 2 du théorème donne $F(X) \leq u \iff X \leq F^{-1}(u)$.

Étape 3. Donc $\mathbb{P}(F(X) \leq u) = \mathbb{P}(X \leq F^{-1}(u)) = F(F^{-1}(u)) = u$: c'est la fonction de répartition de $\text{Un}(0, 1)$. $\square$

Remarque. Pour une fonction de répartition quelconque (notamment discrète), on utilise l'inverse généralisée $F^{-1}(u) = \inf\{x : F(x) \geq u\}$; le théorème d'inversion reste vrai (admis). La réciproque, elle, exige F continue : si X est discrète, $F(X)$ n'est pas uniforme. Comme $1 - U$ est aussi uniforme, on peut simplifier certaines formules. C'est la base de la simulation Monte-Carlo.

2.2 TD 2

Exercice 1 — Retrouver les moments par les fonctions génératrices.

À l'aide des fonctions génératrices, retrouver l'espérance et la variance des lois suivantes (on note $q = 1 - p$) :

1. la loi de Poisson $\text{Po}(\mu)$;
2. la loi géométrique $\text{Ge}(p)$;
3. la loi binomiale $\text{Bi}(n, p)$.

Comparer avec les calculs directs du TD 1 (exercice 1 pour la loi de Poisson, exercice 4 pour la loi binomiale).

Exercice 2 — Sommes de variables indépendantes.

1. Montrer que si $X \sim \text{Bi}(n, p)$ et $Y \sim \text{Bi}(m, p)$ sont indépendantes, $X + Y \sim \text{Bi}(n + m, p)$. Interpréter.
2. Même question pour $X \sim \text{Po}(\mu_1)$ et $Y \sim \text{Po}(\mu_2)$.
3. On admet que $(1 - u)^{-k} = \sum_{j \geq 0} \binom{k+j-1}{j} u^j$ pour $|u| < 1$. Montrer que la somme de k variables $\text{Ge}(p)$ indépendantes suit $\text{Pa}(k, p)$.
4. Si $X \sim \text{Bi}(n, p)$ et $Y \sim \text{Bi}(m, p')$ avec $p \neq p'$ et $0 < p, p' < 1$, $X + Y$ suit-elle une loi binomiale ?

Exercice 3 — Approximation de Poisson.

Une soudure est défectueuse avec probabilité $p = 0,002$, indépendamment des autres. Une structure comporte $n = 1000$ soudures ; X est le nombre de soudures défectueuses.

1. Démontrer, par les fonctions génératrices, que $\text{Bi}(n, \mu/n)$ converge en loi vers $\text{Po}(\mu)$.
2. Calculer $\mathbb{P}(X = 0)$ et $\mathbb{P}(X \leq 2)$ exactement puis par l'approximation de Poisson. Commenter.

Exercice 4 — Départs de feu et grands feux.

Sur une saison, le nombre N de départs de feu dans un massif suit $\text{Po}(40)$. Chaque départ devient un grand feu avec probabilité $p = 0,05$, indépendamment des autres départs et de leur nombre (modèle de l'amincissement du cours).

1. Déterminer la loi du nombre M de grands feux, par les probabilités totales.
2. Calculer $\mathbb{P}(M = 0)$ et $\mathbb{P}(M \geq 3)$.
3. La saison a compté 50 petits feux. Quelle est la loi de M sachant cette information ? Que vaut $\mathbb{P}(M = 0 \mid N - M = 50)$?
4. Même situation, mais le nombre de départs est fixé à $N = 40$. M et $N - M$ sont-elles encore indépendantes ?
5. Retrouver la loi de M par les fonctions génératrices.

Exercice 5 — Charge sinistre annuelle.

Le nombre annuel de sinistres suit $N \sim \text{Po}(20)$. Les coûts Y_i suivent tous une loi exponentielle de moyenne 5 k, et pour tout n , les variables $N, Y_1, \dots, Y_n$ sont indépendantes (cadre des sommes aléatoires du cours).

1. Calculer $\mathbb{E}[S]$ et $\text{Var } S$ pour la charge annuelle $S = Y_1 + \dots + Y_N$.
2. Quelle part de la variance provient du risque de fréquence ? du risque de sévérité ?
3. Même question si le nombre de sinistres était certain et égal à 20.
4. Même question si N suivait une binomiale négative de moyenne 20 et de variance 40.
5. Prime selon le principe de l'écart-type : $\mathbb{E}[S] + 0,5\sigma_S$. Comparer les primes des cas 1 et 4.

Exercice 6 — Changements de variable.

1. Soit $X \sim \mathcal{N}(\mu, \sigma^2)$, avec $\sigma > 0$, et $Y = e^X$. Déterminer la densité de Y (loi log-normale).
2. Montrer que $\mathbb{E}[Y] = e^{\mu + \sigma^2/2}$, en complétant le carré dans l'exposant.
3. Montrer que la médiane de Y est e^μ . Comparer avec l'espérance ; valeurs numériques pour $\mu = 0$, $\sigma = 1$.
4. Soit $Z \sim \mathcal{N}(0, 1)$. Déterminer la densité de Z^2 (loi du χ^2 à 1 degré de liberté).
5. Un laser, placé à distance 1 d'un mur, est orienté selon un angle $\Theta \sim \text{Un}(-\pi/2, \pi/2)$ par rapport à la perpendiculaire au mur. Déterminer la loi de la position $X = \tan \Theta$ du point d'impact.

Exercice 7 — Simulation par inversion.

1. Donner une formule pour simuler $X \sim \text{Exp}(\lambda)$ à partir de $U \sim \text{Un}(0, 1)$.
2. Même question pour la loi de Pareto de paramètres $x_m > 0$ et $\alpha > 0$, de fonction de répartition $F(x) = 1 - (x_m/x)^\alpha$ pour $x \geq x_m$ (et $F(x) = 0$ pour $x < x_m$).
3. Soit $q \in]0, 1[$. Montrer que $X = \lceil \ln U / \ln q \rceil$ suit la loi géométrique de paramètre $p = 1 - q$ ($\lceil y \rceil$ est le plus petit entier supérieur ou égal à y).
4. Écrire et exécuter un script qui vérifie empiriquement les résultats 1 et 3.

Exercice 8 — Hétérogénéité de la fréquence des sinistres.

Dans un portefeuille, le nombre annuel de sinistres N suit une loi de Poisson dont l'intensité Λ est aléatoire, de loi $\Gamma(\alpha, \beta)$: elle varie d'une année à l'autre (conditions climatiques, conjoncture).

1. Rappeler la loi de N , son espérance et sa variance.
2. Déterminer α et β pour que $\mathbb{E}[N] = 20$ et $\text{Var } N = 40$. Faire le lien avec la question 4 de l'exercice 5.

3. Avec ces valeurs, calculer $\mathbb{P}(N = 0)$, et le comparer à la valeur obtenue pour une loi $\text{Po}(20)$. On donne $\mathbb{P}(N \geq 30) \approx 0,076$ et $\mathbb{P}(N \geq 35) \approx 0,020$ pour la binomiale négative, contre 0,022 et 0,0015 pour $\text{Po}(20)$. Commenter.
4. On reprend le modèle d'amincissement de l'exercice 4, mais l'intensité Λ des départs de feu est désormais aléatoire, d'espérance 40 et de variance 100. Calculer la covariance et le coefficient de corrélation entre le nombre de grands feux M et le nombre de petits feux $N - M$, pour $p = 0,05$.

2.3 Corrigés du TD 2

Exercice 1.

1. $G(s) = e^{\mu(s-1)}$. La dérivée de $e^{u(s)}$ est $u'(s)e^{u(s)}$; ici $u(s) = \mu(s-1)$ et $u' = \mu$. Donc $G'(s) = \mu e^{\mu(s-1)}$ et $G''(s) = \mu^2 e^{\mu(s-1)}$. En $s = 1$, $e^0 = 1$: $\mathbb{E}[X] = G'(1) = \mu$ et $G''(1) = \mu^2$, d'où $\text{Var } X = \mu^2 + \mu - \mu^2 = \mu$.
2. $G(s) = \frac{ps}{1-qs}$. Règle du quotient $(u/v)' = (u'v - uv')/v^2$ avec $u = ps$, $u' = p$, $v = 1 - qs$, $v' = -q$:

$$G'(s) = \frac{p(1-qs) - ps(-q)}{(1-qs)^2} = \frac{p - pqs + pqs}{(1-qs)^2} = \frac{p}{(1-qs)^2}.$$

En $s = 1$, $1 - q = p$, donc $G'(1) = p/p^2 = 1/p$. On dérive $G'(s) = p(1-qs)^{-2}$: $G''(s) = p \cdot (-2)(1-qs)^{-3} \cdot (-q) = \frac{2pq}{(1-qs)^3}$, donc $G''(1) = 2pq/p^3 = 2q/p^2$. Enfin

$$\text{Var } X = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{2q + p - 1}{p^2} = \frac{2q - q}{p^2} = \frac{q}{p^2},$$

car $p - 1 = -q$.

3. $G(s) = (q + ps)^n$, donc $G'(s) = n(q + ps)^{n-1} \cdot p$ et $G''(s) = n(n-1)(q + ps)^{n-2} \cdot p^2$. En $s = 1$, $q + p = 1$: $\mathbb{E}[X] = np$, $G''(1) = n(n-1)p^2$, et $\text{Var } X = n(n-1)p^2 + np - n^2p^2 = np - np^2 = npq$.

Plus besoin de manipuler des séries : il suffit de dériver une fonction simple.

Exercice 2.

1. Par le théorème sur les sommes indépendantes, la fonction génératrice de $X + Y$ est $(q + ps)^n(q + ps)^m = (q + ps)^{n+m}$, celle de $\text{Bi}(n + m, p)$. La fonction génératrice caractérisant la loi, $X + Y \sim \text{Bi}(n + m, p)$. Interprétation : n épreuves puis m épreuves indépendantes de même probabilité de succès font $n + m$ épreuves.
2. De même, $e^{\mu_1(s-1)}e^{\mu_2(s-1)} = e^{(\mu_1+\mu_2)(s-1)}$, fonction génératrice de $\text{Po}(\mu_1 + \mu_2)$.
3. La fonction génératrice de la somme de k géométriques indépendantes est $(\frac{ps}{1-qs})^k = (ps)^k(1-qs)^{-k}$. Pour $|s| < 1$, $|qs| < 1$ et la série admise avec $u = qs$ donne $(1-qs)^{-k} = \sum_{j \geq 0} \binom{k+j-1}{j} q^j s^j$. En multipliant par $p^k s^k$:

$$(ps)^k(1-qs)^{-k} = \sum_{j \geq 0} \binom{k+j-1}{j} p^k q^j s^{k+j}.$$

Le coefficient de s^x provient du seul terme $j = x - k$ (il faut $x \geq k$) : il vaut $\binom{x-1}{x-k} p^k q^{x-k}$. Par la symétrie $\binom{a}{b} = \binom{a}{a-b}$, $\binom{x-1}{x-k} = \binom{x-1}{k-1}$. On retrouve $\binom{x-1}{k-1} p^k q^{x-k}$, la loi de Pascal ; comme $p(x)$ est le coefficient de s^x (théorème de caractérisation), la somme suit $\text{Pa}(k, p)$.

4. $(q + ps)^n(q' + p's)^m$ est un polynôme de degré $n + m$, qui s'annule en $s = -q/p$ (avec l'ordre n) et en $s = -q'/p'$ (avec l'ordre m) ; ces deux racines sont distinctes si $p \neq p'$. Une binomiale de même loi que $X + Y$ aurait le même support $\{0, \dots, n + m\}$, donc $n + m$ épreuves et $0 < r < 1$; sa fonction génératrice $(1 - r + rs)^{n+m}$ n'aurait qu'une racine, $-(1-r)/r$, d'ordre $n + m$. Donc $X + Y$ n'est pas binomiale : l'additivité exige des épreuves de même probabilité de succès.

Exercice 3.

1. Voir le cours (approximation de Poisson).
2. $\mu = np = 1000 \times 0,002 = 2$. Valeurs exactes : $\mathbb{P}(X = 0) = q^{1000} = 0,998^{1000}$ et $\mathbb{P}(X \leq 2) = \sum_{x=0}^2 \binom{1000}{x} 0,002^x 0,998^{1000-x}$. Approximations : $\mathbb{P}(X = 0) \approx e^{-2}$ et $\mathbb{P}(X \leq 2) \approx e^{-2}(1 + 2 + \frac{2^2}{2}) = 5e^{-2}$.

	Valeur exacte	Approximation de Poisson
$\mathbb{P}(X = 0)$	0,13506	0,13534
$\mathbb{P}(X \leq 2)$	0,676677	0,676676

L'approximation est excellente : n grand, p très petit, np de l'ordre de l'unité.

Exercice 4.

1. *Par les probabilités totales.* On découpe $\{M = m\}$ selon la valeur de N (qui vaut au moins m). Sachant $N = n$, $M \sim \text{Bi}(n; 0,05)$. Avec $\lambda = 40$, $p = 0,05$, $q = 0,95$ et $n = m + j$:

$$\mathbb{P}(M = m) = \sum_{j \geq 0} e^{-\lambda} \frac{\lambda^{m+j}}{(m+j)!} \cdot \frac{(m+j)!}{m! j!} p^m q^j = e^{-\lambda} \frac{(\lambda p)^m}{m!} \sum_{j \geq 0} \frac{(\lambda q)^j}{j!} = e^{-\lambda} \frac{(\lambda p)^m}{m!} e^{\lambda q} = e^{-\lambda p} \frac{(\lambda p)^m}{m!},$$

car $-\lambda + \lambda q = -\lambda p$. Donc $M \sim \text{Po}(\lambda p) = \text{Po}(2)$, comme l'annonce le théorème d'amincissement.

2. $\mathbb{P}(M = 0) = e^{-2} \approx 0,135$. $\mathbb{P}(M \geq 3) = 1 - [\mathbb{P}(M = 0) + \mathbb{P}(M = 1) + \mathbb{P}(M = 2)] = 1 - e^{-2}(1 + 2 + \frac{2^2}{2}) = 1 - 5e^{-2} \approx 0,323$.
3. Par le théorème, M et $N - M$ sont indépendantes. Donc $\mathbb{P}(M = 0 \mid N - M = 50) = \frac{\mathbb{P}(M = 0) \mathbb{P}(N - M = 50)}{\mathbb{P}(N - M = 50)} = \mathbb{P}(M = 0) \approx 0,135$: sachant $N - M = 50$, M suit toujours $\text{Po}(2)$.
Ce résultat est contre-intuitif. En pratique, une corrélation observée entre petits et grands feux signale que l'intensité λ varie d'une saison à l'autre (sécheresse) : il faut alors enrichir le modèle, par exemple par un mélange de lois de Poisson.
4. Si $N = 40$ est fixé, $M \sim \text{Bi}(40; 0,05)$ et $N - M = 40 - M$: connaître l'une des deux variables détermine l'autre, elles sont totalement dépendantes. L'indépendance de la question 3 est propre à la loi de Poisson.
5. M est une somme aléatoire avec $N \sim \text{Po}(40)$ et $Y \sim \text{Be}(0,05)$, de fonction génératrice $0,95 + 0,05s$. Donc $G_M(s) = G_N(0,95 + 0,05s) = e^{40(0,95+0,05s-1)} = e^{40 \times 0,05(s-1)} = e^{2(s-1)}$, fonction génératrice de $\text{Po}(2)$.

Exercice 5.

1. Pour une loi exponentielle de moyenne 5 (paramètre $\lambda = 1/5$), $\mathbb{E}[Y] = 5$, $\text{Var } Y = 1/\lambda^2 = 25$ et $\mathbb{E}[Y^2] = \text{Var } Y + \mathbb{E}[Y]^2 = 50$. Pour $N \sim \text{Po}(20)$, $\mathbb{E}[N] = \text{Var } N = 20$. Par Wald : $\mathbb{E}[S] = 20 \times 5 = 100$ k et $\text{Var } S = 20 \times 25 + 20 \times 5^2 = 1000$ (k)², soit $\sigma_S = \sqrt{1000} \approx 31,6$ k.
2. Sévérité : $\mathbb{E}[N] \text{Var } Y = 500$. Fréquence : $\text{Var } N \mathbb{E}[Y]^2 = 500$. Chacun pour moitié.
3. $\text{Var } N = 0$: il ne reste que la sévérité, $\text{Var } S = 500$, $\sigma_S \approx 22,4$ k.
4. Fréquence : $40 \times 25 = 1000$; $\text{Var } S = 500 + 1000 = 1500$, $\sigma_S \approx 38,7$ k.
5. Cas 1 : $100 + 0,5 \times 31,6 \approx 115,8$ k. Cas 4 : $100 + 0,5 \times 38,7 \approx 119,4$ k. La surdispersion du nombre de sinistres coûte environ 3,6 k de chargement, à charge moyenne identique.

Exercice 6.

1. On applique le théorème de changement de variable avec $I = \mathbb{R}$, $g(x) = e^x$ (de classe C^1 , $g' = e^x \neq 0$), $g(I) =]0, +\infty[$, $g^{-1}(y) = \ln y$ et $(g^{-1})'(y) = 1/y > 0$. Pour $y > 0$:

$$f_Y(y) = f_X(\ln y) \cdot \frac{1}{y} = \frac{1}{y \sigma \sqrt{2\pi}} \exp\left(-\frac{(\ln y - \mu)^2}{2\sigma^2}\right),$$

et $f_Y(y) = 0$ pour $y \leq 0$.

2. Par le transfert, $\mathbb{E}[e^X] = \int e^x \frac{1}{\sigma \sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)} dx = \int \frac{1}{\sigma \sqrt{2\pi}} \exp\left(x - \frac{(x-\mu)^2}{2\sigma^2}\right) dx$. On complète le carré dans l'exposant :

$$x - \frac{(x-\mu)^2}{2\sigma^2} = -\frac{(x-\mu-\sigma^2)^2}{2\sigma^2} + \mu + \frac{\sigma^2}{2}.$$

Vérification : on développe $(x-\mu-\sigma^2)^2 = (x-\mu)^2 - 2\sigma^2(x-\mu) + \sigma^4$; le membre de droite vaut donc $-\frac{(x-\mu)^2}{2\sigma^2} + (x-\mu) - \frac{\sigma^2}{2} + \mu + \frac{\sigma^2}{2} = -\frac{(x-\mu)^2}{2\sigma^2} + x$. On sort la constante $e^{\mu+\sigma^2/2}$; l'intégrale restante est celle de la densité de $\mathcal{N}(\mu+\sigma^2, \sigma^2)$, qui vaut 1. Donc $\mathbb{E}[Y] = e^{\mu+\sigma^2/2}$.

3. L'exponentielle étant croissante, $\{e^X \leq e^\mu\} = \{X \leq \mu\}$, donc $\mathbb{P}(Y \leq e^\mu) = \mathbb{P}(X \leq \mu) = \frac{1}{2}$ (la loi normale est symétrique autour de μ) : la médiane de Y est e^μ . Si $\sigma > 0$, $\sigma^2/2 > 0$, donc $e^{\mu+\sigma^2/2} > e^\mu$: la médiane est strictement inférieure à la moyenne. Pour $\mu = 0$, $\sigma = 1$: médiane 1, moyenne $e^{0,5} \approx 1,65$. La loi est asymétrique à droite.
4. $z \mapsto z^2$ n'est pas monotone : on utilise la méthode générale. Pour $y \leq 0$, $F(y) = \mathbb{P}(Z^2 \leq y) = 0$. Pour $y > 0$, $Z^2 \leq y \iff -\sqrt{y} \leq Z \leq \sqrt{y}$, donc $F(y) = \Phi(\sqrt{y}) - \Phi(-\sqrt{y}) = 2\Phi(\sqrt{y}) - 1$, en utilisant la symétrie $\Phi(-z) = 1 - \Phi(z)$. F est continue et de classe C^1 sur $]0, +\infty[$; on dérive avec $\Phi' = \varphi$ et $(\sqrt{y})' = \frac{1}{2\sqrt{y}}$:

$$f(y) = 2\varphi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{\varphi(\sqrt{y})}{\sqrt{y}} = \frac{e^{-y/2}}{\sqrt{2\pi y}}.$$

5. On applique le théorème avec $I =]-\pi/2, \pi/2[$ (on a bien $\mathbb{P}(\Theta \in I) = 1$), $g = \tan$ (de classe C^1 , $g' = 1 + \tan^2 > 0$), $g(I) = \mathbb{R}$, $g^{-1} = \arctan$ et $(g^{-1})'(x) = \frac{1}{1+x^2}$. La densité de Θ vaut $\frac{1}{\pi}$ sur I . Donc $f_X(x) = \frac{1}{\pi} \cdot \frac{1}{1+x^2}$ pour tout réel x . C'est la loi de Cauchy (séance 3).

Exercice 7.

1. Pour $\text{Exp}(\lambda)$, $I =]0, +\infty[$ et $F(x) = 1 - e^{-\lambda x}$. On résout $F(x) = u$: $e^{-\lambda x} = 1 - u$, donc $-\lambda x = \ln(1 - u)$, soit $x = F^{-1}(u) = -\ln(1 - u)/\lambda$. Par le théorème d'inversion, $X = -\ln(1 - U)/\lambda$ suit $\text{Exp}(\lambda)$. Comme $1 - U$ est aussi uniforme ($\mathbb{P}(1 - U \leq u) = \mathbb{P}(U \geq 1 - u) = u$), on peut simuler $X = -\ln(U)/\lambda$.
2. Ici $I =]x_m, +\infty[$. On résout $1 - (x_m/x)^\alpha = u$: $(x_m/x)^\alpha = 1 - u$, donc $x_m/x = (1 - u)^{1/\alpha}$, soit $x = x_m(1 - u)^{-1/\alpha}$. Avec la même remarque, on simule $X = x_m U^{-1/\alpha}$.
3. Pour $U \in]0, 1[$, $\ln U < 0$ et $\ln q < 0$, donc $\ln U / \ln q > 0$ et X est un entier au moins égal à 1. Pour tout entier $x \geq 0$, $\lceil y \rceil > x \iff y > x$; donc

$$X > x \iff \frac{\ln U}{\ln q} > x \iff \ln U < x \ln q \iff U < q^x,$$

l'inégalité se renversant lorsqu'on multiplie par $\ln q < 0$, et la dernière équivalence venant de la croissance de l'exponentielle. Donc $\mathbb{P}(X > x) = \mathbb{P}(U < q^x) = q^x$. On en déduit $\mathbb{P}(X = x) = \mathbb{P}(X > x - 1) - \mathbb{P}(X > x) = q^{x-1} - q^x = q^{x-1}(1 - q)$ pour $x \geq 1$: c'est la loi $\text{Ge}(p)$ avec $p = 1 - q$.

4. Script possible :

```

import numpy as np
rng = np.random.default_rng(1)
U = 1 - rng.random(200_000)          # U dans ]0,1] : evite log(0)

X = -np.log(U) / 0.5                  # Exp(lambda = 0.5)
print(X.mean(), X.var())              # attendu : 2 et 4

q = 0.8
G = np.ceil(np.log(U) / np.log(q))    # Ge(p = 0.2)
G = np.maximum(G, 1)                  # cas U = 1 (probabilite nulle)
print(G.mean(), G.var())              # attendu : 1/p = 5 et q/p^2 = 20

```

Exercice 8.

1. D'après le théorème du mélange Poisson-Gamma, N suit la loi binomiale négative $\text{BN}(\alpha, p)$ avec $p = \beta/(1 + \beta)$; son espérance vaut α/β et sa variance $\alpha/\beta + \alpha/\beta^2$.
2. On résout $\alpha/\beta = 20$ et $\alpha/\beta + \alpha/\beta^2 = 40$. La seconde équation donne $\alpha/\beta^2 = 20$; en divisant la première par celle-ci, $\beta = 1$, puis $\alpha = 20$. Donc $p = 1/2$ et $N \sim \text{BN}(20; 1/2)$. C'est précisément la loi « binomiale négative de moyenne 20 et de variance 40 » utilisée sans justification à la question 4 de l'exercice 5 : elle modélise un nombre de sinistres dont l'intensité annuelle varie, avec $\text{Var } \Lambda = \alpha/\beta^2 = 20$.
3. $\mathbb{P}(N = 0) = p^\alpha = 2^{-20} \approx 9,5 \times 10^{-7}$, contre $e^{-20} \approx 2,1 \times 10^{-9}$ pour $\text{Po}(20)$, soit environ 460 fois plus. Dans la queue, $\mathbb{P}(N \geq 35)$ est environ 13 fois plus grande que sous le modèle de Poisson. À espérance égale, le mélange rend beaucoup plus probables les années extrêmes, dans les deux sens. Un modèle de Poisson ajusté sur la seule moyenne sous-estimerait gravement le risque d'une année catastrophique : il faut toujours comparer la moyenne et la variance empiriques des données avant de le retenir.
4. Par la proposition sur l'amincissement d'un mélange, $\text{Cov}(M, N - M) = pq \text{Var } \Lambda = 0,05 \times 0,95 \times 100 = 4,75$. Sachant $\Lambda = \lambda$, M suit $\text{Po}(\lambda p)$: M est donc une loi de Poisson mélangée par $p\Lambda$, et le théorème de surdispersion donne $\text{Var } M = p \mathbb{E}[\Lambda] + p^2 \text{Var } \Lambda = 2 + 0,25 = 2,25$; de même, $\text{Var}(N - M) = q \mathbb{E}[\Lambda] + q^2 \text{Var } \Lambda = 38 + 90,25 = 128,25$. Donc

$$\rho(M, N - M) = \frac{4,75}{\sqrt{2,25 \times 128,25}} \approx 0,28.$$

Une saison où les départs de feu sont nombreux est aussi, en moyenne, une saison à grands feux, parce que les deux reflètent la même intensité (sécheresse). L'indépendance de l'exercice 4 n'était valable qu'à intensité connue.

3 Séance 3 — Inégalités et lois limites

Objectifs. Borner une probabilité en ne connaissant que quelques moments. Démontrer la loi des grands nombres et en tirer le dimensionnement d'une simulation. Comprendre ce que dit le théorème central limite et ce qu'il ne dit pas. Accompagner tout résultat de simulation d'un intervalle de confiance. Introduire la loi du maximum et les périodes de retour.

3.1 Cours

3.1.1 Inégalités de Markov et de Chebyshev

Théorème 3.1 (Markov). *Si $X \geq 0$ et $a > 0$, alors $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$.*

Démonstration. Idée. On compare X à une variable plus simple, qui vaut a quand $X \geq a$ et 0 sinon.

Étape 1 (une inégalité entre variables). Montrons que $a \mathbf{1}_{\{X \geq a\}} \leq X$ pour toute issue. Si $X \geq a$, l'indicatrice vaut 1 et l'inégalité s'écrit $a \leq X$: c'est vrai. Sinon, l'indicatrice vaut 0 et l'inégalité s'écrit $0 \leq X$: c'est vrai car $X \geq 0$.

Étape 2 (croissance). Par croissance de l'espérance, $\mathbb{E}[a \mathbf{1}_{\{X \geq a\}}] \leq \mathbb{E}[X]$.

Étape 3 (calcul). Par linéarité et par la propriété des indicatrices, $\mathbb{E}[a \mathbf{1}_{\{X \geq a\}}] = a \mathbb{E}[\mathbf{1}_{\{X \geq a\}}] = a \mathbb{P}(X \geq a)$. Donc $a \mathbb{P}(X \geq a) \leq \mathbb{E}[X]$, et l'on divise par $a > 0$.

La démonstration n'utilise que la croissance de l'espérance (démontrée dans le cas discret, admise en général). $\square$

Théorème 3.2 (Chebyshev). *Pour toute variable de variance finie et tout $a > 0$, $\mathbb{P}(|X - \mu| \geq a) \leq \text{Var } X / a^2$. Si $\sigma > 0$, avec $a = k\sigma$: $\mathbb{P}(|X - \mu| \geq k\sigma) \leq 1/k^2$.*

Démonstration. Étape 1 (deux événements identiques). $|X - \mu|$ et a sont positifs, et la fonction carré est croissante sur $[0, +\infty[$; donc $|X - \mu| \geq a \iff (X - \mu)^2 \geq a^2$. Les événements $\{|X - \mu| \geq a\}$ et $\{(X - \mu)^2 \geq a^2\}$ sont identiques.

Étape 2 (Markov). On applique l'inégalité de Markov à la variable positive $Z = (X - \mu)^2$, avec le seuil $a^2 > 0$: $\mathbb{P}(Z \geq a^2) \leq \mathbb{E}[Z]/a^2 = \text{Var } X / a^2$, puisque $\mathbb{E}[(X - \mu)^2] = \text{Var } X$ par définition.

Étape 3 (cas $a = k\sigma$). $\text{Var } X / (k\sigma)^2 = \sigma^2 / (k^2 \sigma^2) = 1/k^2$. $\square$

Proposition 3.3 (La borne ne peut pas être améliorée). *Soient $\mu \in \mathbb{R}$, $\sigma > 0$, $k \geq 1$ et X valant $\mu - k\sigma$ et $\mu + k\sigma$ avec probabilité $1/(2k^2)$ chacune, et μ avec probabilité $1 - 1/k^2$. Alors $\mathbb{E}[X] = \mu$, $\text{Var } X = \sigma^2$ et $\mathbb{P}(|X - \mu| \geq k\sigma) = 1/k^2$.*

Démonstration. Étape 1 (c'est bien une loi). Les probabilités sont positives car $k \geq 1$ entraîne $1 - 1/k^2 \geq 0$, et leur somme vaut $\frac{1}{2k^2} + \frac{1}{2k^2} + 1 - \frac{1}{k^2} = 1$.

Étape 2 (espérance). $\mathbb{E}[X] = \frac{\mu - k\sigma}{2k^2} + \frac{\mu + k\sigma}{2k^2} + \mu(1 - \frac{1}{k^2}) = \frac{\mu}{k^2} + \mu - \frac{\mu}{k^2} = \mu$.

Étape 3 (variance). $(X - \mu)^2$ vaut $k^2 \sigma^2$ lorsque $X = \mu \pm k\sigma$ (probabilité totale $1/k^2$), et 0 sinon. Donc $\text{Var } X = k^2 \sigma^2 \times \frac{1}{k^2} = \sigma^2$.

Étape 4 (probabilité). $|X - \mu| \geq k\sigma$ exactement lorsque $X = \mu \pm k\sigma$, ce qui a pour probabilité $\frac{1}{2k^2} + \frac{1}{2k^2} = \frac{1}{k^2}$. $\square$

Si l'on ne connaît que l'espérance et la variance, on ne peut donc pas faire mieux.

3.1.2 Borne de Chernoff

Théorème 3.4 (Chernoff). *Pour tout $t > 0$, $\mathbb{P}(X \geq a) \leq e^{-ta} \mathbb{E}[e^{tX}]$.*

Démonstration. Étape 1 (deux événements identiques). Pour $t > 0$, la fonction $x \mapsto e^{tx}$ est strictement croissante; donc $X \geq a \iff e^{tX} \geq e^{ta}$.

Étape 2 (Markov). La variable $Z = e^{tX}$ est positive, et $e^{ta} > 0$. Par Markov, $\mathbb{P}(Z \geq e^{ta}) \leq \mathbb{E}[Z]/e^{ta} = e^{-ta} \mathbb{E}[e^{tX}]$. (Si $\mathbb{E}[e^{tX}] = +\infty$, l'inégalité est vraie mais sans intérêt.) $\square$

On choisit ensuite le t qui minimise le majorant. Lorsque $\mathbb{E}[e^{tX}]$ est finie pour un $t > 0$, la borne décroît exponentiellement en a , alors que Chebyshev ne décroît qu'en $1/a^2$: pour les événements rares, la différence est considérable.

3.1.3 Loi faible des grands nombres

Théorème 3.5 (Loi faible des grands nombres). *Soit $(X_n)_{n \geq 1}$ une suite de variables indépendantes, de même loi, d'espérance μ et de variance σ^2 finie, et $\bar{X}_n = (X_1 + \dots + X_n)/n$. Pour tout $\varepsilon > 0$,*

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Démonstration. Étape 1 (espérance de la moyenne). Par linéarité, $\mathbb{E}[\bar{X}_n] = \frac{1}{n}(\mathbb{E}[X_1] + \dots + \mathbb{E}[X_n]) = \frac{1}{n} \cdot n\mu = \mu$.

Étape 2 (variance de la moyenne). Par la formule $\text{Var}(aX) = a^2 \text{Var} X$ avec $a = 1/n$, $\text{Var} \bar{X}_n = \frac{1}{n^2} \text{Var}(X_1 + \dots + X_n)$. Les X_i étant indépendantes, leurs covariances sont nulles et la variance de la somme est la somme des variances : $\text{Var} \bar{X}_n = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$.

Étape 3 (Chebyshev). On applique Chebyshev à $\bar{X}_n$, d'espérance μ et de variance σ^2/n , avec $a = \varepsilon$: $\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2/n}{\varepsilon^2}$.

Étape 4 (limite). À ε fixé, $\sigma^2/(n\varepsilon^2) \rightarrow 0$. Une probabilité étant positive et majorée par une quantité qui tend vers 0, elle tend vers 0.

La démonstration n'utilise que la non-corrélation deux à deux. $\square$

Corollaire 3.6 (Fréquences). *Soit $f_n(A)$ la fréquence de A sur n répétitions indépendantes. Pour tout $\varepsilon > 0$,*

$$\mathbb{P}(|f_n(A) - \mathbb{P}(A)| \geq \varepsilon) \leq \frac{\mathbb{P}(A)(1 - \mathbb{P}(A))}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}.$$

Démonstration. Étape 1. Soit X_i l'indicatrice « A est réalisé à la i -ème répétition ». Les X_i sont indépendantes, de loi $\text{Be}(\mathbb{P}(A))$, donc d'espérance $\mathbb{P}(A)$ et de variance $\mathbb{P}(A)(1 - \mathbb{P}(A))$.

Étape 2. $X_1 + \dots + X_n$ compte le nombre de fois où A est réalisé; donc $\bar{X}_n = f_n(A)$. Le théorème donne la première inégalité.

Étape 3. Pour tout $p \in [0, 1]$, $p(1 - p) \leq \frac{1}{4}$, car $\frac{1}{4} - p(1 - p) = p^2 - p + \frac{1}{4} = (p - \frac{1}{2})^2 \geq 0$. $\square$

Remarque. La définition « en fréquence » de la probabilité, présentée au début du cours comme une définition intuitive, reçoit ici une justification **à partir des axiomes** : la fréquence converge vers la probabilité *en probabilité*. L'énoncé « $f_n(A) \rightarrow \mathbb{P}(A)$ » pour presque toute suite d'expériences est plus fort : c'est la loi forte des grands nombres (admise).

3.1.4 Fonction génératrice des moments

Définition 3.7. On dit que X admet une *fonction génératrice des moments* si $\mathbb{E}[e^{tX}]$ est finie pour tout t d'un intervalle **ouvert** J contenant 0; on pose alors $M_X(t) = \mathbb{E}[e^{tX}]$ pour $t \in J$. (L'ouverture de J est nécessaire aux propriétés (a) et (d) ci-dessous.)

Propriétés.

- (a) $M_X(0) = \mathbb{E}[e^0] = 1$, $M'_X(0) = \mathbb{E}[X]$, $M''_X(0) = \mathbb{E}[X^2]$. Intuitivement, on dérive sous l'espérance : $\frac{d}{dt}e^{tX} = Xe^{tX}$, donc $M'_X(t) = \mathbb{E}[Xe^{tX}]$, qui vaut $\mathbb{E}[X]$ en $t = 0$; de même $M''_X(t) = \mathbb{E}[X^2e^{tX}]$. La légitimité de cette dérivation est admise.
- (b) Si $X_1, \dots, X_n$ sont indépendantes, la fonction génératrice des moments de leur somme est le produit des M_{X_i} : même preuve que pour G , avec $e^{t(X_1+\dots+X_n)} = e^{tX_1} \dots e^{tX_n}$ et le théorème du produit.
- (c) $M_{aX+b}(t) = e^{bt}M_X(at)$: en effet $e^{t(aX+b)} = e^{bt}e^{(at)X}$, et e^{bt} est une constante qui sort de l'espérance.
- (d) M_X caractérise la loi (admis).

Proposition 3.8. Si $Z \sim \mathcal{N}(0, 1)$, $M_Z(t) = e^{t^2/2}$; si $X \sim \mathcal{N}(\mu, \sigma^2)$, $M_X(t) = e^{\mu t + \sigma^2 t^2/2}$.

Démonstration. Étape 1 (transfert). $M_Z(t) = \int e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = \frac{1}{\sqrt{2\pi}} \int e^{tz - z^2/2} dz$.

Étape 2 (compléter le carré). On développe $-(z - t)^2/2 = -z^2/2 + tz - t^2/2$; donc $tz - z^2/2 = -(z - t)^2/2 + t^2/2$.

Étape 3 (on sort la constante). $M_Z(t) = e^{t^2/2} \int \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz$. La fonction intégrée est la densité de $\mathcal{N}(t, 1)$; son intégrale vaut 1 (par le changement de variable $u = z - t$, on se ramène à $\int \varphi = 1$, l'intégrale de Gauss, admise). Donc $M_Z(t) = e^{t^2/2}$.

Étape 4 (cas général). $X = \mu + \sigma Z$; par (c) avec $a = \sigma$, $b = \mu$: $M_X(t) = e^{\mu t} M_Z(\sigma t) = e^{\mu t} e^{\sigma^2 t^2/2}$. $\square$

3.1.5 Théorème central limite

Théorème 3.9 (TCL). Soit $(X_n)_{n \geq 1}$ une suite de variables indépendantes, de même loi, d'espérance μ et de variance σ^2 finie et non nulle, et $S_n = X_1 + \dots + X_n$. Pour tout z ,

$$\mathbb{P}\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq z\right) \xrightarrow{n \rightarrow \infty} \Phi(z).$$

Esquisse de démonstration. On suppose que M_X existe au voisinage de 0.

Étape 1 (on centre et on réduit). On pose $Y_i = (X_i - \mu)/\sigma$: par linéarité et par $\text{Var}(aX + b) = a^2 \text{Var} X$, $\mathbb{E}[Y_i] = 0$ et $\text{Var} Y_i = 1$, donc $\mathbb{E}[Y_i^2] = 1$ (Koenig). Comme $S_n - n\mu = \sum_i (X_i - \mu) = \sigma \sum_i Y_i$, la variable étudiée est $S_n^* = \frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{Y_1 + \dots + Y_n}{\sqrt{n}}$.

Étape 2 (fonction génératrice des moments). Par (b), $Y_1 + \dots + Y_n$ a pour fonction génératrice des moments $M_Y(t)^n$ (les Y_i ont même loi). Par (c) avec $a = 1/\sqrt{n}$ et $b = 0$: $M_{S_n^*}(t) = M_Y(t/\sqrt{n})^n$.

Étape 3 (développement limité). Par la formule de Taylor à l'ordre 2 en 0 et par (a), $M_Y(u) = M_Y(0) + M'_Y(0)u + \frac{M''_Y(0)}{2}u^2 + o(u^2) = 1 + 0 + \frac{u^2}{2} + o(u^2)$.

Étape 4 (limite). Avec $u = t/\sqrt{n}$ (donc $u^2 = t^2/n$) : $M_Y(t/\sqrt{n}) = 1 + u_n$, où $u_n = \frac{t^2}{2n} + o(\frac{1}{n})$, de sorte que $n u_n \rightarrow t^2/2$. Par la limite fondamentale (séance 2), $M_{S_n^*}(t) = (1 + u_n)^n \rightarrow e^{t^2/2}$.

Étape 5 (conclusion). $e^{t^2/2}$ est la fonction génératrice des moments de $\mathcal{N}(0, 1)$. On admet un théorème de continuité (dû à Curtiss, analogue pour les fonctions génératrices des moments du théorème de Lévy) : la convergence des fonctions génératrices des moments au voisinage de 0 entraîne celle des fonctions de répartition. La démonstration complète, sans supposer l'existence de M_X , utilise la fonction caractéristique $\mathbb{E}[e^{itX}]$, qui existe pour toute loi. $\square$

Remarque. L'hypothèse de variance finie est indispensable. Pour la loi de Cauchy, qui n'a même pas d'espérance, la moyenne S_n/n suit encore une loi de Cauchy (admis) : aucune normalisation ne fait apparaître la loi normale (exercice 4 du TD).

3.1.6 Intervalle de confiance d'un résultat Monte-Carlo

Un résultat obtenu par simulation est aléatoire : il doit toujours être accompagné d'une mesure de sa précision. Le TCL la fournit, à condition de pouvoir remplacer l'écart-type inconnu σ par une estimation.

Définition 3.10 (Convergence en probabilité). Une suite (V_n) converge en probabilité vers une constante c si, pour tout $\varepsilon > 0$, $\mathbb{P}(|V_n - c| \geq \varepsilon) \rightarrow 0$.

La loi faible des grands nombres dit exactement que $\bar{X}_n$ converge en probabilité vers μ .

Théorème 3.11 (Slutsky, admis). Si U_n converge en loi vers U et si V_n converge en probabilité vers une constante c , alors $U_n + V_n$ converge en loi vers $U + c$ et $U_n V_n$ converge en loi vers cU . De plus, si V_n converge en probabilité vers c et si ϕ est continue en c , alors $\phi(V_n)$ converge en probabilité vers $\phi(c)$.

Proposition 3.12 (Estimation de la variance). Soit (X_n) une suite de variables indépendantes de même loi, avec $\mathbb{E}[X_1^4] < \infty$ et $\text{Var } X_1 = \sigma^2$, et $s_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$. Alors s_n^2 converge en probabilité vers σ^2 .

Démonstration. Étape 1 (réécriture). En développant le carré, $s_n^2 = \frac{1}{n} \sum_i X_i^2 - \bar{X}_n^2$.

Étape 2 (deux lois des grands nombres). Les variables X_i^2 sont indépendantes, de même loi, de variance finie car $\mathbb{E}[X_1^4] < \infty$: par la loi faible des grands nombres, $\frac{1}{n} \sum_i X_i^2$ converge en probabilité vers $\mathbb{E}[X_1^2]$. De même, $\bar{X}_n$ converge en probabilité vers μ .

Étape 3 (conclusion). Par le théorème de Slutsky (fonction continue $x \mapsto x^2$), $\bar{X}_n^2$ converge en probabilité vers μ^2 . Si $A_n \rightarrow a$ et $B_n \rightarrow b$ en probabilité, alors $A_n - B_n \rightarrow a - b$ en probabilité, car $\{|A_n - B_n - (a - b)| \geq \varepsilon\} \subset \{|A_n - a| \geq \varepsilon/2\} \cup \{|B_n - b| \geq \varepsilon/2\}$ et l'on majore par la somme des deux probabilités (inégalité de Boole). Donc $s_n^2 \rightarrow \mathbb{E}[X_1^2] - \mu^2 = \sigma^2$ en probabilité. $\square$

(Le résultat reste vrai sous la seule hypothèse $\mathbb{E}[X_1^2] < \infty$, grâce à la loi forte des grands nombres ; admis.)

Théorème 3.13 (Intervalle de confiance asymptotique). Sous les hypothèses précédentes, avec $\sigma > 0$, et pour $0 < \beta < 1$, notons $z = \Phi^{-1}(1 - \beta/2)$ (par exemple $z = 1,96$ pour $\beta = 0,05$). Alors

$$\mathbb{P}\left(\mu \in \left[\bar{X}_n - z \frac{s_n}{\sqrt{n}}; \bar{X}_n + z \frac{s_n}{\sqrt{n}}\right]\right) \xrightarrow{n \rightarrow \infty} 1 - \beta.$$

Démonstration. Étape 1 (on remplace σ par s_n). On écrit $T_n = \sqrt{n} \frac{\bar{X}_n - \mu}{s_n} = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \cdot \frac{\sigma}{s_n}$ (sur l'événement $s_n > 0$, dont la probabilité tend vers 1). Le premier facteur converge en loi vers $\mathcal{N}(0, 1)$ (TCL) ; le second converge en probabilité vers 1 (proposition précédente et Slutsky avec $\phi(x) = \sigma/\sqrt{x}$, continue en $\sigma^2 > 0$). Par Slutsky, T_n converge en loi vers $\mathcal{N}(0, 1)$.

Étape 2 (traduction). L'événement $\{\mu \in [\bar{X}_n \pm z s_n / \sqrt{n}]\}$ est l'événement $\{-z \leq T_n \leq z\}$. Comme Φ est continue, sa probabilité tend vers $\Phi(z) - \Phi(-z) = 2\Phi(z) - 1 = 1 - \beta$. $\square$

Méthode de Monte-Carlo. Pour estimer $\mu = \mathbb{E}[g(X)]$ par simulation, on tire $X_1, \dots, X_n$ indépendantes de même loi que X , et l'on présente le résultat sous la forme

$$\bar{Y}_n \pm 1,96 \frac{s_n}{\sqrt{n}}, \quad Y_i = g(X_i),$$

qui est un intervalle de confiance de niveau asymptotique 95 %. Pour une probabilité ($g = \mathbf{1}_A$), $\bar{Y}_n = f_n$ et $s_n^2 = f_n(1 - f_n)$. La largeur décroît comme $1/\sqrt{n}$: diviser l'erreur par 10 coûte 100 fois plus de simulations.

3.1.7 Approximation normale en pratique

Corollaire 3.14 (De Moivre-Laplace). Si $X_n \sim \text{Bi}(n, p)$ avec $0 < p < 1$ fixé, alors pour tout z , $\mathbb{P}((X_n - np)/\sqrt{npq} \leq z) \rightarrow \Phi(z)$.

Démonstration. X_n a la loi d'une somme de n variables $\text{Be}(p)$ indépendantes, d'espérance $\mu = p$ et de variance $\sigma^2 = pq > 0$. Le TCL s'applique, avec $n\mu = np$ et $\sigma\sqrt{n} = \sqrt{npq}$. $\square$

Règle pratique. On en tire l'approximation $X \approx \mathcal{N}(np, npq)$ pour n grand. Ce n'est pas un théorème à n fixé : la qualité de l'approximation est quantifiée par Berry-Esseen ci-dessous.

Correction de continuité (heuristique). X étant entière, on approche $\mathbb{P}(X \leq k)$ par l'aire sous la densité normale jusqu'à $k + 0,5$, milieu entre k et $k + 1$:

$$\mathbb{P}(X \leq k) \approx \Phi\left(\frac{k + 0,5 - np}{\sqrt{npq}}\right).$$

Théorème 3.15 (Berry-Esseen, admis). L'écart entre la fonction de répartition de $(S_n - n\mu)/(\sigma\sqrt{n})$ et Φ est majoré, uniformément en z , par $\frac{C\rho}{\sigma^3\sqrt{n}}$, avec $\rho = \mathbb{E}|X - \mu|^3$ (supposé fini) et $C \leq 0,48$.

Cas de Bernoulli. Pour $X \sim \text{Be}(p)$, $X - p$ vaut q avec probabilité p et $-p$ avec probabilité q . Donc $\rho = pq^3 + qp^3 = pq(p^2 + q^2)$, et $\sigma^3 = (pq)^{3/2}$. La borne vaut

$$\frac{Cpq(p^2 + q^2)}{(pq)^{3/2}\sqrt{n}} = \frac{C(p^2 + q^2)}{\sqrt{npq}}.$$

Elle est d'autant plus grande que p est proche de 0 ou de 1 (le dénominateur $\sqrt{npq}$ tend alors vers 0). C'est la justification quantitative de la règle « l'approximation est d'autant meilleure que p est proche de 0,5 ».

Remarque (Mise en garde). Berry-Esseen contrôle une erreur **absolue**. Dans les queues de distribution, l'erreur **relative** peut être énorme (exercice 2 du TD). Le TCL décrit correctement le centre de la loi, pas les événements extrêmes.

3.1.8 Loi du maximum et valeurs extrêmes

Proposition 3.16. Si $X_1, \dots, X_n$ sont indépendantes de même fonction de répartition F et $M_n = \max(X_1, \dots, X_n)$, alors $\mathbb{P}(M_n \leq x) = F(x)^n$.

Démonstration. Étape 1 (traduction). Le plus grand des X_i est inférieur ou égal à x si et seulement si tous les X_i le sont : si l'un d'eux dépassait x , le maximum le dépasserait aussi. Donc $\{M_n \leq x\} = \{X_1 \leq x\} \cap \dots \cap \{X_n \leq x\}$.

Étape 2 (indépendance). Par définition de l'indépendance, avec $B_i =]-\infty, x]$, la probabilité de cette intersection est le produit des $\mathbb{P}(X_i \leq x) = F(x)$, soit $F(x)^n$. $\square$

Théorème 3.17 (Loi de Gumbel). Si les X_i suivent $\text{Exp}(1)$, alors pour tout réel x ,

$$\mathbb{P}(M_n - \ln n \leq x) \longrightarrow \Lambda(x) = \exp(-e^{-x}).$$

Démonstration. Étape 1 (fonction de répartition). Pour $\text{Exp}(1)$, $F(y) = 1 - e^{-y}$ si $y \geq 0$.

Étape 2 (calcul exact). Fixons x . Pour n assez grand ($n \geq e^{-x}$), $x + \ln n \geq 0$, et $F(x + \ln n) = 1 - e^{-(x + \ln n)} = 1 - e^{-x}e^{-\ln n} = 1 - \frac{e^{-x}}{n}$. Par la proposition précédente, $\mathbb{P}(M_n - \ln n \leq x) = \mathbb{P}(M_n \leq x + \ln n) = \left(1 - \frac{e^{-x}}{n}\right)^n$.

Étape 3 (limite). Par la limite fondamentale (séance 2) avec $a = -e^{-x}$, cette quantité tend vers $e^{-e^{-x}}$. $\square$

La densité de Gumbel s'obtient en dérivant : $\Lambda'(x) = e^{-x} \exp(-e^{-x})$. Pour des $X_i \sim \text{Exp}(\lambda)$, on écrit $X_i = X'_i/\lambda$ avec $X'_i \sim \text{Exp}(1)$: le théorème appliqué aux X'_i montre que $\lambda M_n - \ln n$ converge en loi vers la loi de Gumbel. Autrement dit, M_n est de l'ordre de $(\ln n)/\lambda$, avec des fluctuations de l'ordre de $1/\lambda$.

Théorème 3.18 (Loi de Fréchet). *Si les X_i suivent la loi de Pareto de survie $x^{-\alpha}$ pour $x \geq 1$, alors pour tout $x > 0$, $\mathbb{P}(M_n \leq n^{1/\alpha}x) \rightarrow \exp(-x^{-\alpha})$.*

Démonstration. Étape 1. Ici $F(y) = 1 - y^{-\alpha}$ pour $y \geq 1$. Pour n assez grand, $n^{1/\alpha}x \geq 1$, et $(n^{1/\alpha}x)^{-\alpha} = n^{-1}x^{-\alpha}$, donc $F(n^{1/\alpha}x) = 1 - \frac{x^{-\alpha}}{n}$.

Étape 2. $\mathbb{P}(M_n \leq n^{1/\alpha}x) = (1 - x^{-\alpha}/n)^n \rightarrow \exp(-x^{-\alpha})$, par la limite fondamentale avec $a = -x^{-\alpha}$. $\square$

Remarque. Le maximum de n exponentielles croît comme $\ln n$; celui de n variables de Pareto comme $n^{1/\alpha}$, beaucoup plus vite : les queues lourdes produisent des records bien plus élevés.

Théorème 3.19 (Fisher-Tippett-Gnedenko, admis). *Si le maximum, convenablement centré et réduit, converge en loi vers une loi non dégénérée, cette loi appartient, à une transformation affine près, à l'une de trois familles : Gumbel (typiquement pour des queues de type exponentiel : normale, exponentielle, log-normale), Fréchet (queues lourdes de type Pareto) ou Weibull inversée (certaines lois bornées à droite).*

Niveau de retour. On suppose que le maximum annuel suit une loi de Gumbel de paramètres a et b : $F(x) = \exp(-e^{-(x-a)/b})$. Le niveau de retour T ans est la valeur x_T dépassée avec probabilité $1/T$ chaque année : $F(x_T) = 1 - 1/T$. On résout pas à pas :

$$e^{-e^{-(x_T-a)/b}} = 1 - \frac{1}{T} \iff e^{-(x_T-a)/b} = -\ln\left(1 - \frac{1}{T}\right) \iff -\frac{x_T-a}{b} = \ln\left(-\ln\left(1 - \frac{1}{T}\right)\right),$$

d'où $x_T = a - b \ln(-\ln(1 - 1/T))$. Pour T grand, $\ln(1+u)/u \rightarrow 1$ quand $u \rightarrow 0$ donne $-\ln(1 - 1/T) = \frac{1}{T}(1 + \varepsilon_T)$ avec $\varepsilon_T \rightarrow 0$, donc $\ln(-\ln(1 - 1/T)) = -\ln T + \ln(1 + \varepsilon_T)$ et

$$x_T = a + b \ln T - b \ln(1 + \varepsilon_T), \quad \text{avec } b \ln(1 + \varepsilon_T) \xrightarrow{T \rightarrow \infty} 0.$$

Le niveau de retour croît donc comme $a + b \ln T$, linéairement en $\ln T$.

Temps d'attente. Si les années sont indépendantes, la première année de dépassement est l'année k si les $k-1$ premières années sont sans dépassement et la k -ième en a un : probabilité $(1 - 1/T)^{k-1} \cdot (1/T)$. C'est la loi $\text{Ge}(1/T)$, d'espérance T : c'est le sens exact de « période de retour ». La probabilité d'au moins un dépassement en m années vaut $1 - \mathbb{P}(\text{aucun}) = 1 - (1 - 1/T)^m$.

3.2 TD 3

Exercice 1 — Chebyshev face à la réalité.

1. Calculer $\mathbb{P}(|X - \mu| \geq 2\sigma)$ exactement, où μ et σ désignent l'espérance et l'écart-type de X , pour $X \sim \mathcal{N}(\mu, \sigma^2)$, $X \sim \text{Exp}(1)$ et $X \sim \text{Un}(0, 1)$. Comparer avec la borne de Chebyshev.
2. Même question pour 3σ , avec les lois normale et exponentielle.
3. Construire une loi pour laquelle $\mathbb{P}(|X - \mu| \geq 2\sigma) = 1/4$ exactement.

Exercice 2 — Queues d'une binomiale.

Soit $X \sim \text{Bi}(1000; 0,01)$, le nombre d'incidents sur 1000 opérations indépendantes. On s'intéresse à $\mathbb{P}(X \geq 30)$, dont la valeur exacte est environ $2,1 \times 10^{-7}$.

1. Donner la borne de Chebyshev.
2. a) Montrer que $1 - p + p e^t \leq \exp(p(e^t - 1))$.
b) En déduire que $\mathbb{P}(X \geq a) \leq \exp(\mu(e^t - 1) - ta)$ pour tout $t > 0$, avec $\mu = np$.
c) Optimiser en t et montrer que, pour $a > \mu$, $\mathbb{P}(X \geq a) \leq e^{-\mu}(e\mu/a)^a$.
d) Calculer cette borne pour $a = 30$.
3. Calculer l'approximation normale avec correction de continuité.
4. Comparer les quatre valeurs. Quelle est l'erreur la plus dangereuse en analyse de risque ?

Exercice 3 — Dimensionner une simulation Monte-Carlo.

On estime une probabilité p par la fréquence f_n observée sur n simulations indépendantes.

1. Combien de simulations faut-il pour que $\mathbb{P}(|f_n - p| \geq 0,01) \leq 0,05$, quel que soit p ? Répondre avec Chebyshev, puis avec l'approximation normale.
2. Pour $p = 10^{-4}$, on demande une précision relative de 10 % : $\mathbb{P}(|f_n - p| \geq 0,1 p) \leq 0,05$. Refaire le calcul par les deux méthodes. En déduire une règle pratique.
3. Combien de simulations faudrait-il pour estimer, avec cette précision relative, la probabilité de l'exercice 2 ? Conclure.

Exercice 4 — Quand la loi des grands nombres échoue.

Soit X de loi de Cauchy, de densité $f(x) = \frac{1}{\pi(1+x^2)}$.

1. Vérifier que f est une densité. Montrer que $\mathbb{E}|X| = +\infty$.
2. Simuler par inversion 10 000 tirages de Cauchy et 10 000 tirages de $\mathcal{N}(0, 1)$. Tracer, pour chacun, la moyenne empirique en fonction du nombre de tirages. Faire de même avec la médiane empirique.
3. Commenter. Quelle hypothèse de la loi des grands nombres est violée ?

Exercice 5 — Le TCL pour la loi de Poisson.

1. Calculer la fonction génératrice des moments de $\text{Be}(p)$ et de $\text{Po}(\mu)$.
2. Soit $X \sim \text{Po}(\mu)$. Montrer que la fonction génératrice des moments de $(X - \mu)/\sqrt{\mu}$ tend vers $e^{t^2/2}$ quand $\mu \rightarrow \infty$, pour tout réel t . Quel résultat du cours retrouve-t-on ?
3. Application : pour $X \sim \text{Po}(100)$, approcher $\mathbb{P}(X \leq 90)$, avec et sans correction de continuité (valeur exacte : 0,1714).

Exercice 6 — Qualité de l'approximation normale.

Soit $X \sim \text{Bi}(50; 0,2)$.

1. Approcher $\mathbb{P}(X \leq 5)$ sans puis avec correction de continuité (valeur exacte : 0,0480).
2. Calculer la borne de Berry-Esseen avec $C = 0,4748$ et la comparer aux erreurs commises.
3. Comment évolue cette borne quand $p \rightarrow 0$ à n fixé ? Interpréter.

Exercice 7 — Pluies extrêmes et période de retour.

On modélise la hauteur de pluie journalière par une loi exponentielle de moyenne 10 mm ; les hauteurs des 365 jours de l'année sont supposées indépendantes, et les maxima annuels successifs aussi.

1. Donner la fonction de répartition du maximum annuel M .
2. Montrer que $M - 10 \ln 365$ suit approximativement une loi de Gumbel de paramètre d'échelle 10.
3. Calculer la médiane de M , exactement puis par l'approximation de Gumbel.

4. Calculer le niveau de retour 100 ans à l'aide de l'approximation de Gumbel.
5. Quelle est la probabilité que ce niveau soit dépassé au moins une fois en 30 ans ? en 100 ans ?
6. Critiquer l'hypothèse d'indépendance des jours.

Exercice 8 — Charge sinistre simulée, avec intervalle de confiance.

On reprend la charge sinistre de l'exercice 5 du TD 2 : $S = Y_1 + \dots + Y_N$, avec $N \sim \text{Po}(20)$ et des coûts exponentiels de moyenne 5 k ($\mathbb{E}[S] = 100$, $\sigma_S \approx 31,6$).

1. Montrer que, sachant $N = n \geq 1$, S suit la loi $\Gamma(n, 1/5)$. On calculera la fonction génératrice des moments de $\text{Exp}(\lambda)$ et de $\Gamma(n, \lambda)$, et on admettra qu'elle caractérise la loi.
2. Écrire un script qui simule $n = 10\,000$ réalisations de S , puis estime $\mathbb{E}[S]$ et $p = \mathbb{P}(S > 150)$ avec leurs intervalles de confiance à 95 %.
3. La valeur exacte, obtenue par la formule des probabilités totales et la question 1, est $p \approx 0,0677$. Que donne l'approximation normale de S ? Commenter.
4. Combien de simulations faut-il pour estimer p avec une précision relative de 5 % ?

3.3 Corrigés du TD 3

Exercice 1.

1. *Loi normale.* Avec $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$, $\mathbb{P}(|X - \mu| \geq 2\sigma) = \mathbb{P}(|Z| \geq 2) = \mathbb{P}(Z \geq 2) + \mathbb{P}(Z \leq -2) = 2(1 - \Phi(2)) \approx 0,0455$.
Loi Exp(1). $\mathbb{E}[X] = 1$ et $\text{Var } X = 1$, donc $\mu = \sigma = 1$. $|X - 1| \geq 2$ équivaut à $X \geq 3$ ou $X \leq -1$; le second cas est impossible ($X \geq 0$). Donc $\mathbb{P}(|X - 1| \geq 2) = \mathbb{P}(X \geq 3) = e^{-3} \approx 0,050$.
Loi Un(0, 1). $\mu = \frac{1}{2}$, $\text{Var } X = \frac{1}{12}$, $\sigma = 1/\sqrt{12} \approx 0,289$, donc $2\sigma \approx 0,577$. Or $|X - \frac{1}{2}| \leq \frac{1}{2}$ toujours : la probabilité est nulle.
 La borne de Chebyshev vaut $1/2^2 = 0,25$ dans les trois cas : très pessimiste, car elle ne suppose rien sur la forme de la loi.
2. Loi normale : $2(1 - \Phi(3)) \approx 0,0027$. Exp(1) : $\mathbb{P}(|X - 1| \geq 3) = \mathbb{P}(X \geq 4) = e^{-4} \approx 0,018$. Chebyshev : $1/9 \approx 0,111$. La loi exponentielle a une queue nettement plus lourde que la normale.
3. C'est la loi du cours avec $k = 2$: $\mu - 2\sigma$ et $\mu + 2\sigma$ avec probabilité $1/8$ chacune, et μ avec probabilité $3/4$.

Exercice 2.

1. $\mu = np = 10$ et $\sigma^2 = npq = 1000 \times 0,01 \times 0,99 = 9,9$. Si $X \geq 30$, alors $X - 10 \geq 20$, donc $|X - 10| \geq 20$: l'événement $\{X \geq 30\}$ est inclus dans $\{|X - 10| \geq 20\}$. Par Chebyshev, $\mathbb{P}(X \geq 30) \leq \mathbb{P}(|X - 10| \geq 20) \leq 9,9/20^2 \approx 0,025$.
2. a) Pour tout réel u , $1 + u \leq e^u$: la fonction $f(u) = e^u - 1 - u$ a pour dérivée $e^u - 1$, négative pour $u < 0$ et positive pour $u > 0$; son minimum est $f(0) = 0$. On applique cette inégalité à $u = p(e^t - 1)$: $1 - p + p e^t = 1 + p(e^t - 1) \leq \exp(p(e^t - 1))$.
 b) X a la loi d'une somme de 1000 variables $\text{Be}(p)$ indépendantes, de fonction génératrice des moments $1 - p + p e^t$. Par la propriété (b), $\mathbb{E}[e^{tX}] = (1 - p + p e^t)^{1000}$. Chaque facteur, positif, est majoré grâce à a), donc $\mathbb{E}[e^{tX}] \leq \exp(1000 p(e^t - 1)) = \exp(\mu(e^t - 1))$. On conclut par Chernoff : $\mathbb{P}(X \geq a) \leq e^{-ta} \exp(\mu(e^t - 1)) = \exp(\mu(e^t - 1) - ta)$.
 c) On minimise l'exposant $h(t) = \mu(e^t - 1) - ta$. Sa dérivée $h'(t) = \mu e^t - a$ s'annule pour $e^t = a/\mu$, soit $t = \ln(a/\mu)$, qui est positif car $a > \mu$; et $h''(t) = \mu e^t > 0$, donc c'est un minimum. En ce point :

$$h = \mu \left(\frac{a}{\mu} - 1 \right) - a \ln \frac{a}{\mu} = a - \mu - a \ln \frac{a}{\mu}, \quad \text{d'où} \quad e^h = e^{-\mu} e^a \left(\frac{\mu}{a} \right)^a = e^{-\mu} \left(\frac{e\mu}{a} \right)^a.$$

- d) Pour $a = 30$ et $\mu = 10$: $\exp(30 - 10 - 30 \ln 3) = \exp(20 - 32,96) = \exp(-12,96) \approx 2,4 \times 10^{-6}$.
3. $\mathbb{P}(X \geq 30) = 1 - \mathbb{P}(X \leq 29)$. Avec la correction de continuité, $\mathbb{P}(X \leq 29) \approx \Phi((29,5 - 10)/\sqrt{9,9}) = \Phi(19,5/3,146) = \Phi(6,20)$, donc $\mathbb{P}(X \geq 30) \approx 1 - \Phi(6,20) \approx 2,9 \times 10^{-10}$.
4. Récapitulatif :

Méthode	Résultat	Commentaire
Valeur exacte	$2,1 \times 10^{-7}$	
Chebyshev	$\leq 2,5 \times 10^{-2}$	vraie borne, inutilisable
Chernoff	$\leq 2,4 \times 10^{-6}$	vraie borne, facteur 11
Approximation normale	$\approx 2,9 \times 10^{-10}$	sous-estimation d'un facteur 700

Les deux bornes sont prudentes par construction. L'approximation normale **sous-estime** le risque de plus de deux ordres de grandeur : c'est l'erreur la plus dangereuse, car elle conduit à des décisions non conservatives. Le TCL ne doit pas servir à évaluer des probabilités d'événements rares.

Exercice 3.

1. f_n est la moyenne de n indicatrices indépendantes de loi $\text{Be}(p)$: $\mathbb{E}[f_n] = p$ et $\text{Var } f_n = p(1-p)/n$ (loi faible des grands nombres).

Chebyshev. $\mathbb{P}(|f_n - p| \geq 0,01) \leq \frac{p(1-p)}{n \times 0,01^2} \leq \frac{1}{4n \times 10^{-4}} = \frac{2500}{n}$. Pour que ce soit au plus 0,05, il suffit que $n \geq 2500/0,05 = 50\,000$.

Approximation normale. $f_n \approx \mathcal{N}(p, p(1-p)/n)$, donc $\mathbb{P}(|f_n - p| \geq 0,01) \approx 2(1 - \Phi(0,01/s))$ avec $s = \sqrt{p(1-p)/n}$. Cette quantité vaut au plus 0,05 si $0,01/s \geq 1,96$, soit $n \geq 1,96^2 p(1-p)/10^{-4}$; dans le pire cas $p = 1/2$, $n \geq 1,96^2 \times 0,25 \times 10^4 \approx 9\,604$.

Chebyshev est environ cinq fois plus exigeant, car il ne suppose rien sur la forme de la loi. Mais seule la valeur de Chebyshev est **garantie** : celle de l'approximation normale repose sur le TCL, résultat asymptotique.

2. *Chebyshev.* $\frac{p(1-p)}{n(0,1p)^2} = \frac{1-p}{0,01np} \leq 0,05$ si $n \geq \frac{1-p}{0,0005p} = \frac{2000(1-p)}{p} \approx 2 \times 10^7$.

Approximation normale. $1,96\sqrt{p(1-p)/n} \leq 0,1p$ si $n \geq \frac{1,96^2(1-p)}{0,01p} \approx \frac{384(1-p)}{p} \approx 3,8 \times 10^6$.

Même remarque : seul le résultat de Chebyshev est garanti. Règle pratique : $n \approx 400/p$ simulations pour une précision relative de 10 % à 95 %.

3. Avec $p \approx 2 \times 10^{-7}$: $n \approx 400/(2 \times 10^{-7}) = 2 \times 10^9$. La simulation directe devient impraticable pour les événements rares ; on utilise des méthodes d'accélération (échantillonnage préférentiel, splitting) ou des résultats analytiques comme ceux de l'exercice 2.

Exercice 4.

1. $f \geq 0$, et une primitive de $\frac{1}{1+x^2}$ est $\arctan x$, qui tend vers $\pm \frac{\pi}{2}$ en $\pm \infty$: $\int f = \frac{1}{\pi}(\frac{\pi}{2} + \frac{\pi}{2}) = 1$. La fonction $|x|f(x)$ étant paire, $\mathbb{E}|X| = \frac{2}{\pi} \int_0^\infty \frac{x}{1+x^2} dx$; une primitive de $\frac{x}{1+x^2}$ est $\frac{1}{2} \ln(1+x^2)$, qui tend vers $+\infty$. Donc $\mathbb{E}|X| = +\infty$: X n'a pas d'espérance.
2. Simulation par inversion (TD 2, exercice 6, question 5) : $\Theta = \pi(U - \frac{1}{2})$ suit $\text{Un}(-\pi/2, \pi/2)$, donc $X = \tan(\pi(U - 1/2))$ suit la loi de Cauchy.

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(2)
n = 10_000
C = np.tan(np.pi * (rng.random(n) - 0.5)) # Cauchy
Z = rng.standard_normal(n)                # N(0,1)
```

```

k = np.arange(1, n + 1)
fig, ax = plt.subplots(1, 2, figsize=(10, 3.5))
ax[0].plot(k, np.cumsum(Z) / k, label="N(0,1)")
ax[0].plot(k, np.cumsum(C) / k, label="Cauchy")
ax[0].set_title("Moyenne empirique"); ax[0].legend()
med = [np.median(C[:m]) for m in range(1, n + 1, 50)]
ax[1].plot(range(1, n + 1, 50), med)
ax[1].set_title("Mediane empirique (Cauchy)")
plt.show()

```

3. La moyenne des tirages normaux converge rapidement vers 0. Celle des tirages de Cauchy présente des sauts brutaux, dus à des valeurs isolées énormes, et ne se stabilise jamais. On admet que la moyenne de n variables de Cauchy indépendantes suit encore une loi de Cauchy : moyenner n'apporte aucune information. La médiane empirique, elle, converge vers 0, médiane théorique (admis). L'hypothèse violée est l'existence de l'espérance (et a fortiori de la variance). La symétrie ne suffit pas à donner $\mathbb{E}[X] = 0$, puisque $\mathbb{E}[X]$ n'existe pas (voir la remarque du corrigé de l'exercice 3 du TD 1). Pour des données à queues lourdes, les estimateurs robustes comme la médiane sont préférables à la moyenne.

Exercice 5.

1. $\text{Be}(p) : M(t) = qe^{t \cdot 0} + pe^{t \cdot 1} = q + pe^t$. $\text{Po}(\mu) : \text{par le transfert, } M(t) = \sum_x e^{tx} e^{-\mu} \frac{\mu^x}{x!} = e^{-\mu} \sum_x \frac{(\mu e^t)^x}{x!} = e^{-\mu} e^{\mu e^t} = \exp(\mu(e^t - 1))$ (série exponentielle avec $u = \mu e^t$).
2. $(X - \mu)/\sqrt{\mu} = aX + b$ avec $a = 1/\sqrt{\mu}$ et $b = -\sqrt{\mu}$. Par la propriété (c), $M(t) = e^{bt} M_X(at) = e^{-t\sqrt{\mu}} \exp(\mu(e^{t/\sqrt{\mu}} - 1))$. Le développement $e^v = 1 + v + \frac{v^2}{2} + o(v^2)$ avec $v = t/\sqrt{\mu}$ donne $\mu(e^{t/\sqrt{\mu}} - 1) = \mu\left(\frac{t}{\sqrt{\mu}} + \frac{t^2}{2\mu} + o\left(\frac{1}{\mu}\right)\right) = t\sqrt{\mu} + \frac{t^2}{2} + o(1)$. L'exposant total vaut donc $-t\sqrt{\mu} + t\sqrt{\mu} + \frac{t^2}{2} + o(1) \rightarrow \frac{t^2}{2}$, et $M(t) \rightarrow e^{t^2/2}$; par le théorème de continuité (admis), $(X - \mu)/\sqrt{\mu}$ converge en loi vers $\mathcal{N}(0, 1)$. On retrouve l'affirmation du cours $\text{Po}(\mu) \approx \mathcal{N}(\mu, \mu)$ pour μ grand, cohérente avec le TCL ($\text{Po}(\mu)$ est la somme de μ variables $\text{Po}(1)$ indépendantes quand μ est entier).
3. $\mu = 100$, $\sqrt{\mu} = 10$. Avec correction : $\mathbb{P}(X \leq 90) \approx \Phi((90,5 - 100)/10) = \Phi(-0,95) \approx 0,1711$. Sans correction : $\Phi((90 - 100)/10) = \Phi(-1) \approx 0,1587$. La valeur exacte 0,1714 est très bien approchée avec la correction.

Exercice 6.

1. $np = 10$, $npq = 8$, $\sqrt{8} \approx 2,83$. Sans correction : $\Phi((5 - 10)/2,83) = \Phi(-1,77) \approx 0,0385$, erreur $0,0480 - 0,0385 = 0,0095$. Avec correction : $\Phi((5,5 - 10)/2,83) = \Phi(-1,59) \approx 0,0558$, erreur $0,0558 - 0,0480 = 0,0078$.
2. $p^2 + q^2 = 0,04 + 0,64 = 0,68$. Borne : $0,4748 \times 0,68/2,83 \approx 0,114$, soit 12 à 15 fois les erreurs réelles. La borne est garantie pour toute loi ayant ces moments, donc très conservative : elle sert à comprendre de quoi dépend l'erreur, pas à l'évaluer précisément.
3. Quand $p \rightarrow 0$, $p^2 + q^2 \rightarrow 1$ et $\sqrt{npq} \rightarrow 0$: la borne se comporte comme $1/\sqrt{npq}$ et tend vers l'infini. C'est le nombre moyen de succès np qui doit être grand, pas n seul ; d'où les règles pratiques du type $np \geq 5$ et $nq \geq 5$.

Exercice 7.

1. Pour une loi exponentielle de moyenne 10 (paramètre $1/10$), $F(x) = 1 - e^{-x/10}$ pour $x \geq 0$. Par la loi du maximum, $\mathbb{P}(M \leq x) = (1 - e^{-x/10})^{365}$.
2. On pose $x = 10(\ln 365 + u)$. Alors $e^{-x/10} = e^{-\ln 365} e^{-u} = e^{-u}/365$, et $\mathbb{P}(M \leq 10 \ln 365 + 10u) = (1 - e^{-u}/365)^{365} \approx \exp(-e^{-u})$, par la limite fondamentale (365 est grand). Donc $(M - 10 \ln 365)/10$ suit approximativement la loi de Gumbel : M suit approximativement une loi de Gumbel de paramètres $a = 10 \ln 365 \approx 59,0$ mm et $b = 10$ mm.

3. Médiane exacte : $(1 - e^{-x/10})^{365} = \frac{1}{2}$ équivaut à $1 - e^{-x/10} = 2^{-1/365}$, soit $x = -10 \ln(1 - 2^{-1/365}) \approx 62,67$ mm. Par Gumbel : $\exp(-e^{-u}) = \frac{1}{2}$ équivaut à $e^{-u} = \ln 2$, soit $u = -\ln \ln 2 \approx 0,367$, d'où $59,0 + 10 \times 0,367 \approx 62,66$ mm. L'approximation est excellente.
4. $-\ln 0,99 \approx 0,01005$ et $\ln(0,01005) \approx -4,60$, donc $x_{100} = a - b \ln(-\ln 0,99) \approx 59,0 + 10 \times 4,60 \approx 105$ mm.
5. Les années étant indépendantes, la probabilité d'aucun dépassement en m ans est $0,99^m$. En 30 ans : $1 - 0,99^{30} \approx 0,26$. En 100 ans : $1 - 0,99^{100} \approx 0,63$. Une pluie « centennale » a presque deux chances sur trois de se produire en un siècle, et une chance sur quatre sur 30 ans. La probabilité de ne jamais l'observer en 100 ans, 0,366, est très proche de $1/e$: le nombre de dépassements en 100 ans suit $\text{Bi}(100; 0,01) \approx \text{Po}(1)$, et $(1 - 1/T)^T \rightarrow e^{-1}$.
6. Les pluies de jours consécutifs sont corrélées (épisodes pluvieux de plusieurs jours) : le nombre effectif de jours « indépendants » est inférieur à 365. En pratique, on ajuste directement une loi de Gumbel sur les maxima annuels observés ; le théorème de Fisher-Tippett justifie ce choix de famille sans qu'il soit nécessaire de connaître la loi journalière.

Exercice 8.

1. Pour $Y \sim \text{Exp}(\lambda)$ et $t < \lambda$: $M_Y(t) = \int_0^{+\infty} e^{tx} \lambda e^{-\lambda x} dx = \lambda \int_0^{+\infty} e^{-(\lambda-t)x} dx = \frac{\lambda}{\lambda-t}$. Pour $G \sim \Gamma(n, \lambda)$ et $t < \lambda$, le calcul de normalisation de la loi Gamma (avec $\lambda - t$ à la place de β) donne $M_G(t) = \frac{\lambda^n}{\Gamma(n)} \int_0^{+\infty} x^{n-1} e^{-(\lambda-t)x} dx = \left(\frac{\lambda}{\lambda-t}\right)^n$. Sachant $N = n$, S a la loi de $Y_1 + \dots + Y_n$ (séance 2), de fonction génératrice des moments $M_Y(t)^n = (\lambda/(\lambda-t))^n$ (produit pour des variables indépendantes). C'est celle de $\Gamma(n, \lambda)$, avec ici $\lambda = 1/5$; on conclut par la caractérisation.
2. Script possible (`rng.gamma(N, 5.0)` tire une loi $\Gamma(N, 1/5)$, et vaut 0 si $N = 0$) :

```
import numpy as np
rng = np.random.default_rng(3)
n = 10_000
N = rng.poisson(20, n)
S = rng.gamma(N, 5.0)          # sachant N, S ~ Gamma(N, 1/5)

m, s = S.mean(), S.std()
print(m, m - 1.96*s/np.sqrt(n), m + 1.96*s/np.sqrt(n))

f = (S > 150).mean()
h = 1.96*np.sqrt(f*(1 - f)/n)
print(f, f - h, f + h)
```

On obtient par exemple $\mathbb{E}[S] \in [99,6; 100,8]$ et $p \in [0,059; 0,069]$: les deux intervalles contiennent les valeurs exactes 100 et 0,0677. Un autre tirage donne d'autres intervalles ; environ 95 % d'entre eux contiennent la vraie valeur.

3. $\mathbb{P}(S > 150) \approx 1 - \Phi((150 - 100)/31,6) = 1 - \Phi(1,58) \approx 0,057$, soit une sous-estimation d'environ 16 %. La loi de S est asymétrique à droite (une somme de coûts positifs, dont le nombre est aléatoire) ; l'approximation normale, symétrique, sous-estime sa queue droite. L'écart s'aggrave plus loin dans la queue (TD 4).
4. Il faut $1,96\sqrt{p(1-p)/n} \leq 0,05p$, soit $n \geq \frac{1,96^2(1-p)}{0,05^2 p} \approx \frac{3,84 \times 0,932}{0,0025 \times 0,0677} \approx 21\,000$ simulations.

4 Séance 4 — Mesures de risque et événements rares

Objectifs. Définir et calculer les mesures de risque utilisées en assurance, en finance et en ingénierie : quantile (VaR) et TVaR. Comprendre pourquoi la VaR peut pénaliser la diversification et pourquoi la TVaR ne le fait pas. Estimer ces quantités par simulation, et rendre la simulation des événements rares possible grâce à l'échantillonnage préférentiel.

4.1 Cours

Dans toute cette séance, X désigne une *perte* (une valeur élevée est défavorable), de fonction de répartition F . On rappelle que F est croissante, continue à droite, de limites 0 en $-\infty$ et 1 en $+\infty$.

4.1.1 Quantiles

Définition 4.1. Pour $\alpha \in]0, 1[$, le quantile d'ordre α de X est $q_\alpha(X) = \inf\{x \in \mathbb{R} : F(x) \geq \alpha\}$. C'est l'inverse généralisée de F introduite en séance 2.

Proposition 4.2. (i) q_α est un réel, et $F(q_\alpha) \geq \alpha$.

(ii) Pour tout réel x , $F(x) \geq \alpha \iff x \geq q_\alpha$.

(iii) Si F est continue au point q_α , $F(q_\alpha) = \alpha$ et $\mathbb{P}(X > q_\alpha) = 1 - \alpha$.

Démonstration. Notons $E_\alpha = \{x \in \mathbb{R} : F(x) \geq \alpha\}$.

Étape 1 (q_α est fini). Comme $F(x) \rightarrow 1 > \alpha$ quand $x \rightarrow +\infty$, E_α n'est pas vide. Comme $F(x) \rightarrow 0 < \alpha$ quand $x \rightarrow -\infty$, il existe x_0 tel que $F(x) < \alpha$ pour tout $x \leq x_0$ (F est croissante) : E_α est minoré par x_0 . Sa borne inférieure q_α est donc un réel.

Étape 2 (E_α est un intervalle non borné à droite). Si $x \in E_\alpha$ et $y \geq x$, alors $F(y) \geq F(x) \geq \alpha$, donc $y \in E_\alpha$. Par définition de la borne inférieure, pour tout $x > q_\alpha$ il existe $e \in E_\alpha$ avec $e < x$, donc $x \in E_\alpha$.

Étape 3 (q_α appartient à E_α). Par l'étape 2, $F(q_\alpha + 1/n) \geq \alpha$ pour tout $n \geq 1$; F étant continue à droite, $F(q_\alpha) = \lim F(q_\alpha + 1/n) \geq \alpha$. Donc $E_\alpha = [q_\alpha, +\infty[$, ce qui prouve (i) et (ii).

Étape 4 (cas continu). Pour $x < q_\alpha$, $F(x) < \alpha$ par (ii). En faisant tendre x vers q_α par la gauche, la continuité de F en q_α donne $F(q_\alpha) \leq \alpha$, donc $F(q_\alpha) = \alpha$ par (i), et $\mathbb{P}(X > q_\alpha) = 1 - F(q_\alpha) = 1 - \alpha$. $\square$

Proposition 4.3 (Transformation affine). Pour $a > 0$ et b réel, $q_\alpha(aX + b) = a q_\alpha(X) + b$.

Démonstration. $F_{aX+b}(y) = \mathbb{P}(aX + b \leq y) = F((y-b)/a)$ car $a > 0$. Par (ii) appliqué à X : $F_{aX+b}(y) \geq \alpha \iff (y-b)/a \geq q_\alpha(X) \iff y \geq a q_\alpha(X) + b$. Le plus petit tel y est $a q_\alpha(X) + b$. $\square$

4.1.2 Value-at-Risk

Définition 4.4. La *Value-at-Risk* de niveau α est $\text{VaR}_\alpha(X) = q_\alpha(X)$.

Par (i), $\mathbb{P}(X > \text{VaR}_\alpha(X)) = 1 - F(\text{VaR}_\alpha(X)) \leq 1 - \alpha$: la perte ne dépasse la VaR qu'avec probabilité au plus $1 - \alpha$. La directive européenne Solvabilité II calibre le capital réglementaire des assureurs sur la VaR à 99,5 % de la perte à un an ; en ingénierie, un niveau de retour est aussi un quantile (voir plus bas).

Proposition 4.5 (Propriétés de la VaR). (a) *Monotonie* : si $X \leq Y$ pour toute issue, $\text{VaR}_\alpha(X) \leq \text{VaR}_\alpha(Y)$.

(b) *Invariance par translation et homogénéité positive* : $\text{VaR}_\alpha(aX + b) = a \text{VaR}_\alpha(X) + b$ pour $a > 0$.

Démonstration. (a) $\{Y \leq x\} \subset \{X \leq x\}$, donc $F_Y \leq F_X$; ainsi $F_Y(x) \geq \alpha$ entraîne $F_X(x) \geq \alpha$: l'ensemble dont $\text{VaR}_\alpha(Y)$ est la borne inférieure est inclus dans celui de $\text{VaR}_\alpha(X)$, d'où l'inégalité. (b) C'est la proposition sur les transformations affines. $\square$

Proposition 4.6 (La VaR n'est pas sous-additive). *Soient X et Y indépendantes, valant chacune 100 avec probabilité 0,04 et 0 sinon. Alors $\text{VaR}_{0,95}(X) = \text{VaR}_{0,95}(Y) = 0$, mais $\text{VaR}_{0,95}(X + Y) = 100$.*

Démonstration. Étape 1. $F_X(x) = 0$ pour $x < 0$ et $F_X(x) = 0,96 \geq 0,95$ pour $0 \leq x < 100$: le plus petit x tel que $F_X(x) \geq 0,95$ est 0.

Étape 2. $X + Y$ prend les valeurs 0, 100 et 200, avec $\mathbb{P}(X + Y = 0) = 0,96^2 = 0,9216$ par indépendance. Donc $F_{X+Y}(x) = 0,9216 < 0,95$ pour $0 \leq x < 100$, et $F_{X+Y}(100) = 1 - 0,04^2 = 0,9984 \geq 0,95$: $\text{VaR}_{0,95}(X + Y) = 100$. $\square$

Regrouper deux risques peut donc *augmenter* la VaR totale, ce qui contredit l'intuition de la diversification (séance 1); symétriquement, fractionner un portefeuille peut faire baisser artificiellement la VaR affichée. La VaR ne dit en outre rien de l'ampleur des pertes au-delà d'elle.

Exemples.

- Loi normale $\mathcal{N}(\mu, \sigma^2)$: Φ étant continue et strictement croissante, $q_\alpha(Z) = \Phi^{-1}(\alpha) =: z_\alpha$ pour $Z \sim \mathcal{N}(0, 1)$, et $\text{VaR}_\alpha(\mu + \sigma Z) = \mu + \sigma z_\alpha$.
- Loi exponentielle $\text{Exp}(\lambda)$: on résout $1 - e^{-\lambda x} = \alpha$, d'où $\text{VaR}_\alpha = -\ln(1 - \alpha)/\lambda$.
- Loi de Pareto ($x_m > 0, \theta > 0, F(x) = 1 - (x_m/x)^\theta$ pour $x \geq x_m$) : on résout $(x_m/x)^\theta = 1 - \alpha$, d'où $\text{VaR}_\alpha = x_m(1 - \alpha)^{-1/\theta}$.

4.1.3 Tail Value-at-Risk

Hypothèse (H). X admet une espérance et sa fonction de répartition F est continue au point $q_\alpha(X)$ (c'est le cas si F est continue). Alors $\mathbb{P}(X > q_\alpha) = 1 - \alpha > 0$ par (iii).

Définition 4.7. Sous (H), la *Tail Value-at-Risk* (ou *Expected Shortfall*) de niveau α est

$$\text{TVaR}_\alpha(X) = \mathbb{E}[X \mid X > \text{VaR}_\alpha(X)] = \frac{\mathbb{E}[X \mathbf{1}_{\{X > q_\alpha\}}]}{1 - \alpha}.$$

C'est la perte moyenne *dans les* $100(1 - \alpha)\%$ *pires cas*. On a $\text{TVaR}_\alpha(X) \geq \text{VaR}_\alpha(X)$: sur l'événement $\{X > q_\alpha\}$, $X > q_\alpha$, et l'on applique la croissance à la loi conditionnelle.

Proposition 4.8 (Représentation). *Sous (H), pour tout réel c , posons $\psi(c) = c + \frac{\mathbb{E}[(X - c)^+]}{1 - \alpha}$, où $t^+ = \max(t, 0)$. Alors $\psi(c) \geq \psi(q_\alpha) = \text{TVaR}_\alpha(X)$: la TVaR est le minimum de ψ .*

Démonstration. Notons $q = q_\alpha$. Les espérances sont finies car $(x - c)^+ \leq |x| + |c|$.

Étape 1 ($\psi(q)$ est la TVaR). $(X - q)^+ = (X - q)\mathbf{1}_{\{X > q\}}$, donc $\mathbb{E}[(X - q)^+] = \mathbb{E}[X \mathbf{1}_{\{X > q\}}] - q \mathbb{P}(X > q) = \mathbb{E}[X \mathbf{1}_{\{X > q\}}] - q(1 - \alpha)$, et $\psi(q) = q + \frac{\mathbb{E}[X \mathbf{1}_{\{X > q\}}]}{1 - \alpha} - q = \text{TVaR}_\alpha(X)$.

Étape 2 (cas $c > q$). Pour tout réel x , $(x - q)^+ - (x - c)^+ \leq (c - q)\mathbf{1}_{\{x > q\}}$: si $x \leq q$, le membre de gauche est nul ; si $q < x < c$, il vaut $x - q < c - q$; si $x \geq c$, il vaut $c - q$. Par croissance, $\mathbb{E}[(X - q)^+] - \mathbb{E}[(X - c)^+] \leq (c - q)(1 - \alpha)$, d'où $\psi(c) - \psi(q) = (c - q) - \frac{\mathbb{E}[(X - q)^+] - \mathbb{E}[(X - c)^+]}{1 - \alpha} \geq 0$.

Étape 3 (cas $c < q$). Pour tout réel x , $(x - c)^+ - (x - q)^+ \geq (q - c)\mathbf{1}_{\{x \geq q\}}$: si $x \geq q$, le membre de gauche vaut $q - c$; sinon il est positif. Par croissance et comme $\mathbb{P}(X \geq q) \geq \mathbb{P}(X > q) = 1 - \alpha$, $\mathbb{E}[(X - c)^+] - \mathbb{E}[(X - q)^+] \geq (q - c)(1 - \alpha)$, d'où $\psi(c) - \psi(q) = (c - q) + \frac{\mathbb{E}[(X - c)^+] - \mathbb{E}[(X - q)^+]}{1 - \alpha} \geq (c - q) + (q - c) = 0$. $\square$

Théorème 4.9 (Sous-additivité de la TVaR). *Si X , Y et $X + Y$ vérifient (H), alors $\text{TVaR}_\alpha(X + Y) \leq \text{TVaR}_\alpha(X) + \text{TVaR}_\alpha(Y)$.*

Démonstration. Étape 1 (sous-additivité de la partie positive). Pour tous réels s, t , $(s + t)^+ \leq s^+ + t^+$: en effet $s + t \leq s^+ + t^+$ et $0 \leq s^+ + t^+$.

Étape 2. Pour tous réels c_1, c_2 , l'étape 1 avec $s = X - c_1$ et $t = Y - c_2$, puis la croissance et la linéarité, donnent $\mathbb{E}[(X + Y - c_1 - c_2)^+] \leq \mathbb{E}[(X - c_1)^+] + \mathbb{E}[(Y - c_2)^+]$, c'est-à-dire $\psi_{X+Y}(c_1 + c_2) \leq \psi_X(c_1) + \psi_Y(c_2)$.

Étape 3. Avec $c_1 = \text{VaR}_\alpha(X)$ et $c_2 = \text{VaR}_\alpha(Y)$, la proposition de représentation donne $\text{TVaR}_\alpha(X + Y) \leq \psi_{X+Y}(c_1 + c_2) \leq \psi_X(c_1) + \psi_Y(c_2) = \text{TVaR}_\alpha(X) + \text{TVaR}_\alpha(Y)$. $\square$

Remarque. La TVaR est aussi monotone, invariante par translation et positivement homogène (on le vérifie directement sur la définition). Ces quatre propriétés définissent une *mesure de risque cohérente* (Artzner, Delbaen, Eber et Heath, 1999) ; la VaR n'en est pas une. Pour une loi quelconque, on définit $\text{TVaR}_\alpha(X) = \frac{1}{1-\alpha} \int_\alpha^1 \text{VaR}_u(X) du$, qui coïncide avec la définition précédente sous (H) (admis). La réglementation bancaire de Bâle et le Test suisse de solvabilité retiennent cette mesure (sous le nom d'*Expected Shortfall*).

Exemples.

- Loi normale. Pour $Z \sim \mathcal{N}(0, 1)$, comme $\varphi' = -z\varphi$ (exercice 3 du TD 1), $\mathbb{E}[Z\mathbf{1}_{\{Z > z\}}] = \int_z^{+\infty} u\varphi(u) du = [-\varphi(u)]_z^{+\infty} = \varphi(z)$. Donc $\text{TVaR}_\alpha(Z) = \varphi(z_\alpha)/(1 - \alpha)$ et, la TVaR se transformant comme l'espérance conditionnelle, $\text{TVaR}_\alpha(\mu + \sigma Z) = \mu + \sigma \varphi(z_\alpha)/(1 - \alpha)$.
- Loi exponentielle. Par intégration par parties, $\int_q^{+\infty} x\lambda e^{-\lambda x} dx = [-xe^{-\lambda x}]_q^{+\infty} + \int_q^{+\infty} e^{-\lambda x} dx = (q + \frac{1}{\lambda})e^{-\lambda q}$; en divisant par $\mathbb{P}(X > q) = e^{-\lambda q}$, $\text{TVaR}_\alpha = \text{VaR}_\alpha + \frac{1}{\lambda}$. (C'est l'absence de mémoire : au-delà de q , l'excès suit encore la loi $\text{Exp}(\lambda)$.)
- Loi de Pareto, $\theta > 1$. $\int_q^{+\infty} x\theta x_m^\theta x^{-\theta-1} dx = \frac{\theta}{\theta-1} x_m^\theta q^{1-\theta}$; en divisant par $\mathbb{P}(X > q) = (x_m/q)^\theta$, $\text{TVaR}_\alpha = \frac{\theta}{\theta-1} \text{VaR}_\alpha$.

Le rapport TVaR/VaR mesure le poids de la queue : pour la loi de Pareto, il vaut $\theta/(\theta - 1)$ quel que soit α , et devient très grand quand θ approche 1.

4.1.4 Lien avec les valeurs extrêmes

Le niveau de retour T ans de la séance 3 est défini par $F(x_T) = 1 - 1/T$, où F est la fonction de répartition, continue, du maximum annuel M . Par (ii) et (iii), c'est exactement $x_T = \text{VaR}_{1-1/T}(M)$: la crue centennale est la VaR à 99 % du maximum annuel.

4.1.5 Estimation empirique

À partir d'un échantillon (observé ou simulé) $X_1, \dots, X_n$, on définit la fonction de répartition empirique $F_n(x) = \frac{1}{n} \#\{i : X_i \leq x\}$, et l'on note $X_{(1)} \leq \dots \leq X_{(n)}$ les valeurs rangées par ordre croissant.

Proposition 4.10. *Le quantile d'ordre α de F_n est $X_{(k)}$, avec $k = \lceil n\alpha \rceil$.*

Démonstration. $F_n(x) \geq \alpha \iff \#\{i : X_i \leq x\} \geq n\alpha \iff \#\{i : X_i \leq x\} \geq \lceil n\alpha \rceil$ (un nombre entier est supérieur ou égal à $n\alpha$ si et seulement s'il l'est à $\lceil n\alpha \rceil$) $\iff x \geq X_{(\lceil n\alpha \rceil)}$. Le plus petit tel x est $X_{(\lceil n\alpha \rceil)}$. $\square$

On admet que la VaR empirique converge en probabilité vers $\text{VaR}_\alpha(X)$ lorsque F est continue et strictement croissante au voisinage de q_α (conséquence du théorème de Glivenko-Cantelli, voir Delmas, chapitre V). La TVaR empirique est la moyenne des observations supérieures à la VaR empirique. Seules $n(1 - \alpha)$ observations environ tombent dans la queue : avec $n = 10\,000$ et $\alpha = 0,995$, on n'en dispose que d'une cinquantaine. Estimer une mesure de risque extrême par simulation pose donc le même problème que les événements rares.

4.1.6 Échantillonnage préférentiel

Pour estimer $p = \mathbb{P}(X \in A)$ par simulation directe, il faut environ $400/p$ tirages pour une précision relative de 10 % (séance 3). L'idée de l'échantillonnage préférentiel est de simuler sous une autre loi, qui rend l'événement fréquent, puis de corriger par un poids.

Théorème 4.11. Soit X de densité f , A un intervalle (ou une réunion finie d'intervalles), $p = \mathbb{P}(X \in A)$, et g une densité telle que $g(y) > 0$ pour tout $y \in A$ où $f(y) > 0$. On pose $w = f/g$ là où $g > 0$ et $w = 0$ ailleurs. Soient $Y_1, \dots, Y_n$ indépendantes de densité g , et

$$\hat{p}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_A(Y_i) w(Y_i).$$

Alors $\mathbb{E}[\hat{p}_n] = p$ et, si $m_2 = \int_A f(y)^2/g(y) dy < \infty$, $\text{Var } \hat{p}_n = (m_2 - p^2)/n$ et $\hat{p}_n$ converge en probabilité vers p .

Démonstration. Étape 1 (sans biais). Par le transfert pour une variable à densité, $\mathbb{E}[\mathbf{1}_A(Y_1)w(Y_1)] = \int_A w(y)g(y) dy = \int_A f(y) dy = p$: là où $g > 0$, $wg = f$; là où $g = 0$ sur A , $f = 0$ par hypothèse et les deux intégrandes sont nuls. Par linéarité, $\mathbb{E}[\hat{p}_n] = p$.

Étape 2 (variance). De même, $\mathbb{E}[(\mathbf{1}_A(Y_1)w(Y_1))^2] = \int_A w^2g = \int_A f^2/g = m_2$, donc $\text{Var}(\mathbf{1}_A(Y_1)w(Y_1)) = m_2 - p^2$ (Koenig). Les termes étant indépendants, la variance de la somme est la somme des variances, et $\text{Var } \hat{p}_n = (m_2 - p^2)/n$.

Étape 3 (convergence). C'est la loi faible des grands nombres. $\square$

Remarque (Densité optimale). Avec $g^* = f\mathbf{1}_A/p$, le poids $\mathbf{1}_A w$ vaut p sur A , donc $m_2 = p^2$ et la variance est nulle. Cette densité est inutilisable, puisqu'elle suppose p connu, mais elle indique la bonne stratégie : choisir g proche de la loi de X conditionnée à l'événement rare.

Exemple. $X \sim \text{Exp}(1)$, $A =]a, +\infty[$, $p = e^{-a}$. On prend g la densité de $\text{Exp}(\theta)$, avec $0 < \theta < 2$, donc $w(y) = e^{-(1-\theta)y}/\theta$. Alors

$$m_2 = \int_a^{+\infty} \frac{e^{-2y}}{\theta e^{-\theta y}} dy = \frac{1}{\theta} \int_a^{+\infty} e^{-(2-\theta)y} dy = \frac{e^{-(2-\theta)a}}{\theta(2-\theta)},$$

et la variance relative d'un tirage vaut $\frac{m_2 - p^2}{p^2} = \frac{e^{\theta a}}{\theta(2-\theta)} - 1$. Pour $\theta = 1$ (simulation directe),

on retrouve $e^a - 1 = (1 - p)/p$. Pour $\theta = 1/a$, elle vaut $\frac{e a^2}{2a - 1} - 1 \approx \frac{e a}{2}$: elle ne croît plus que linéairement en a , au lieu d'exponentiellement. Pour $a = 16$ ($p \approx 1,1 \times 10^{-7}$), une précision relative de 10 % à 95 % demande $1,96^2 \times \text{variance relative}/0,01$ tirages : environ $3,4 \times 10^9$ en simulation directe, contre environ 8 200 avec $\theta = 1/16$. Sous g , l'événement $\{Y > 16\}$ a une probabilité $e^{-1} \approx 0,37$: il n'est plus rare.

4.2 TD 4

Exercice 1 — Trois lois de même espérance.

On considère trois modèles de perte d'espérance 10 : $X_1 \sim \mathcal{N}(10, 10^2)$, $X_2 \sim \text{Exp}(1/10)$ et X_3 de loi de Pareto de paramètres $x_m = 5$ et $\theta = 2$.

1. Vérifier que $\mathbb{E}[X_3] = 10$. Comparer les variances des trois lois.
2. Calculer $\text{VaR}_{0,99}$ et $\text{TVaR}_{0,99}$ pour chacune ($z_{0,99} \approx 2,326$ et $\varphi(z_{0,99}) \approx 0,0267$).
3. Commenter : que révèle la TVaR que la VaR ne montre pas ?

Exercice 2 — Quand la VaR décourage la diversification.

1. Démontrer la proposition du cours sur la non-sous-additivité de la VaR.
2. Un établissement détient les deux risques X et Y de la proposition. Il crée deux filiales portant chacune un seul risque. Que devient la VaR à 95 % déclarée ? Qu'en conclure pour un régulateur ?
3. Montrer que, pour des risques vérifiant (H), un tel arbitrage est impossible avec la TVaR.

Exercice 3 — Capital de solvabilité d'un portefeuille.

On reprend la charge sinistre S de l'exercice 5 du TD 2 ($\mathbb{E}[S] = 100$, $\sigma_S \approx 31,6$), dont on admet que la fonction de répartition est continue sur $]0, +\infty[$.

1. Calculer $\text{VaR}_{0,995}(S)$ et $\text{TVaR}_{0,995}(S)$ sous l'approximation normale ($z_{0,995} \approx 2,576$, $\varphi(z_{0,995}) \approx 0,0145$).
2. Les valeurs exactes, obtenues numériquement, sont $\text{VaR}_{0,995}(S) \approx 195,1$ et $\text{TVaR}_{0,995}(S) \approx 209,6$. Quelle erreur commet-on ? Dans quel sens ?
3. Écrire un script qui estime $\text{VaR}_{0,995}(S)$ et $\text{TVaR}_{0,995}(S)$ à partir de $n = 100\,000$ simulations. Combien d'observations servent à l'estimation de la TVaR ?

Exercice 4 — Échantillonnage préférentiel pour une queue gaussienne.

On veut estimer $p = \mathbb{P}(Z > a)$ pour $Z \sim \mathcal{N}(0, 1)$ et $a = 5$ ($p \approx 2,87 \times 10^{-7}$). On simule sous la loi $\mathcal{N}(a, 1)$, c'est-à-dire la loi normale « recentrée sur l'événement rare ».

1. Montrer que le poids vaut $w(y) = e^{-ay+a^2/2}$.
2. Montrer que $m_2 = e^{a^2}(1 - \Phi(2a))$. On pourra établir que $e^{-ay}\varphi(y) = e^{a^2/2}\varphi(y+a)$.
3. Sachant que la variance relative d'un tirage vaut alors environ 5,7, combien de tirages faut-il pour une précision relative de 10 % à 95 % ? Comparer avec la simulation directe.
4. Écrire le script correspondant et vérifier que l'intervalle de confiance obtenu contient p .

4.3 Corrigés du TD 4

Exercice 1.

1. Pour la loi de Pareto, $\mathbb{E}[X_3] = \int_{x_m}^{+\infty} x \theta x_m^\theta x^{-\theta-1} dx = \frac{\theta x_m}{\theta-1} = \frac{2 \times 5}{1} = 10$. Sa variance est infinie, car $\int_{x_m}^{+\infty} x^2 x^{-3} dx = \int_{x_m}^{+\infty} \frac{dx}{x} = +\infty$. Les lois normale et exponentielle ont toutes deux une variance de 100.
2. Par les formules du cours, avec $1 - \alpha = 0,01$:

	VaR _{0,99}	TVaR _{0,99}
$\mathcal{N}(10, 10^2)$	$10 + 10 \times 2,326 \approx 33,3$	$10 + 10 \times \frac{0,0267}{0,01} \approx 36,7$
$\text{Exp}(1/10)$	$-10 \ln 0,01 \approx 46,1$	$46,1 + 10 = 56,1$
Pareto (5 ; 2)	$5 \times 0,01^{-1/2} = 50$	$2 \times 50 = 100$

3. À espérance égale, et à variance égale pour les deux premières, les VaR diffèrent déjà nettement. Mais c'est la TVaR qui révèle le poids de la queue : pour la loi normale, la perte moyenne au-delà de la VaR ne la dépasse que de 10 % ; pour la loi de Pareto, elle la double. Deux risques de VaR voisines (46 et 50) peuvent avoir des pertes extrêmes moyennes qui vont du simple au double. C'est le cas typique des sinistres catastrophiques (tempêtes, incendies industriels), dont la loi est souvent à queue lourde.

Exercice 2.

1. Voir la démonstration du cours.

2. Chaque filiale déclare une VaR à 95 % nulle, soit 0 au total, alors que le risque global, identique, a une VaR de 100. Fractionner un portefeuille permet de faire disparaître le risque affiché : un régulateur qui additionne des VaR calculées séparément peut être trompé, et une mesure non sous-additive peut pénaliser la mutualisation.
3. Si l'on remplace la VaR par la TVaR, la sous-additivité donne $\text{TVaR}_\alpha(X + Y) \leq \text{TVaR}_\alpha(X) + \text{TVaR}_\alpha(Y)$: la somme des mesures déclarées par les filiales majore toujours la mesure du risque global. Fractionner ne peut donc qu'augmenter le total déclaré.

Exercice 3.

1. $\text{VaR} \approx 100 + 2,576 \times 31,6 \approx 181,5$ et $\text{TVaR} \approx 100 + 31,6 \times \frac{0,0145}{0,005} \approx 191,5$.
2. L'approximation normale sous-estime la VaR d'environ 7 % (181,5 contre 195,1) et la TVaR d'environ 9 % (191,5 contre 209,6). L'erreur va dans le sens dangereux : le capital calculé serait insuffisant. La loi de S est asymétrique à droite, et le TCL décrit mal sa queue (séance 3).
3. Script possible :

```
import numpy as np
rng = np.random.default_rng(4)
n = 100_000
S = np.sort(rng.gamma(rng.poisson(20, n), 5.0))
k = int(np.ceil(n*0.995))          # VaR empirique = X_(k)
var = S[k - 1]                    # indices Python a partir de 0
tvar = S[S > var].mean()
print(var, tvar, (S > var).sum())
```

On obtient des valeurs proches de 195 et 210. La TVaR n'est estimée qu'à partir d'environ $n(1 - \alpha) = 500$ observations : pour un niveau plus extrême, il faudrait augmenter n ou recourir à l'échantillonnage préférentiel.

Exercice 4.

1. $w(y) = \frac{\varphi(y)}{\varphi(y-a)} = \exp\left(-\frac{y^2}{2} + \frac{(y-a)^2}{2}\right) = \exp\left(-\frac{y^2}{2} + \frac{y^2 - 2ay + a^2}{2}\right) = e^{-ay+a^2/2}$.
2. On complète le carré : $-\frac{y^2}{2} - ay = -\frac{(y+a)^2}{2} + \frac{a^2}{2}$, donc $e^{-ay}\varphi(y) = e^{a^2/2}\varphi(y+a)$. Comme $w \cdot \varphi(\cdot - a) = \varphi$,

$$m_2 = \int_a^{+\infty} w(y)^2 \varphi(y-a) dy = \int_a^{+\infty} w(y) \varphi(y) dy = e^{a^2/2} \int_a^{+\infty} e^{-ay} \varphi(y) dy = e^{a^2} \int_a^{+\infty} \varphi(y+a) dy = e^{a^2} (1 - \Phi(a))$$

3. Il faut $n \geq 1,96^2 \times 5,7/0,01 \approx 2\,200$ tirages, contre $1,96^2(1-p)/(0,01p) \approx 1,3 \times 10^9$ en simulation directe : un gain d'un facteur 600 000 environ.
4. Script possible :

```
import numpy as np
from scipy.stats import norm
rng = np.random.default_rng(5)
a, n = 5.0, 2200
Y = rng.normal(a, 1.0, n)
T = (Y > a) * np.exp(-a*Y + a*a/2)
m, s = T.mean(), T.std()
print(m - 1.96*s/np.sqrt(n), m + 1.96*s/np.sqrt(n), norm.sf(a))
```

L'intervalle obtenu a une demi-largeur d'environ 10 % de p et contient la valeur exacte $2,87 \times 10^{-7}$ dans environ 95 % des tirages.

5 Séance 5 — Vecteurs aléatoires et dépendance

Objectifs. Manipuler plusieurs risques à la fois : matrice de covariance, agrégation d'un portefeuille, vecteurs gaussiens et simulation de risques corrélés. Comprendre les limites de la corrélation, en particulier pour les événements extrêmes simultanés, et découvrir l'idée de copule.

5.1 Cours

5.1.1 Vecteurs aléatoires et matrice de covariance

Définition 5.1. Un vecteur aléatoire $X = (X_1, \dots, X_d)^\top$ est un vecteur colonne de variables aléatoires. Si elles admettent une espérance, $\mathbb{E}[X] = (\mathbb{E}[X_1], \dots, \mathbb{E}[X_d])^\top$. Si elles sont de variance finie, la *matrice de covariance* de X est la matrice $d \times d$

$$\Sigma = (\text{Cov}(X_i, X_j))_{1 \leq i, j \leq d}.$$

La *matrice de corrélation* a pour coefficients $\Sigma_{ij}/(\sigma_i \sigma_j)$ lorsque les variances σ_i^2 sont non nulles.

Proposition 5.2. Soit X un vecteur de variables de variance finie, d'espérance μ et de matrice de covariance Σ .

- (a) Σ est symétrique, et ses coefficients diagonaux sont les variances $\text{Var } X_i$.
- (b) Pour tout $a \in \mathbb{R}^d$, $\text{Var}(a^\top X) = a^\top \Sigma a$. En particulier $a^\top \Sigma a \geq 0$: Σ est positive.
- (c) Pour toute matrice A de taille $k \times d$ et tout $b \in \mathbb{R}^k$, $\mathbb{E}[AX + b] = A\mu + b$ et la matrice de covariance de $AX + b$ est $A\Sigma A^\top$.

Démonstration. (a) $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$ et $\text{Cov}(X_i, X_i) = \text{Var } X_i$ (séance 1).

(b) $a^\top X = \sum_i a_i X_i$. Par bilinéarité de la covariance (séance 1), $\text{Var}(\sum_i a_i X_i) = \text{Cov}(\sum_i a_i X_i, \sum_j a_j X_j) = \sum_i \sum_j a_i a_j \text{Cov}(X_i, X_j) = a^\top \Sigma a$. Une variance étant positive, $a^\top \Sigma a \geq 0$.

(c) La k -ième composante de $AX + b$ est $\sum_j A_{kj} X_j + b_k$; la linéarité donne son espérance $\sum_j A_{kj} \mu_j + b_k = (A\mu + b)_k$. Par bilinéarité, et comme les constantes b_k ne changent pas les covariances, $\text{Cov}((AX + b)_k, (AX + b)_l) = \sum_i \sum_j A_{ki} A_{lj} \text{Cov}(X_i, X_j) = (A\Sigma A^\top)_{kl}$. $\square$

5.1.2 Agrégation des risques

La perte d'un portefeuille composé des quantités $w_1, \dots, w_d$ de risques $X_1, \dots, X_d$ est $L = w^\top X$. Par la proposition précédente,

$$\mathbb{E}[L] = w^\top \mu, \quad \text{Var } L = w^\top \Sigma w.$$

Par exemple, si les d risques ont la même variance σ^2 et une corrélation ρ deux à deux, $\Sigma = \sigma^2((1 - \rho)I_d + \rho \mathbf{1}\mathbf{1}^\top)$, où $\mathbf{1}$ est le vecteur dont toutes les composantes valent 1. Pour la perte moyenne ($w = \mathbf{1}/d$), $\text{Var } L = \sigma^2(\frac{1-\rho}{d} + \rho)$: on retrouve l'exercice 7 du TD 1.

5.1.3 Vecteurs gaussiens

Définition 5.3. Le vecteur X est *gaussien* si, pour tout $a \in \mathbb{R}^d$, la variable $a^\top X$ suit une loi normale, éventuellement dégénérée (on convient que $\mathcal{N}(m, 0)$ est la loi de la constante m).

Proposition 5.4. Si $Z_1, \dots, Z_d$ sont indépendantes de loi $\mathcal{N}(0, 1)$, le vecteur $Z = (Z_1, \dots, Z_d)^\top$ est gaussien, d'espérance nulle et de matrice de covariance I_d .

Démonstration. Soit $a \neq 0$. Par les propriétés (b) et (c) de la fonction génératrice des moments (séance 3) et $M_{Z_i}(t) = e^{t^2/2}$: $M_{a^\top Z}(t) = \prod_i M_{Z_i}(a_i t) = \prod_i e^{a_i^2 t^2/2} = e^{\|a\|^2 t^2/2}$, qui est la fonction génératrice des moments de $\mathcal{N}(0, \|a\|^2)$; on conclut par la caractérisation (admise). Pour $a = 0$, $a^\top Z = 0$ suit $\mathcal{N}(0, 0)$. Enfin, les Z_i étant indépendantes, leurs covariances sont nulles, et leurs variances valent 1. $\square$

Proposition 5.5. *Si X est un vecteur gaussien, alors $AX + b$ est un vecteur gaussien pour toute matrice A et tout vecteur b de tailles compatibles.*

Démonstration. Pour tout c , $c^\top (AX + b) = (A^\top c)^\top X + c^\top b$. Le premier terme suit une loi normale, puisque X est gaussien ; ajouter une constante donne encore une loi normale. $\square$

Proposition 5.6 (Construction). *Soit $\mu \in \mathbb{R}^d$, Σ une matrice symétrique positive, et L une matrice telle que $LL^\top = \Sigma$. Si Z est comme dans la proposition précédente, $X = \mu + LZ$ est un vecteur gaussien d'espérance μ et de matrice de covariance Σ .*

Démonstration. X est gaussien par les deux propositions précédentes. Par (c), son espérance vaut $L \cdot 0 + \mu = \mu$ et sa matrice de covariance $LI_dL^\top = \Sigma$. $\square$

Lorsque Σ est définie positive, une telle matrice L , triangulaire inférieure, est fournie par la *factorisation de Cholesky* (résultat d'algèbre linéaire, admis). En dimension 2, avec $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$

et $|\rho| < 1$, on vérifie directement que $L = \begin{pmatrix} \sigma_1 & 0 \\ \rho\sigma_2 & \sigma_2\sqrt{1-\rho^2} \end{pmatrix}$ convient : $LL^\top$ a pour coefficients σ_1^2 , $\rho\sigma_1\sigma_2$ et $\rho^2\sigma_2^2 + \sigma_2^2(1-\rho^2) = \sigma_2^2$. Autrement dit,

$$X_1 = \mu_1 + \sigma_1 Z_1, \quad X_2 = \mu_2 + \sigma_2(\rho Z_1 + \sqrt{1-\rho^2} Z_2).$$

Proposition 5.7 (La loi d'un vecteur gaussien). *Si X est gaussien, d'espérance μ et de matrice de covariance Σ , alors pour tout $t \in \mathbb{R}^d$, $t^\top X \sim \mathcal{N}(t^\top \mu, t^\top \Sigma t)$ et*

$$\mathbb{E}[e^{t^\top X}] = \exp\left(t^\top \mu + \frac{1}{2} t^\top \Sigma t\right).$$

On admet que cette fonction de t caractérise la loi du vecteur X : la loi d'un vecteur gaussien est déterminée par μ et Σ , et l'on la note $\mathcal{N}_d(\mu, \Sigma)$.

Démonstration. $t^\top X$ suit une loi normale par définition ; son espérance $t^\top \mu$ et sa variance $t^\top \Sigma t$ viennent de la linéarité et de (b). La formule est la fonction génératrice des moments de cette loi normale, évaluée en 1 (séance 3). $\square$

Proposition 5.8 (Indépendance). *Les composantes d'un vecteur gaussien sont indépendantes si et seulement si sa matrice de covariance est diagonale.*

Démonstration. Si elles sont indépendantes, leurs covariances sont nulles (séance 1). Réciproquement, si Σ est diagonale, de coefficients σ_i^2 , la formule précédente se factorise : $\mathbb{E}[e^{t^\top X}] = \prod_i \exp(t_i \mu_i + \sigma_i^2 t_i^2 / 2)$. C'est aussi la fonction $t \mapsto \mathbb{E}[e^{t^\top X'}]$ du vecteur X' dont les composantes $X'_i = \mu_i + \sigma_i Z_i$ sont indépendantes (théorème du produit). Par la caractérisation admise, X et X' ont même loi, donc les composantes de X sont indépendantes. $\square$

Proposition 5.9 (Des marges gaussiennes ne suffisent pas). *Soit $X \sim \mathcal{N}(0, 1)$ et S indépendante de X , valant 1 ou -1 avec probabilité $\frac{1}{2}$, et $Y = SX$. Alors $Y \sim \mathcal{N}(0, 1)$ et $\text{Cov}(X, Y) = 0$, mais X et Y ne sont pas indépendantes, et (X, Y) n'est pas un vecteur gaussien.*

Démonstration. Étape 1 (loi de Y). Par les probabilités totales et l'indépendance, $\mathbb{P}(Y \leq y) = \frac{1}{2}\mathbb{P}(X \leq y) + \frac{1}{2}\mathbb{P}(-X \leq y) = \frac{1}{2}\Phi(y) + \frac{1}{2}(1 - \Phi(-y)) = \Phi(y)$, par la symétrie $\Phi(-y) = 1 - \Phi(y)$.

Étape 2 (covariance). Par le théorème du produit, $\mathbb{E}[XY] = \mathbb{E}[S] \mathbb{E}[X^2] = 0 \times 1 = 0$, et $\mathbb{E}[X] = \mathbb{E}[Y] = 0$, donc $\text{Cov}(X, Y) = 0$.

Étape 3 (dépendance). $|Y| = |X|$, donc $\mathbb{P}(|X| \leq 1, |Y| > 1) = 0$, alors que $\mathbb{P}(|X| \leq 1) \mathbb{P}(|Y| > 1) > 0$.

Étape 4 (pas un vecteur gaussien). $X + Y = (1 + S)X$ vaut 0 avec probabilité au moins $\mathbb{P}(S = -1) = \frac{1}{2}$. Une loi normale non dégénérée ne charge aucun point, et $X + Y$ n'est pas constante (elle vaut $2X$ lorsque $S = 1$) : $X + Y$ n'est pas normale. $\square$

5.1.4 VaR gaussienne et diversification

Proposition 5.10. Si (X, Y) est un vecteur gaussien et $\alpha \geq \frac{1}{2}$, alors $\text{VaR}_\alpha(X+Y) \leq \text{VaR}_\alpha(X) + \text{VaR}_\alpha(Y)$, et l'écart vaut $z_\alpha(\sigma_X + \sigma_Y - \sigma_{X+Y}) \geq 0$.

Démonstration. X , Y et $X+Y$ sont normales (définition, avec $a = (1, 0)$, $(0, 1)$, $(1, 1)$), de VaR $\mu + z_\alpha \sigma$ (séance 4). Or $\sigma_{X+Y}^2 = \sigma_X^2 + \sigma_Y^2 + 2\rho\sigma_X\sigma_Y \leq (\sigma_X + \sigma_Y)^2$ car $\rho \leq 1$, donc $\sigma_{X+Y} \leq \sigma_X + \sigma_Y$; et $z_\alpha \geq 0$ pour $\alpha \geq \frac{1}{2}$. $\square$

Dans un monde gaussien, la VaR récompense donc toujours la diversification. Les contre-exemples de la séance 4 viennent de lois éloignées de la loi normale : discrètes, asymétriques ou à queue lourde.

5.1.5 Limites de la corrélation : la dépendance de queue

La corrélation résume la dépendance *en moyenne*. En gestion des risques, on s'intéresse surtout aux extrêmes *simultanés* : une tempête qui frappe tous les contrats d'une région, des crues concomitantes sur des bassins voisins, une défaillance de cause commune.

Définition 5.11. Soient X et Y de fonctions de répartition continues. Leur coefficient de dépendance de queue (supérieure) est, lorsque la limite existe,

$$\lambda_U = \lim_{u \rightarrow 1^-} \mathbb{P}(Y > q_u(Y) \mid X > q_u(X)).$$

Proposition 5.12. (a) Si X et Y sont indépendantes, $\lambda_U = 0$.

(b) Si $Y = g(X)$ avec g continue et strictement croissante (on dit que X et Y sont comonotones), $\lambda_U = 1$.

(c) Pour l'exemple (X, SX) ci-dessus, $\lambda_U = \frac{1}{2}$, bien que $\text{Cov}(X, Y) = 0$.

Démonstration. (a) Par indépendance et (iii) de la séance 4, la probabilité conditionnelle vaut $\mathbb{P}(Y > q_u(Y)) = 1 - u \rightarrow 0$.

(b) Notons $q = q_u(X)$. On a $F_Y(g(q)) = \mathbb{P}(g(X) \leq g(q)) = \mathbb{P}(X \leq q) = u$. Si $y < g(q)$, soit y est inférieur à toutes les valeurs de g et $F_Y(y) = 0$, soit $y = g(x)$ avec $x < q$ (g est continue, donc son image est un intervalle) et $F_Y(y) = F_X(x) < u$. Donc $q_u(Y) = g(q)$, et $\{Y > q_u(Y)\} = \{g(X) > g(q)\} = \{X > q\}$: la probabilité conditionnelle vaut 1.

(c) X et Y ont même loi, donc $q_u(Y) = q_u(X) = q$, avec $q \geq 0$ pour $u \geq \frac{1}{2}$. L'événement $\{X > q, Y > q\}$ est $\{X > q, S = 1\}$, car $S = -1$ exigerait $X > q \geq 0$ et $-X > q \geq 0$. Par indépendance, sa probabilité est $\frac{1}{2}(1 - u)$, et la probabilité conditionnelle vaut $\frac{1}{2}$ pour tout $u \geq \frac{1}{2}$. $\square$

Pour un vecteur gaussien de corrélation $|\rho| < 1$, on admet que $\lambda_U = 0$: les extrêmes finissent par devenir indépendants. La convergence est lente ; pour $\rho = 0,7$, la probabilité conditionnelle vaut environ 0,47 pour $u = 0,9$, 0,27 pour $u = 0,99$, 0,16 pour $u = 0,999$ et 0,10 pour $u = 0,9999$. Un modèle gaussien, calibré sur la corrélation observée en temps normal, sous-estime donc la fréquence des catastrophes simultanées.

5.1.6 Ouverture : les copules

Proposition 5.13 (Théorème de Sklar, cas des marges continues strictement croissantes). Soient X et Y de fonctions de répartition F et G continues et strictement croissantes sur $\mathbb{R}$, et $H(x, y) = \mathbb{P}(X \leq x, Y \leq y)$. Soit C la fonction de répartition du couple $(U, V) = (F(X), G(Y))$. Alors U et V suivent la loi $\text{Un}(0, 1)$, et $H(x, y) = C(F(x), G(y))$ pour tous x, y .

Démonstration. U et V sont uniformes par la réciproque de la méthode d'inversion (séance 2). F et G étant strictement croissantes, $\{X \leq x\} = \{F(X) \leq F(x)\}$ et $\{Y \leq y\} = \{G(Y) \leq G(y)\}$, d'où $H(x, y) = \mathbb{P}(U \leq F(x), V \leq G(y)) = C(F(x), G(y))$. $\square$

La fonction C , appelée *copule*, contient toute la dépendance ; les marges F et G contiennent tout le reste. On peut donc choisir séparément les lois de chaque risque et leur structure de dépendance. Pour simuler, on tire (U, V) selon C , puis on pose $X = F^{-1}(U)$ et $Y = G^{-1}(V)$ (méthode d'inversion). La copule d'un vecteur gaussien a une dépendance de queue nulle ; d'autres familles (copules de Gumbel ou de Student, par exemple) ont une dépendance de queue positive (admis). Le résultat s'étend à des marges quelconques (théorème de Sklar, admis).

5.2 TD 5

Exercice 1 — Portefeuille de deux risques gaussiens.

(X_1, X_2) est un vecteur gaussien d'espérance $(10, 20)$, d'écarts-types $\sigma_1 = 3$, $\sigma_2 = 4$ et de corrélation $\rho = 0,5$.

1. Écrire la matrice de covariance Σ , et donner la loi de $L = X_1 + X_2$.
2. Calculer $\text{VaR}_{0,995}$ de X_1 , de X_2 et de L ($z_{0,995} \approx 2,576$). Quel est le gain de diversification ?
3. Reprendre le calcul de $\text{VaR}_{0,995}(L)$ pour $\rho = 1$, $\rho = 0$ et $\rho = -0,5$.
4. On investit une proportion w dans le premier risque et $1 - w$ dans le second. Quelle valeur de w minimise la variance de la perte $wX_1 + (1 - w)X_2$?

Exercice 2 — Simuler des risques corrélés.

1. Soient Z_1, Z_2 indépendantes de loi $\mathcal{N}(0, 1)$ et $|\rho| < 1$. Montrer que $W = \rho Z_1 + \sqrt{1 - \rho^2} Z_2$ suit $\mathcal{N}(0, 1)$ et que $\text{Cov}(Z_1, W) = \rho$.
2. Écrire un script qui simule 10^6 couples (Z_1, W) pour $\rho = 0,7$, puis estime leur corrélation et la probabilité conditionnelle $\mathbb{P}(W > q \mid Z_1 > q)$ pour $q = \Phi^{-1}(0,99)$. Comparer à la valeur exacte 0,27.

Exercice 3 — Chocs communs.

Deux régions subissent des sinistres : $N_1 = M_0 + M_1$ et $N_2 = M_0 + M_2$, où $M_0 \sim \text{Po}(2)$ compte les événements qui touchent les deux régions (tempêtes) et $M_1, M_2 \sim \text{Po}(3)$ les événements locaux, les trois variables étant indépendantes.

1. Quelle est la loi de N_1 ? de N_2 ?
2. Calculer $\text{Cov}(N_1, N_2)$ et le coefficient de corrélation.
3. Calculer la fonction génératrice de $N_1 + N_2$, son espérance et sa variance. $N_1 + N_2$ suit-elle une loi de Poisson ?
4. On donne $\mathbb{P}(N_1 \geq 8, N_2 \geq 8) \approx 0,0435$ et $\mathbb{P}(N_1 \geq 8) \approx 0,133$. Comparer avec le cas de deux régions indépendantes de même loi. Interpréter.

Exercice 4 — Corrélation nulle, extrêmes liés.

On reprend $X \sim \mathcal{N}(0, 1)$, $S = \pm 1$ avec probabilité $\frac{1}{2}$ indépendante de X , et $Y = SX$.

1. Démontrer la proposition du cours : $Y \sim \mathcal{N}(0, 1)$, $\text{Cov}(X, Y) = 0$, X et Y ne sont pas indépendantes, et (X, Y) n'est pas gaussien.
2. Calculer $\mathbb{P}(X > 2, Y > 2)$ et comparer à $\mathbb{P}(X > 2)\mathbb{P}(Y > 2)$.
3. Quel est le coefficient de dépendance de queue ? Que retenir pour la modélisation ?

Exercice 5 — Marges, dépendance et mesure de risque.

On considère deux pertes de marges fixées, $X \sim \text{Exp}(1/10)$ et Y de loi de Pareto ($x_m = 5$, $\theta = 2$), celles de l'exercice 1 du TD 4. On les couple par une copule gaussienne : $X = F^{-1}(\Phi(Z_1))$ et $Y = G^{-1}(\Phi(W))$, avec (Z_1, W) comme dans l'exercice 2.

1. Vérifier que X et Y ont bien les lois annoncées.

2. Écrire un script estimant $\text{VaR}_{0,99}(X + Y)$ et $\text{TVaR}_{0,99}(X + Y)$ pour $\rho = 0$ et $\rho = 0,7$, avec 10^6 simulations.
3. Comparer avec $\text{VaR}_{0,99}(X) + \text{VaR}_{0,99}(Y)$ et $\text{TVaR}_{0,99}(X) + \text{TVaR}_{0,99}(Y)$. Que se passe-t-il si X et Y sont comonotones ?

5.3 Corrigés du TD 5

Exercice 1.

1. $\Sigma = \begin{pmatrix} 9 & 6 \\ 6 & 16 \end{pmatrix}$, car $\text{Cov}(X_1, X_2) = 0,5 \times 3 \times 4 = 6$. Avec $a = (1, 1)$, L est normale d'espérance 30 et de variance $a^\top \Sigma a = 9 + 16 + 2 \times 6 = 37$: $L \sim \mathcal{N}(30, 37)$, $\sigma_L \approx 6,08$.
2. $\text{VaR}(X_1) = 10 + 3 \times 2,576 \approx 17,73$; $\text{VaR}(X_2) = 20 + 4 \times 2,576 \approx 30,30$; $\text{VaR}(L) = 30 + 6,08 \times 2,576 \approx 45,67$. La somme des VaR vaut 48,03 : le gain de diversification est $2,576 \times (3+4-6,08) \approx 2,36$.
3. $\sigma_L^2 = 25 + 24\rho$. Pour $\rho = 1$: $\sigma_L = 7$, $\text{VaR} = 48,03$ (aucun gain). Pour $\rho = 0$: $\sigma_L = 5$, $\text{VaR} \approx 42,88$. Pour $\rho = -0,5$: $\sigma_L = \sqrt{13} \approx 3,61$, $\text{VaR} \approx 39,29$. Le gain croît quand la corrélation baisse.
4. $\text{Var}(wX_1 + (1-w)X_2) = 9w^2 + 16(1-w)^2 + 12w(1-w)$, de dérivée $18w - 32(1-w) + 12(1-2w) = 26w - 20$, nulle pour $w = 10/13 \approx 0,77$. La variance y vaut $1404/169 \approx 8,31$, inférieure à celle de chacun des deux risques.

Exercice 2.

1. (Z_1, Z_2) est gaussien, donc $W = (\rho, \sqrt{1-\rho^2}) (Z_1, Z_2)^\top$ est normale, d'espérance 0 et de variance $\rho^2 + (1-\rho^2) = 1$. Par bilinéarité, $\text{Cov}(Z_1, W) = \rho \text{Var } Z_1 + \sqrt{1-\rho^2} \text{Cov}(Z_1, Z_2) = \rho$.
2. Script possible :

```
import numpy as np
from scipy.stats import norm
rng = np.random.default_rng(7)
n, r = 10**6, 0.7
Z1, Z2 = rng.standard_normal((2, n))
W = r*Z1 + np.sqrt(1 - r*r)*Z2
q = norm.ppf(0.99)
print(np.corrcoef(Z1, W)[0, 1], np.mean((Z1 > q) & (W > q)) / 0.01)
```

On obtient une corrélation proche de 0,70 et une probabilité conditionnelle proche de 0,27 : malgré une corrélation de 0,7, quand l'un des risques dépasse son quantile à 99 %, l'autre ne le dépasse qu'une fois sur quatre.

Exercice 3.

1. Somme de lois de Poisson indépendantes : N_1 et N_2 suivent $\text{Po}(5)$.
2. Par bilinéarité et indépendance, $\text{Cov}(N_1, N_2) = \text{Cov}(M_0, M_0) = \text{Var } M_0 = 2$, d'où $\rho = 2/\sqrt{5 \times 5} = 0,4$.
3. $N_1 + N_2 = 2M_0 + M_1 + M_2$, somme de variables indépendantes. La fonction génératrice de $2M_0$ est $\mathbb{E}[s^{2M_0}] = G_{M_0}(s^2) = e^{2(s^2-1)}$, donc $G_{N_1+N_2}(s) = e^{2(s^2-1)}e^{3(s-1)}e^{3(s-1)} = e^{2(s^2-1)+6(s-1)}$. Espérance : $2 \times 2 + 3 + 3 = 10$; variance : $4 \times 2 + 3 + 3 = 14$. Comme $14 \neq 10$, $N_1 + N_2$ ne suit pas une loi de Poisson : les chocs communs créent de la surdispersion.
4. Si les régions étaient indépendantes, $\mathbb{P}(N_1 \geq 8, N_2 \geq 8) = 0,133^2 \approx 0,0178$. Le choc commun multiplie par 2,4 la probabilité d'une année difficile dans les deux régions à la fois, avec une corrélation pourtant modérée (0,4). C'est ce type d'effet qui limite la mutualisation géographique en assurance des catastrophes naturelles.

Exercice 4.

1. Voir la démonstration du cours.
2. $\{X > 2, Y > 2\} = \{X > 2, S = 1\}$, donc $\mathbb{P}(X > 2, Y > 2) = \frac{1}{2}(1 - \Phi(2)) \approx 0,0114$, contre $(1 - \Phi(2))^2 \approx 0,00052$ si les variables étaient indépendantes : 22 fois plus.
3. $\lambda_U = \frac{1}{2}$ (cours). Une corrélation nulle n'exclut pas des extrêmes fortement liés : la corrélation ne suffit pas à décrire la dépendance entre risques, surtout dans les queues.

Exercice 5.

1. $\Phi(Z_1)$ et $\Phi(W)$ suivent $\text{Un}(0,1)$ (réciproque de l'inversion, séance 2, car Z_1 et W suivent $\mathcal{N}(0,1)$), donc X et Y ont les lois de fonctions de répartition F et G (théorème d'inversion).
2. Script possible :

```
import numpy as np
from scipy.stats import norm
rng = np.random.default_rng(6)
n = 10**6
for r in (0.0, 0.7):
    Z1, Z2 = rng.standard_normal((2, n))
    W = r*Z1 + np.sqrt(1 - r*r)*Z2
    X = -10*np.log(1 - norm.cdf(Z1))      # Exp(1/10)
    Y = 5*(1 - norm.cdf(W))**(-1/2)      # Pareto(5 ; 2)
    L = np.sort(X + Y)
    var = L[int(np.ceil(0.99*n)) - 1]
    print(r, var, L[L > var].mean())
```

On obtient environ $\text{VaR} \approx 70$ et $\text{TVaR} \approx 116$ pour $\rho = 0$, et $\text{VaR} \approx 87$ et $\text{TVaR} \approx 144$ pour $\rho = 0,7$. (La loi de Pareto ayant une variance infinie, les estimations de TVaR fluctuent sensiblement d'un tirage à l'autre.)

3. Avec les valeurs du TD 4, $\text{VaR}(X) + \text{VaR}(Y) \approx 46,1 + 50 = 96,1$ et $\text{TVaR}(X) + \text{TVaR}(Y) \approx 56,1 + 100 = 156,1$. La TVaR de la somme reste inférieure à la somme des TVaR , comme l'assure la sous-additivité. Si X et Y sont comonotones ($Y = g(X)$ avec g croissante), alors $X + Y = (\text{id} + g)(X)$ est une fonction continue strictement croissante de X , et le même raisonnement qu'en (b) de la proposition sur la dépendance de queue donne $\text{VaR}_\alpha(X + Y) = q_\alpha(X) + g(q_\alpha(X)) = \text{VaR}_\alpha(X) + \text{VaR}_\alpha(Y)$: aucun gain de diversification. La dépendance, et pas seulement les marges, détermine le capital nécessaire.

A Présentation du cours

Cette annexe vous présente les objectifs du cours, l'enchaînement des séances et les liens entre elles. Lisez-la avant la première séance, puis revenez-y à la fin du cours : elle vous aidera à voir comment les outils s'articulent.

A.1 Pourquoi ce cours ?

Dans le cours d'introduction, vous avez appris à décrire *une* variable aléatoire : sa loi, son espérance, sa variance. Or en gestion des risques, on ne s'intéresse presque jamais à une variable isolée. La charge annuelle d'un assureur est une somme de sinistres dont le nombre est lui-même aléatoire, et dont la fréquence varie d'une année à l'autre. Le capital qu'une compagnie doit immobiliser se fixe sur un quantile extrême de ses pertes, pas sur leur moyenne. Un ouvrage de protection est dimensionné sur la pire crue, et deux régions voisines peuvent être frappées par la même tempête.

Ce cours répond à cinq questions, une par séance :

- comment calculer quand on **additionne** des variables, dépendantes ou non, et comment utiliser une information partielle pour **prédire** ;
- comment calculer quand le nombre de termes est **lui-même aléatoire**, quand son intensité est **hétérogène**, ou quand on **transforme** une variable ;
- que se passe-t-il quand on additionne **beaucoup** de variables, ou quand on regarde **la pire** d'entre elles ;
- comment **mesurer** un risque par un seul nombre, et comment estimer par simulation la probabilité d'événements **très rares** ;
- comment décrire **plusieurs risques à la fois**, et leur tendance à survenir **ensemble**.

L'objectif est que l'espérance, la variance et la loi deviennent pour vous des outils de raisonnement sur des systèmes de risques, et plus seulement des calculs sur des lois isolées.

A.2 Séance 1 : additionner des variables, conditionner

Vous commencerez par recalculer l'espérance et la variance des lois de Poisson, exponentielle et normale. Ce n'est pas une simple révision : vous verrez que vous utilisiez déjà, sans le nommer, le théorème de transfert chaque fois que vous écriviez $\mathbb{E}[X^2] = \int x^2 f(x) dx$, et vous comprendrez pourquoi certains calculs passent par $X(X-1)$ ou par une intégration par parties.

L'idée centrale de la séance est la suivante : **l'espérance d'une somme est la somme des espérances, même quand les variables sont dépendantes**. Combinée aux indicatrices, elle permet de traiter en quelques lignes des problèmes de dénombrement difficiles, comme le contrôle d'un lot par échantillonnage.

La variance, elle, ne s'additionne que si les variables sont non corrélées. Vous en tirerez une conséquence très concrète : **la diversification est plafonnée par la corrélation**. Un assureur peut mutualiser des incendies indépendants, mais pas une tempête qui touche tous ses contrats ; en milieu industriel, c'est la question des causes communes de défaillance.

La séance se termine par la **variance totale** et l'**espérance conditionnelle**. La première décompose la variabilité en une part interne à des groupes et une part entre les groupes, ce qui explique pourquoi une carte de contrôle calculée sur un lot mélangé est trompeuse. La seconde, $\mathbb{E}[X | Y]$, est la meilleure prédiction de X quand on connaît Y . Un exercice vous fera découvrir un phénomène qui reviendra souvent : un mélange de lois de Poisson n'est plus une loi de Poisson.

A.3 Séance 2 : sommes aléatoires, hétérogénéité, transformations

Les **fonctions génératrices** codent une loi de façon à transformer les sommes de variables indépendantes en produits. Elles vous permettront de retrouver en deux lignes les résultats de la séance 1, ce qui vous donne un moyen de vérifier vos calculs.

Le cur de la séance est la **somme aléatoire** : un nombre aléatoire d'événements, chacun d'une gravité aléatoire. C'est le modèle de base de l'assurance (nombre de sinistres $\times$ coût) comme du risque industriel ou naturel (nombre de départs de feu $\times$ surface brûlée). Les formules de Wald, qui en découlent, séparent deux sources de risque : la **fréquence** et la **sévérité**.

Vous étudierez ensuite l'**amincissement** d'une loi de Poisson, qui donne un résultat surprenant : lorsqu'on ne retient qu'une partie des événements, les événements retenus sont indépendants des événements rejetés. Ce résultat suppose une intensité connue. Les **mélanges de lois de Poisson** décrivent une intensité qui varie d'une année à l'autre (sécheresse, conjoncture économique) : ils rendent les années extrêmes beaucoup plus probables qu'un modèle de Poisson de même moyenne, et conduisent à la loi binomiale négative. Retenez ce réflexe : avant d'utiliser un modèle de Poisson, comparez la moyenne et la variance des données.

La séance s'achève sur les **changements de variable** et la **méthode d'inversion**, qui permet de simuler n'importe quelle loi à partir de nombres aléatoires uniformes. L'inverse de la fonction de répartition que vous y rencontrerez reviendra en séance 4, sous le nom de quantile, et en séance 5, pour construire des lois à plusieurs dimensions.

A.4 Séance 3 : garanties, lois limites, extrêmes

Les **inégalités de Markov et de Chebyshev** bornent une probabilité sans connaître la loi, et la **borne de Chernoff** fait beaucoup mieux pour les événements rares. La **loi des grands nombres** démontre ce que vous avez admis au début de votre formation : la fréquence d'un événement se rapproche de sa probabilité. C'est ce qui justifie la simulation Monte-Carlo, et vous apprendrez à la dimensionner : il faut environ $400/p$ tirages pour estimer une probabilité p à 10 % près.

Le **théorème central limite** explique pourquoi la loi normale est partout. Il fournit aussi l'**intervalle de confiance** qui doit accompagner tout résultat de simulation : un chiffre simulé sans sa précision n'a pas de valeur. Mais retenez surtout sa limite : il décrit bien le centre des distributions, **pas leurs queues**. Sur un exemple, l'approximation normale sous-estime une probabilité rare d'un facteur 700, et la loi de Cauchy vous montrera un cas où une moyenne ne se stabilise jamais.

La séance se termine par les **valeurs extrêmes** : loi du maximum, niveau et période de retour. Vous verrez qu'une pluie « centennale » a presque deux chances sur trois de se produire au cours d'un siècle.

A.5 Séance 4 : mesurer le risque, simuler l'improbable

Un risque se résume souvent par un nombre, sur lequel on fixe un capital ou un dimensionnement. La **Value-at-Risk** (VaR) est un quantile : c'est la mesure retenue par la réglementation européenne des assurances (Solvabilité II), et un niveau de retour n'est rien d'autre qu'une VaR. Vous démontrerez pourtant qu'elle a deux défauts graves : elle ne dit rien des pertes au-delà d'elle, et elle **n'est pas sous-additive**, si bien que regrouper deux risques peut augmenter la VaR totale. La **TVaR**, perte moyenne dans les pires cas, corrige ces deux défauts. Sur trois lois de même espérance, vous verrez la TVaR à 99 % varier de 37 à 100 selon le poids de la queue.

Estimer ces mesures par simulation pose un problème : seule une petite fraction des tirages tombe dans la queue. L'**échantillonnage préférentiel** y répond en simulant sous une loi qui rend l'événement fréquent, puis en corrigeant par un poids. Sur un exemple, il remplace plusieurs milliards de tirages par quelques milliers.

A.6 Séance 5 : plusieurs risques à la fois

La **matrice de covariance** décrit un portefeuille de risques et donne en une formule la variance de la perte totale. Les **vecteurs gaussiens** vous permettront de simuler des risques corrélés, et

vous verrez que, dans ce cadre, la VaR récompense toujours la diversification aux niveaux usuels ($\alpha \geq 1/2$).

La séance montre ensuite les **limites de la corrélation**. Deux risques peuvent être non corrélés et pourtant liés dans les extrêmes : sur un exemple, une corrélation nulle coexiste avec une chance sur deux que les deux risques soient extrêmes en même temps. Le **coefficient de dépendance de queue** mesure cette tendance aux catastrophes simultanées ; il est nul pour un vecteur gaussien, ce qui rend les modèles gaussiens trop optimistes. Un modèle de **chocs communs**, une tempête qui touche deux régions, vous montrera ce qui limite la mutualisation géographique. Le cours s'ouvre enfin sur les **copules**, qui permettent de choisir séparément la loi de chaque risque et la forme de leur dépendance.

A.7 Les fils conducteurs du cours

Les séances ne sont pas des chapitres indépendants : chacune réutilise les précédentes. Gardez en tête les fils suivants, qui vous aideront à relier les résultats.

- **Découper selon les valeurs d'une autre variable**. C'est la même idée qui sert pour les lois marginales, la variance totale, l'espérance conditionnelle, les sommes aléatoires, l'amin-cissement et les mélanges.
- **Une seule limite fondamentale**, $(1 + a/n)^n \rightarrow e^a$, sert pour l'approximation de Poisson, le théorème central limite, la loi de Gumbel et la période de retour.
- **L'inverse de la fonction de répartition** relie la simulation (séance 2), la VaR (séance 4) et les copules (séance 5).
- **Les événements rares** relient la borne de Chernoff et le dimensionnement des simulations (séance 3) à la TVaR et à l'échantillonnage préférentiel (séance 4).
- **La diversification** traverse tout le cours : corrélation (séance 1), sous-additivité (séance 4), dépendance de queue et chocs communs (séance 5).

A.8 Ce que vous saurez faire à l'issue du cours

Vous disposerez de **méthodes réutilisables plutôt que de formules** : indicatrices, conditionnement, fonctions génératrices, simulation. Vous saurez aussi calculer un même résultat de plusieurs façons, ce qui reste le meilleur moyen de vérifier un calcul.

Vous saurez mettre en uvre des **outils professionnels** : modéliser une charge de sinistres par fréquence et sévérité, tenir compte de l'hétérogénéité d'une fréquence, calculer une VaR et une TVaR, dimensionner une simulation et en donner la précision, déterminer un niveau de retour, agréger des risques corrélés.

Surtout, vous aurez développé un **sens critique** : savoir quand un modèle ou une approximation cesse d'être valable. L'approximation normale échoue dans les queues, le modèle de Poisson ignore l'hétérogénéité, la VaR peut pénaliser la diversification, et la corrélation ne dit rien des catastrophes simultanées. Pour un ingénieur risque, c'est souvent plus important que le calcul lui-même.

A.9 Comment travailler

Le cours comprend cinq séances de deux heures, complétées par un travail personnel indispensable. Le tableau d'organisation, au début du document, indique pour chaque séance ce qu'il faut préparer, ce qui sera traité en séance et ce qu'il faut faire ensuite.

- **Avant la séance**, lisez les rappels et préparez les exercices indiqués : ce sont surtout des calculs directs, qui libèrent du temps en séance pour les idées nouvelles.
- **Après la séance**, traitez les exercices d'approfondissement, en particulier ceux qui demandent un script Python : simuler un résultat que l'on vient de démontrer est la meilleure façon de le comprendre.

- **Refaites les démonstrations** sans regarder le texte. Chacune est découpée en étapes dont le titre annonce l'idée : si vous savez retrouver l'enchaînement des étapes, vous avez compris le résultat.
- **Repérez ce qui est démontré et ce qui est admis.** Le document le signale toujours ; savoir sur quoi repose un outil, c'est savoir quand on a le droit de l'utiliser.
- **Utilisez les corrigés après avoir cherché**, pas avant : ils détaillent chaque étape pour vous permettre de repérer précisément où votre raisonnement s'est arrêté.